





دانشکده‌گان علوم
دانشکده ریاضی، آمار و علوم کامپیوتر

هرس کردن مجموعه داده های بزرگ با روش عدم قطعیت دینامیک

نگارنده
بهار نیک نام
استاد راهنما
دکتر هدیه ساجدی

پایان نامه برای دریافت درجه کارشناسی ارشد
در رشته آمار ریاضی

دی ۱۴۰۴

تقدیم به

مادر کرامی ام، که با حمایت و دلگرمی های بی دریغ خود
همواره پشتیبان و مشوق راه علمی من بوده اند.
و نیز استاد فریخته ام که با دانش و رهنمودهای ارزشمند خود، چراغ
راه پژوهش و تلاش علمی ام شدند.
و به تمامی عزیزانی که با حضور، محبت و دلگرمی شان، مرادیه سمودن
این مسیریاری کردند.

سپاسگزاری

باتقدیر و سپاس فراوان مراتب قدردانی و سپاس صمیمانه خود را از زحمات، راهنمایی‌های ارزشمند و صبر و حوصله بی‌دریغ سرکار خانم دکتر هدیه ساجدی، استاد راهنمای گرامی این پایان نامه، ابراز می‌دارم. بی‌تردید همراهی، راهنمایی‌های دلسوزانه و نظرات علمی ایشان نقش بسزایی در پیشرفت و تکمیل این پژوهش داشته است.

بهار نیک‌نام
ذی ۱۴۰۴

تعهدنامه اصالت اثر

هیچ قسمت از این پایان‌نامه، پیش از این در هیچ موسسه تحصیلات عالی برای دریافت درجه تحصیلی استفاده نشده است. همچنین، هیچ قسمت از این پایان‌نامه برگردان فارسی تمامی یا قسمتی از یک اثر دیگر علمی (مانند مقاله، پایان‌نامه، و غیره) به زبانی دیگر نمی‌باشد. ارائه این پایان‌نامه توسط اینجانب بهار نیک نام به معاونت آموزشی (معاونت پژوهشی و تحصیلات تکمیلی برای ارشد به منزله تعهد نگارنده به اصالت متن و محتوای ارائه شده بر اساس یک کار پژوهشی در مدت تحصیل در دانشگاه تهران می‌باشد. در صورت اثبات خلاف این امر، مدرک تحصیلی اخذ شده توسط این پایان‌نامه از دانشگاه تهران، معتبر نمی‌باشد.

نام و نام خانوادگی امضا

حق مالکیت معنوی

حق مالکیت معنوی این اثر متعلق به دانشگاه تهران می‌باشد. استفاده از مطالب این پایان‌نامه در فعالیت‌های تحقیقاتی با ذکر منبع بلامانع می‌باشد. در صورت استفاده تجاری، مانند چاپ این پایان‌نامه، هماهنگی لازم و اجازه کتبی از دانشگاه و نگارنده پایان‌نامه الزامی می‌باشد.

چکیده

با افزایش حجم داده‌ها در مسائل یادگیری عمیق، هزینه‌های محاسباتی، زمان آموزش و مصرف انرژی به‌طور قابل توجهی افزایش یافته است، در حالی که افزایش داده‌ها همواره به بهبود متناسب عملکرد مدل منجر نمی‌شود. از این رو، هرس داده‌ها به‌عنوان یکی از رویکردهای مؤثر برای کاهش حجم داده‌های آموزشی با حفظ کارایی مدل مطرح شده است. در این پایان‌نامه، یک روش هرس داده‌ی پویا مبتنی بر عدم قطعیت ارائه می‌شود که هدف آن شناسایی و حذف داده‌های کم‌اهمیت و غیرضروری در فرآیند آموزش است.

در روش پیشنهادی، اهمیت داده‌ها با توجه به رفتار مدل در طول فرآیند آموزش و با استفاده از یک سازوکار امتیازدهی پویا مبتنی بر زمان، به‌صورت تطبیقی ارزیابی می‌شود. این سازوکار با بهره‌گیری از یک امتیازدهی دوعمقی زمانی، امکان تفکیک مؤثر داده‌های کم‌اهمیت از داده‌های اثرگذار را فراهم کرده و مجموعه‌ی داده‌های آموزشی را به‌طور تدریجی پالایش می‌کند. نتایج ارزیابی‌های تجربی نشان می‌دهد که روش ارائه‌شده قادر است با حذف بخش قابل توجهی از داده‌ها، افت دقت ناچیزی در عملکرد مدل ایجاد کرده و در عین حال پایداری مناسبی در فرآیند یادگیری حفظ نماید. این نتایج بیانگر آن است که هرس داده‌ی پویا مبتنی بر عدم قطعیت می‌تواند به‌عنوان راهکاری کارآمد برای بهبود مقیاس‌پذیری و کاهش هزینه‌های آموزش مدل‌های یادگیری عمیق مورد استفاده قرار گیرد. کلمات کلیدی: هرس داده، یادگیری عمیق، عدم قطعیت، امتیازدهی دوعمقی زمانی، انتخاب نمونه، مقیاس‌پذیری

پیشگفتار

با گسترش روزافزون کاربردهای یادگیری عمیق در حوزه‌های مختلف علمی و صنعتی، حجم داده‌های مورد استفاده برای آموزش مدل‌ها به‌طور چشمگیری افزایش یافته است. این افزایش حجم داده، اگرچه در بسیاری از موارد منجر به بهبود عملکرد مدل‌ها می‌شود، اما هزینه‌های محاسباتی، زمان آموزش و مصرف انرژی را نیز به‌طور قابل توجهی افزایش می‌دهد. از سوی دیگر، مطالعات اخیر نشان داده‌اند که مطابق قانون مقیاس‌پذیری توانی، افزودن داده‌های بیشتر لزوماً به بهبود متناسب و خطی عملکرد مدل منجر نمی‌شود. این مسئله ضرورت توجه به کارایی داده‌ها و استفاده‌ی بهینه از مجموعه داده‌های آموزشی را بیش از پیش آشکار می‌سازد.

در این راستا، هرس داده‌ها به‌عنوان یکی از رویکردهای مؤثر برای کاهش حجم داده‌های آموزشی با حفظ عملکرد مدل مطرح شده است. هدف اصلی هرس داده‌ها، شناسایی و حذف نمونه‌های کم‌اهمیت، تکراری یا غیرضروری به‌گونه‌ای است که فرآیند یادگیری دچار افت معنا دار نشود. این رویکرد در مقایسه با روش‌هایی نظیر هرس مدل یا کاهش معماری شبکه، بدون تغییر در ساختار مدل، مستقیماً بر داده‌های ورودی تمرکز داشته و از این منظر دارای مزایای عملی قابل توجهی است. با این حال، تعیین اهمیت داده‌ها و تصمیم‌گیری درباره‌ی حذف یا نگه‌داری آن‌ها، به‌ویژه در فرآیندهای یادگیری عمیق، همچنان یک چالش اساسی محسوب می‌شود.

پژوهش‌های پیشین در حوزه‌ی هرس داده، معیارهای متنوعی را برای سنجش اهمیت نمونه‌ها پیشنهاد داده‌اند؛ از جمله معیارهای مبتنی بر خطای پیش‌بینی، اطمینان مدل، گرادیان، هندسه‌ی داده‌ها و پویایی یادگیری. هر یک از این رویکردها، اگرچه در شرایط خاصی مؤثر بوده‌اند، اما معمولاً با محدودیت‌هایی از جمله حساسیت به نویز، عدم پایداری در طول آموزش یا نیاز به محاسبات پرهزینه همراه هستند. در سال‌های اخیر، توجه پژوهشگران به روش‌های پویا معطوف شده است که رفتار مدل را در طول فرآیند آموزش در نظر می‌گیرند و تلاش می‌کنند اهمیت داده‌ها را به‌صورت تطبیقی و زمان‌مند ارزیابی نمایند. این دسته از روش‌ها زمینه‌ی مناسبی برای بهبود مقیاس‌پذیری و کارایی آموزش مدل‌های عمیق فراهم کرده‌اند.

هدف این پایان‌نامه، ارائه‌ی یک روش هرس داده‌ی پویا مبتنی بر عدم قطعیت است که بتواند با در نظر گرفتن رفتار مدل در طول آموزش، داده‌های کم‌اهمیت را به‌صورت تدریجی شناسایی و حذف نماید. در این پژوهش تلاش شده است تا با تمرکز بر پایداری فرآیند یادگیری و حفظ دقت مدل، راهکاری ارائه شود که ضمن کاهش حجم داده‌های آموزشی، اثرات منفی حذف داده‌ها بر عملکرد نهایی مدل به حداقل برسد. نتایج کلی حاصل از این پژوهش نشان می‌دهد که استفاده از هرس داده‌ی

پویا می‌تواند نقش مؤثری در کاهش هزینه‌های محاسباتی و بهبود کارایی آموزش مدل‌های یادگیری عمیق ایفا کند.

این پایان‌نامه بر پایه‌ی مطالعات نظری و تجربی انجام‌شده در زمینه‌ی هرس داده، یادگیری عمیق و روش‌های مبتنی بر عدم قطعیت تدوین شده است و در بخش‌هایی از آن، از نتایج و ایده‌های مطرح‌شده در مقالات معتبر این حوزه بهره گرفته شده است. مراجع اصلی مورد استفاده در توسعه‌ی چارچوب مفهومی و روش پیشنهادی، در فصل‌های مربوطه معرفی و مورد بحث قرار گرفته‌اند.

در ادامه، ساختار کلی پایان‌نامه به‌صورت زیر است. در فصل اول، مفاهیم پایه، تعاریف و مبانی نظری مرتبط با داده، مجموعه داده، هسته داده، هرس داده و قانون مقیاس‌پذیری مرور می‌شود. فصل دوم به بررسی و تحلیل پژوهش‌های مرتبط در حوزه‌ی هرس داده و تقطیر دادگان اختصاص دارد و رویکردهای موجود به‌صورت منظم دسته‌بندی و مقایسه می‌شوند. در فصل سوم، روش پیشنهادی این پژوهش معرفی شده و چارچوب کلی آن تشریح می‌گردد. فصل چهارم به پیاده‌سازی، تنظیمات آزمایشی و ارائه‌ی نتایج تجربی اختصاص دارد و عملکرد روش پیشنهادی با روش‌های مرجع مقایسه می‌شود. در نهایت، فصل پنجم شامل جمع‌بندی نتایج، نتیجه‌گیری و پیشنهادهایی برای پژوهش‌های آینده است.

فهرست مطالب

یک	چکیده
دو	پیشگفتار
هفت	فهرست مطالب
نه	فهرست شکل‌ها
ده	فهرست جداول
۱	۱ تعاریف و مفاهیم مقدماتی
۱	۱.۱ تعریف داده
۲	۲.۱ تعریف مجموعه داده
۳	۳.۱ داده‌های تکراری و زائد
۳	۴.۱ تعریف هسته داده
۵	۵.۱ تعریف هرس داده
۶	۶.۱ مقیاس‌پذیری قانون توانی و نمایی
۷	۱.۶.۱ مشکلات مقیاس‌پذیری قانون توانی
۷	۲.۶.۱ راه‌حل‌های پیشنهادی برای حل مشکلات مقیاس‌پذیری قانون توانی
۸	۷.۱ جمع‌بندی
۹	۲ پژوهش‌های مرتبط
۱۰	۱.۲ هرس داده‌ها بر اساس معیارهای مدل
۱۰	۱.۱.۲ هرس مبتنی بر عملکرد مدل
۱۰	۱.۱.۱.۲ هرس مبتنی بر خطای پیش‌بینی
۱۲	۲.۱.۱.۲ هرس مبتنی بر معیار اطمینان مدل
۱۴	۳.۱.۱.۲ هرس مبتنی بر اثر داده بر عملکرد مدل
۱۶	۴.۱.۱.۲ هرس مبتنی بر حساسیت مدل به داده‌ها

۱۷	هرس مبتنی بر پایداری عملکرد مدل	۵.۱.۱.۲
۱۹	هرس مبتنی بر معیارهای کلی ارزیابی	۶.۱.۱.۲
۲۱	هرس مبتنی بر ویژگی‌های مدل	۲.۱.۲
۲۱	هرس ویژگی‌های کم‌اطلاعات	۱.۲.۱.۲
۲۲	هرس ویژگی‌های تکراری	۲.۲.۱.۲
۲۳	هرس ویژگی‌های غیرضروری	۳.۲.۱.۲
۲۳	هرس داده‌ها بر اساس معیارهای داده‌ای و آماری	۲.۲
۲۴	هرس مبتنی بر اهمیت نمونه‌ها	۱.۲.۲
۲۵	هرس بر اساس شاخص‌های آماری	۱.۱.۲.۲
۲۶	هرس بر اساس شباهت داده‌ها	۲.۱.۲.۲
۲۸	هرس بر اساس توزیع داده‌ها	۲.۲.۲
۲۸	هرس بر اساس نواحی پرت داده‌ها	۱.۲.۲.۲
۲۹	هرس بر اساس چگالی داده‌ها	۲.۲.۲.۲
۳۰	هرس داده‌ها بر اساس الگوریتم‌ها و مدل‌های خاص	۳.۲
۳۱	هرس در درخت‌های تصمیم‌گیری	۱.۳.۲
۳۱	هرس پیش‌ساختی	۱.۱.۳.۲
۳۱	هرس پس‌ساختی	۲.۱.۳.۲
۳۲	هرس در شبکه‌های عصبی	۲.۳.۲
۳۲	حذف وزن‌ها	۱.۲.۳.۲
۳۳	حذف نورون‌ها	۲.۲.۳.۲
۳۴	هرس داده‌ها بر اساس معیارهای ریاضی و تابعی	۴.۲
۳۴	هرس مبتنی بر گرادیان	۱.۴.۲
۳۴	هرس مبتنی بر تغییرات گرادیان	۱.۱.۴.۲
۳۵	هرس مبتنی بر اهمیت گرادیان	۲.۱.۴.۲
۳۵	هرس مبتنی بر نرم‌ها و خطاها	۲.۴.۲
۳۵	هرس بر اساس نرم گرادیان	۱.۲.۴.۲
۳۶	هرس بر اساس نرم خطا	۲.۲.۴.۲
۳۶	هرس مبتنی بر تابع اثر	۳.۴.۲
۳۶	هرس بر اساس اثر محلی	۱.۳.۴.۲
۳۸	هرس بر اساس اثر جهانی	۲.۳.۴.۲
۳۸	هرس داده‌ها بر اساس هندسه داده‌ها	۵.۲
۳۹	هرس مبتنی بر تحلیل هندسی	۱.۵.۲
۳۹	هرس بر اساس خوشه‌بندی هندسی	۱.۱.۵.۲
۴۰	هرس بر اساس هندسه‌ی فضای ویژگی‌ها	۲.۱.۵.۲
۴۱	هرس مبتنی بر خوشه‌بندی فاصله‌ای	۲.۵.۲

۴۱	۱.۲.۵.۲	هرس داده‌ها بر اساس فاصله از مرکز خوشه	۶.۲
۴۱	۱.۶.۲	هرس داده‌ها بر اساس معیارهای فراموشی	۷.۲
۴۲	۲.۶.۲	هرس بر اساس فراموشی تدریجی	
۴۳	۳.۶.۲	هرس بر اساس فراموشی تصادفی	
۴۴	۱.۷.۲	مقایسه‌ی روش‌های فراموشی تدریجی و فراموشی تصادفی	
۴۴	۱.۷.۲	تقطیر دادگان	
۴۵	۱.۱.۷.۲	روش‌های مختلف تقطیر دادگان	
۴۵	۲.۱.۷.۲	یادگیری فشرده	
۴۶	۳.۱.۷.۲	کدگذاری و رمزگشایی	
۴۷	۴.۱.۷.۲	تکنیک‌های فاکتوریزه	
۴۹	۵.۱.۷.۲	الگوریتم‌های بهینه‌سازی	
۵۱	۶.۱.۷.۲	نمونه‌برداری از ویژگی‌ها	
۵۲	۷.۱.۷.۲	تقطیر مبتنی بر گرادیان	
۵۴	۸.۱.۷.۲	ترکیب ویژگی‌ها	
۵۵	۹.۱.۷.۲	روش‌های ترکیبی	
۵۵	۱۰.۱.۷.۲	تقطیر مبتنی بر یادگیری تقویتی	
۵۶	۲.۷.۲	شبیه‌سازی نمونه‌ها	
۵۷	۸.۲	مقایسه‌ی روش‌های مختلف تقطیر دادگان	
۵۹	۱.۸.۲	هرس داده‌ها با امتیازدهی دو عمقی زمانی	
۶۰	۲.۸.۲	فرمول‌بندی مسئله	
۶۰	۳.۸.۲	عمق بیرونی: بیشینه‌سازی واریانس زمانی	
۶۱	۴.۸.۲	عمق درونی: تخمین سهم واقعی نمونه‌ها	
۶۲	۵.۸.۲	تجمع زمانی با پنجره لغزان	
۶۲	۹.۲	آموزش آگاه از اهمیت نمونه‌ها	
۶۲	۱.۹.۲	هرس داده‌ها بر اساس عدم قطعیت پویا	
۶۳	۲.۹.۲	تعریف عدم قطعیت پیش‌بینی	
۶۳	۳.۹.۲	عدم قطعیت پویا و تحلیل زمانی	
۶۴	۴.۹.۲	امتیازدهی پویا به نمونه‌ها	
۶۴	۱۰.۲	معیار هرس داده‌ها	
۶۴	۳	جمع‌بندی	
۶۶	۱.۳	روش پیشنهادی	
۶۶	۱.۱.۳	توضیح معماری الگوریتم	
۶۶	۲.۱.۳	صورت‌بندی مسئله	
۶۷		ثبت دینامیک خروجی مدل در طول آموزش	

۶۸	نگاشت لاجیت به توزیع احتمال	۳.۱.۳
۶۹	عدم قطعیت پویا وزن دار	۴.۱.۳
۷۱	امتیازدهی دو عمقی زمانی هموار شده	۵.۱.۳
۷۳	نرمال سازی و ترکیب معیارها	۶.۱.۳
۷۴	انتخاب نمونه ها و هرس داده	۷.۱.۳
۷۶	وزن دهی مبتنی بر اهمیت در مرحله بازآموزی	۸.۱.۳
۷۷	تحلیل پیچیدگی زمانی و حافظه ای روش پیشنهادی	۲.۳
۷۷	پیچیدگی ثبت دینامیک خروجی مدل	۱.۲.۳
۷۸	پیچیدگی نگاشت لاجیت به توزیع احتمال	۲.۲.۳
۷۸	پیچیدگی محاسبه عدم قطعیت پویا وزن دار	۳.۲.۳
۷۸	پیچیدگی محاسبه امتیازدهی دو عمقی زمانی هموار شده	۴.۲.۳
۷۹	پیچیدگی نرمال سازی، ترکیب معیارها و مرتب سازی	۵.۲.۳
۷۹	پیچیدگی مرحله بازآموزی	۶.۲.۳
۸۰	جمع بندی پیچیدگی کلی	۷.۲.۳
۸۰	تحلیل نوآوری ها و تمایز روش پیشنهادی نسبت به Dyn-Unc و TDDS	۳.۳
۸۰	تحلیل نوآوری نسبت به روش Dyn-Unc	۱.۳.۳
۸۱	تحلیل نوآوری نسبت به روش TDDS	۲.۳.۳
۸۱	نوآوری در ترکیب چند معیاره و امتیازدهی نهایی	۳.۳.۳
۸۲	نوآوری در یکپارچه سازی هرس و بازآموزی	۴.۳.۳
۸۲	جمع بندی تمایزها	۵.۳.۳
۸۳	جمع بندی	۴.۳
۸۵	پیاده سازی و نتایج	۴
۸۵	مجموعه داده ها و پیش پردازش	۱.۴
۸۵	مجموعه داده CIFAR-10	۱.۱.۴
۸۶	مجموعه داده CIFAR-100	۲.۱.۴
۸۷	هدف از انتخاب مجموعه داده ها	۳.۱.۴
۸۷	کتابخانه ها، ابزارها و محیط اجرا	۲.۴
۸۸	مدل های مورد استفاده	۳.۴
۸۹	ResNet-18	۱.۳.۴
۸۹	ResNet-50	۲.۳.۴
۸۹	ConvNeXt	۳.۳.۴
۹۰	نتایج به تفکیک مجموعه داده	۴.۴
۹۰	نتایج دیتاست CIFAR-100	۱.۴.۴
۹۱	نتایج روی مدل ResNet-18	۱.۱.۴.۴

۹۴	تأثیر تغییرات ابرپارامترها	۲.۱.۴.۴
۹۹	نتایج دیتاست CIFAR-10	۲.۴.۴
۹۹	نتایج روی مدل ResNet-18	۱.۲.۴.۴
۱۰۴	نتایج روی مدل ResNet-50	۲.۲.۴.۴
۱۰۴	نتایج روی مدل ConvNeXt	۳.۲.۴.۴

۱۰۷	نتیجه‌گیری و جمع‌بندی	۵
۱۰۷	جمع‌بندی و نتیجه‌گیری	۱.۵
۱۰۸	مسیرهای آینده پژوهش	۲.۵
۱۱۰	واژه‌نامه	
۱۲۲	مراجع	

فهرست تصاویر

۱.۳	الگوریتم نهایی هرس داده‌های بزرگ با روش عدم قطعیت دینامیک	۸۴
۱.۴	مقایسه دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 در حالت آموزش با کل داده‌ها و آموزش با نسبت‌های مختلف حذف داده با استفاده از روش TD-DyUn	۹۳
۲.۴	تحلیل پارامتر اندازه پنجره k بر عملکرد مدل ResNet-18 روی مجموعه داده CIFAR-100. خطوط نمودار مربوط به مقادیر مختلف k هستند (مثلاً: $k = 10$ ، دایره: $k = 20$ ، مربع: $k = 30$) و عملکرد مدل را در نرخ‌های مختلف حذف داده نشان می‌دهند.	۹۵
۳.۴	نمودار Heatmap نشان‌دهنده دقت مدل TD-DyUn با معماری ResNet-18 روی مجموعه داده CIFAR-100 برای مقادیر مختلف پنجره k و نرخ‌های prune متفاوت است. رنگ‌ها و اعداد داخل سلول‌ها دقت (%) مدل را نشان می‌دهند.	۹۶
۴.۴	نمودار نشان‌دهنده تأثیر مقادیر مختلف α بر دقت مدل ResNet-18 روی مجموعه داده CIFAR-100 برای دو نرخ حذف متفاوت (۳۰٪ و ۸۰٪) است. بیشترین دقت در مقادیر میانی $\alpha \approx 0.5$ مشاهده می‌شود.	۹۸
۵.۴	تأثیر پارامتر α بر دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 برای نرخ‌های مختلف حذف داده در روش TD-DyUn	۹۹
۶.۴	تأثیر پارامتر β بر دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 برای نرخ‌های مختلف حذف داده در روش TD-DyUn	۱۰۰
۷.۴	تأثیر ضریب کاهش β بر دقت مدل ResNet-18 روی مجموعه داده CIFAR-100 برای نسبت‌های حذف مختلف. هر نمودار جزئی مربوط به یک نسبت حذف مشخص (۳۰٪، ۵۰٪، ۷۰٪) است و چهار میله در هر نمودار نشان‌دهنده مقادیر β برابر با ۰، ۰/۸۵، ۰/۹ و ۰/۹۵ هستند. ارتفاع هر میله دقت طبقه‌بندی پس از حذف داده و بازآموزی با وزن‌دهی اهمیت نمونه‌ها را نشان می‌دهد.	۱۰۱
۸.۴	دقت طبقه‌بندی مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-10 در نسبت‌های مختلف حذف داده با استفاده از روش پیشنهادی TD-DyUn	۱۰۳

- ۹.۴ دقت مدل ResNet-18 روی مجموعه داده CIFAR-10 برای نسبت های مختلف حذف داده در روش های ذکر شده. نمودار نشان می دهد که روش TD-DyUn کاهش دقت کمتری نسبت به سایر روش ها دارد و در حذف شدید داده عملکرد پایدارتری ارائه می دهد. ۱۰.۳
- ۱۰.۴ دقت طبقه بندی مدل ResNet-50 روی مجموعه داده CIFAR-10 برای نسبت های مختلف حذف داده. میله اول دقت مدل روی کل داده ها و میله های بعدی دقت پس از حذف ۳۰، ۵۰، ۷۰ و ۸۰ درصد داده ها را نشان می دهند. ۱۰.۵
- ۱۱.۴ دقت طبقه بندی مدل ConvNeXt روی مجموعه داده CIFAR-10 برای نسبت های مختلف حذف داده. میله اول دقت مدل روی کل داده ها و میله های بعدی دقت پس از حذف ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪ داده ها را نشان می دهند. ۱۰.۶

فهرست جداول

۴۴	مقایسه‌ی روش‌های فراموشی تدریجی و فراموشی تصادفی در هرس داده‌ها	۱.۲
۵۸	مقایسه‌ی روش‌های مختلف تقطیر دادگان	۲.۲
۸۷	خلاصه‌ی مجموعه‌داده‌ها و مراحل پیش‌پردازش مورد استفاده در آزمایش‌ها	۱.۴
۳.۴	دقت طبقه‌بندی مدل ResNet-18 روی مجموعه‌داده‌ی CIFAR-100 در نسبت‌های	
۹۲	مختلف حذف داده	
۴.۴	تأثیر پارامتر k بر عملکرد روش TD-DyUn بر روی مجموعه‌داده‌ی CIFAR-100	
۹۴	۱۰۰ با معماری ResNet-18	
۹۷	تأثیر α بر دقت مدل ResNet-18 روی CIFAR-100 با نرخ‌های حذف مختلف	۵.۴
۹۹	تأثیر β بر دقت مدل ResNet-18 روی CIFAR-100 برای نرخ‌های prune مختلف	۶.۴
۷.۴	دقت طبقه‌بندی مدل ResNet-18 روی مجموعه‌داده‌ی CIFAR-10 در نسبت‌های	
۱۰۲	مختلف حذف داده	
۸.۴	دقت طبقه‌بندی مدل ResNet-50 روی مجموعه‌داده CIFAR-10 پس از اعمال	
۱۰۴	نسبت‌های مختلف حذف با روش TD-DyUn	
۹.۴	دقت طبقه‌بندی مدل ConvNeXt روی مجموعه‌داده CIFAR-10 پس از اعمال	
۱۰۵	نسبت‌های مختلف حذف با روش TD-DyUn	

فصل ۱

تعاریف و مفاهیم مقدماتی

در این فصل، به منظور ایجاد درک مفهومی یکسان از مبانی نظری پژوهش حاضر، مفاهیمی که در سرتاسر این تحقیق مورد استفاده قرار می‌گیرند، تعریف و بررسی می‌شوند. این تعاریف شامل داده^۲ و مجموعه داده^۳، داده‌های تکراری و زائد، مفهوم هرس داده^۴، هسته داده^۵، اهمیت داده و کارایی داده هستند. درک دقیق این مفاهیم برای تبیین اهمیت مسئله‌ی هرس داده و ارتباط آن با کارایی مدل‌های یادگیری عمیق، ضروری است.

۱.۱ تعریف داده

داده به مجموعه‌ای از مشاهدات^۶، اندازه‌گیری‌ها^۷ یا نمونه‌هایی^۸ گفته می‌شود که از پدیده‌های واقعی یا فرآیندهای مصنوعی به دست آمده‌اند و می‌توانند به صورت عددی^۹، متنی^{۱۰}، تصویری^{۱۱} یا صوتی^{۱۲} نمایش داده شوند.

در علوم داده و یادگیری ماشین، داده معمولاً به صورت زوج‌های (x_i, y_i) تعریف می‌شود که در آن x_i بردار ویژگی‌ها^{۱۳} و y_i برچسب یا خروجی^{۱۴} مورد انتظار است [۲۳].

²Data

³Dataset

⁴Data Pruning

⁵Coreset

⁶Observations

⁷Measurements

⁸Samples

⁹Numerical

¹⁰Textual

¹¹Visual

¹²Audio

¹³Feature vector

¹⁴Label or target output

داده‌ها ماده‌ی خام^۱ هستند که تمام فرآیندهای یادگیری^۲ بر پایه‌ی آن‌ها بنا می‌شوند و کیفیت و تنوع آن‌ها مستقیماً بر دقت^۳، تعمیم‌پذیری^۴ و پایداری مدل^۵ تأثیر می‌گذارد. در زمینه‌ی یادگیری ماشین، هدف اصلی یافتن تابعی $f_{\theta}(x)$ است که تخمین مناسبی از برچسب y را برای ورودی جدید x فراهم کند، به گونه‌ای که تابع زیان^۶ مورد انتظار روی توزیع داده‌ها^۷ کمینه شود. هر چه داده‌ها بهتر نماینده‌ی توزیع واقعی باشند، مدل به شکل مؤثرتری آموزش می‌بیند و قابلیت تعمیم بالاتری خواهد داشت. داده‌ها در واقع نمایندگان تجربی از توزیع احتمالی پنهانی $P(x, y)$ هستند.

۲.۱ تعریف مجموعه داده

مجموعه داده به مجموعه‌ای از داده‌های نمونه گفته می‌شود که برای آموزش، اعتبارسنجی و آزمون مدل‌های یادگیری استفاده می‌شود. معمولاً یک مجموعه داده به سه بخش تقسیم می‌گردد: مجموعه آموزشی^۸ برای به‌روزرسانی پارامترهای مدل و یادگیری الگوها استفاده می‌شود. مجموعه اعتبارسنجی^۹ به منظور تنظیم ابرپارامترها^{۱۰} و جلوگیری از بیش‌برازشی^{۱۱} کاربرد دارد. همچنین، مجموعه آزمایشی^{۱۲} برای ارزیابی عملکرد نهایی مدل بر روی داده‌های دیده‌نشده مورد استفاده قرار می‌گیرد.

در عصر داده‌های کلان^{۱۳}، اندازه‌ی مجموعه داده‌ها به‌طور چشمگیری افزایش یافته است. مجموعه‌هایی مانند ImageNet، COCO و JFT حاوی میلیون‌ها تصویر و برچسب هستند که آموزش مدل‌های بزرگ نظیر شبکه‌های عصبی کانولوشنی^{۱۴} یا ترنسفورمرها^{۱۵} را ممکن ساخته‌اند [۱۷]. با این حال، افزایش حجم داده‌ها منجر به رشد نمایی هزینه‌ی محاسباتی، زمان آموزش و مصرف انرژی می‌شود. از این رو، بهبود کارایی داده‌ها به عنوان چالشی اساسی مطرح شده است.

¹Raw material

²Learning processes

³Accuracy

⁴Generalization

⁵Model stability

⁶Loss function

⁷Data distribution

⁸Training set

⁹Validation set

¹⁰Hyperparameters

¹¹Overfitting

¹²Test set

¹³Big data

¹⁴Convolutional neural networks

¹⁵Transformers

۳.۱ داده‌های تکراری و زائد

یکی از ویژگی‌های ذاتی مجموعه داده‌های بزرگ، وجود داده‌های تکراری، مشابه یا کم‌اهمیت است که اطلاعات جدیدی برای مدل فراهم نمی‌کنند. چنین داده‌هایی می‌توانند شامل نمونه‌های بسیار مشابه^۱ از یک کلاس، داده‌های دارای نویز یا برچسب اشتباه، و داده‌هایی باشند که در فضای ویژگی‌ها در نواحی پرت^۲ قرار دارند.

باشند. وجود داده‌های غیرمفید باعث می‌شود که مدل در طول آموزش زمان و منابع بیشتری صرف کند، بدون آنکه عملکرد نهایی بهبود یابد. افزون‌براین، حضور داده‌های نادرست می‌تواند موجب کاهش دقت و تعمیم‌پذیری مدل شود. پژوهش‌های متعددی نشان داده‌اند که مجموعه داده‌های بزرگ مانند ImageNet نیز حاوی درصد قابل توجهی از نمونه‌های تکراری یا دارای خطا هستند [۱۱]. هدف از هرس داده، شناسایی و حذف چنین نمونه‌هایی است تا آموزش مدل تنها با داده‌های پراطلاع^۳ انجام شود. این ایده با مفهوم کارایی داده ارتباط مستقیم دارد.

۴.۱ تعریف هسته داده

مفهوم هسته داده به یک زیرمجموعه‌ی کوچک‌تر از داده‌ها اطلاق می‌شود که به‌طور مؤثر نمایانگر خصوصیات آماری^۴ یا هندسی^۵ داده‌های اصلی است. هدف از انتخاب هسته داده، فشردگی مؤثر داده‌ها بدون افت محسوس در عملکرد مدل است [۴۵]. این تکنیک به‌طور خاص برای کاهش حجم داده‌ها و کاهش هزینه‌های محاسباتی طراحی شده است، در حالی که اطلاعات و ویژگی‌های حیاتی داده‌ها حفظ می‌شود.

۱. مفهوم کلی هسته داده

هسته داده در حقیقت یک زیرمجموعه انتخابی از مجموعه داده اصلی است که برای حفظ ساختار و توزیع آماری داده‌ها انتخاب می‌شود. این زیرمجموعه، که معمولاً شامل نمونه‌های خاص از داده‌ها است، می‌تواند به عنوان یک نماینده از داده‌های اصلی در فرآیند یادگیری و مدل‌سازی استفاده شود. مزیت اصلی استفاده از هسته داده در این است که به جای استفاده از داده‌های کامل و بزرگ، می‌توان با استفاده از هسته داده، عملکرد مدل را حفظ کرد، اما زمان و منابع محاسباتی به مراتب کمتری مصرف خواهد شد.

۲. دلایل استفاده از هسته داده

در پردازش داده‌های بزرگ، مشکلاتی همچون هزینه‌های محاسباتی بالا و زمان زیاد آموزش مدل‌ها به ویژه در مدل‌های پیچیده مشاهده می‌شود. از این رو، هسته داده به عنوان ابزاری برای کاهش حجم داده‌ها، کمینه کردن هزینه‌های محاسباتی و همچنین حفظ دقت مدل معرفی شده است. در حقیقت،

¹Redundancy samples

²Outliers

³Informative data

⁴Statistical features

⁵Geometric features

هدف از هسته‌داده این است که نمونه‌هایی منتخب از داده‌ها به گونه‌ای انتخاب شوند که تقریباً همان عملکرد مدل را نسبت به داده‌های اصلی فراهم کنند.

۳. ویژگی‌های آماری و هندسی هسته‌داده

هسته‌داده می‌تواند با توجه به ویژگی‌های آماری یا هندسی داده‌ها انتخاب شود: - ویژگی‌های آماری: مانند میانگین‌ها، واریانس‌ها یا دیگر پارامترهای توزیع داده‌ها. - ویژگی‌های هندسی: که می‌تواند شامل فاصله‌ها^۱ یا موقعیت‌های داده‌ها در فضای ویژگی‌ها باشد.

این ویژگی‌ها به انتخاب نمونه‌هایی کمک می‌کنند که نمایانگر الگوها و توزیع کلی داده‌ها هستند. به عنوان مثال، در یک مسئله کلاس‌بندی^۲، هسته‌داده ممکن است شامل نمونه‌هایی باشد که مرکز داده‌ها یا حاشیه‌های تصمیم‌گیری را نمایانگر باشند.

۴. فرمول‌بندی ریاضی هسته‌داده

انتخاب یک هسته‌داده خوب به‌طور معمول به‌صورت یک مسئله بهینه‌سازی مدل‌سازی می‌شود. یکی از مثال‌ها در مسائل کلاس‌بندی به صورت زیر است:

$$\min_{S \subset T} \sum_{i \in S} \|x_i - c_S\|^2 \quad (1.1)$$

که در (۱.۱)، S نمایانگر هسته‌داده، T مجموعه‌ی داده‌های اصلی، x_i نمونه‌های داده و c_S مرکز هسته‌داده است. این فرمول به این معناست که هسته‌داده باید شامل نمونه‌هایی باشد که کمترین فاصله را با مرکز c_S دارند. اده‌ها دارند، به‌طوری که نمایندگی مناسبی از داده‌های اصلی ایجاد کند.

۵. کاربرد هسته‌داده در یادگیری ماشین

هرس داده به‌عنوان یکی از رویکردهای کلیدی در یادگیری ماشین^۳ و یادگیری عمیق^۴ با هدف کاهش حجم داده‌های آموزشی، حذف نمونه‌های زائد یا کم‌اطلاع، و بهبود کارایی محاسباتی مدل‌ها به کار می‌رود. این روش با حفظ نمونه‌های نماینده و مؤثر، ضمن کاهش پیچیدگی مدل، می‌تواند منجر به بهبود یا حفظ عملکرد پیش‌بینی شود. از مهم‌ترین کاربردهای دیتا پرونینگ می‌توان به یادگیری فعال^۵، که در آن نمونه‌های پراطلاع نگه‌داشته شده و نمونه‌های کم‌اثر حذف می‌شوند تا سهم مؤثری در یادگیری مدل داشته باشند، یادگیری نیمه‌نظارتی^۶، که پالایش داده‌های بدون برچسب و انتخاب نمونه‌های مناسب برای ترکیب با داده‌های برچسب‌دار به منظور افزایش کیفیت آموزش انجام می‌شود، و کاهش ابعاد و فشردگی داده‌ها^۷، که با حذف ویژگی‌ها یا نمونه‌های غیرضروری فضای داده و هزینه‌های محاسباتی کاهش یافته و اطلاعات اساسی حفظ می‌شود، اشاره کرد.

¹Distances

²Classification problem

³Machine Learning

⁴Deep Learning

⁵Active Learning

⁶Semi-supervised Learning

⁷Dimensionality Reduction

۶. انتخاب هسته داده

برای انتخاب هسته داده، دو ویژگی کلیدی باید در نظر گرفته شوند: ۱. نمایندگی: هسته داده باید توانایی نمایندگی داده‌های اصلی را داشته باشد. ۲. کاهش حجم: انتخاب هسته داده باید به گونه‌ای باشد که حجم داده‌ها به طور قابل توجهی کاهش یابد، ولی همچنان دقت مدل حفظ شود.

۵.۱ تعریف هرس داده

هرس داده فرآیندی است که طی آن از یک مجموعه داده‌ی بزرگ، زیرمجموعه‌ای کوچک‌تر اما حاوی بیشترین اطلاعات آماری انتخاب می‌شود، به گونه‌ای که مدل آموزش داده شده بر آن، عملکردی نزدیک یا معادل با آموزش بر کل مجموعه داده داشته باشد [۵۲]. به عبارت دیگر، هدف از هرس داده، حذف داده‌های غیرضروری با کمترین افت ممکن در دقت مدل است. فرمول‌بندی کلی مسئله به صورت زیر است:

$$S^* = \arg \max_{S \subseteq T, |S| < |T|} \text{Perf}(f_S) \quad (2.1)$$

در (۲.۱)، T کل مجموعه داده، S زیرمجموعه‌ی منتخب (هسته داده) و $\text{Perf}(f_S)$ عملکرد مدل آموزش داده شده بر روی S است. فرآیند هرس داده معمولاً شامل محاسبه‌ی یک معیار هرس^۱ برای هر نمونه، مرتب‌سازی نمونه‌ها بر اساس این معیار، و انتخاب یا حذف درصدی از داده‌ها بر اساس امتیاز^۲ می‌باشد.

روش‌های مختلفی برای محاسبه‌ی معیار اهمیت داده ارائه شده‌اند که شامل روش‌های هندسی^۳ مانند K-Center و Herding، روش‌های عدم قطعیت^۴، مانند Entropy یا EL2N، روش‌های گرادینانی یا خطا محور^۵، مانند GraNd و Forgetting، و روش‌های مبتنی بر پویایی آموزش^۶، مانند Dyn-Unc [۳۲] و TDDS [۷۲]، می‌شوند.

در فصل بعد، به تفصیل به توضیح هر کدام از این روش‌ها خواهیم پرداخت.

مزیت اصلی هرس داده نسبت به سایر روش‌های بهینه‌سازی، کاهش هزینه‌ی آموزش بدون نیاز به تغییر در ساختار مدل است. در حالی که هرس مدل^۷ پارامترهای غیرضروری شبکه را حذف می‌کند، هرس داده تمرکز خود را بر کاهش داده‌های ورودی قرار می‌دهد.

¹Metric Pruning

²Score

³Geometry-based

⁴Uncertainty-based

⁵Error-based

⁶Dynamic-based

⁷Pruning Model

۶.۱ مقیاس پذیری قانون توانی و نمایی

در دهه‌های اخیر، مشاهده شده که عملکرد مدل‌های یادگیری عمیق معمولاً با افزایش اندازه داده یا پارامترها به صورت توانی^۱ تغییر می‌کند. این موضوع نشان می‌دهد که برای کاهش خطا، به حجم زیادی از داده‌ها یا پارامترها نیاز است. به عبارت دیگر، در مدل‌های یادگیری عمیق، خطا با افزایش اندازه داده‌ها یا تعداد پارامترهای مدل به صورت نمایی کاهش نمی‌یابد، بلکه به شکل توانی کاهش می‌یابد [۳۳، ۳۴].

مقیاس‌پذیری قانون توانی^۲ به این معناست که افزایش خطای مدل‌ها با افزایش داده‌ها یا پارامترها، در ابتدا سریع است و به مرور زمان کاهش می‌یابد، اما این کاهش به طور نمایی رخ نمی‌دهد. به عبارت دیگر، خطای مدل در ابتدا با اضافه شدن داده‌های بیشتر کاهش می‌یابد، ولی سرعت این کاهش با افزایش داده‌ها یا پارامترها کاهش پیدا می‌کند. مقیاس‌پذیری قانون توانی را می‌توان به صورت ریاضی به شکل زیر نوشت:

$$E \propto \left(\frac{N}{D}\right)^{\alpha} \quad (۳.۱)$$

در رابطه‌ی (۳.۱)، E نمایانگر خطای مدل، N تعداد داده‌ها یا پارامترهای مدل، D به عنوان یک مقدار ثابت در نظر گرفته می‌شود و α ضریب قدرتی است که میزان کاهش خطا با افزایش داده‌ها یا پارامترها را نشان می‌دهد. این رابطه نشان‌دهنده کاهش خطا به صورت غیرخطی است که به تدریج با افزایش داده‌ها یا پارامترها بهبود می‌یابد.

این موضوع به ویژه در مدل‌های یادگیری عمیق که با داده‌های بزرگ و پارامترهای پیچیده آموزش می‌بینند، اهمیت پیدا می‌کند. در این مدل‌ها، برای دستیابی به بهبود چشمگیر در عملکرد، نیاز به داده‌های زیاد و یا مدل‌هایی با پارامترهای متعدد است. در مقایسه با مقیاس‌پذیری نمایی^۳ که در آن کاهش خطا با افزایش داده‌ها به صورت بسیار سریع و نمایی است، مقیاس‌پذیری قانون توانی نشان می‌دهد که خطا به صورت غیرخطی و به‌طور کندتر کاهش می‌یابد. در این مدل، با اضافه کردن داده‌های بیشتر، بهبودهایی در عملکرد مدل به دست می‌آید، اما این بهبود به اندازه مقیاس‌پذیری نمایی چشمگیر و سریع نیست. فرمول مقیاس‌پذیری نمایی به صورت زیر است:

$$E \propto e^{-\beta N} \quad (۴.۱)$$

در رابطه‌ی (۴.۱)، E نمایانگر خطای مدل، N تعداد داده‌ها یا پارامترها و β ضریب نمایی است

^۱Power Law

^۲Power Law Scaling

^۳Scaling Exponential

که میزان کاهش خطا با افزایش داده‌ها یا پارامترها را نشان می‌دهد. در مقیاس‌پذیری نمایی، با افزایش داده‌ها، عملکرد مدل به طور نمایی بهبود می‌یابد. این روند به‌ویژه در مقیاس‌های بزرگ و برای داده‌های حجیم مشاهده می‌شود. از طرفی، در مقیاس‌پذیری قانون توانی، بهبود عملکرد مدل به صورت غیرخطی و با شیب کمتری انجام می‌شود و پیشرفت بهینه در افزایش داده‌ها یا پارامترها به سرعت نمایی حاصل نمی‌شود. به عبارت دیگر، با افزایش داده‌ها یا پارامترها، خطای مدل به طور نمایی کاهش نمی‌یابد، بلکه این کاهش به شکل توانی است و روند آن با افزایش اندازه داده‌ها یا مدل‌های پیچیده‌تر کاهش می‌یابد.

این تفاوت‌ها به‌ویژه در مدل‌های یادگیری عمیق که نیاز به داده‌های بزرگ دارند، مطرح می‌شود و باعث می‌شود تا هزینه‌های محاسباتی و مصرف انرژی برای مدل‌های پیچیده‌تر و بزرگ‌تر به طور چشمگیری افزایش یابد [۳۳، ۳۴]. در مقایسه با مقیاس‌پذیری نمایی که در آن کاهش خطا با افزایش داده‌ها به صورت بسیار سریع و نمایی است، مقیاس‌پذیری قانون توانی نشان می‌دهد که خطا به صورت غیرخطی و به‌طور کندتر کاهش می‌یابد. در این مدل، با اضافه کردن داده‌های بیشتر، بهبودهایی در عملکرد مدل به دست می‌آید، اما این بهبود به اندازه مقیاس‌پذیری نمایی چشمگیر و سریع نیست.

۱.۶.۱ مشکلات مقیاس‌پذیری قانون توانی

چالش‌های اساسی در مقیاس‌پذیری قانون توانی شامل هزینه محاسباتی بالا است؛ زیرا برای کاهش خطا تنها با اضافه کردن داده‌های بیشتر، هزینه‌های محاسباتی افزایش می‌یابد [۳۴]. همچنین، مصرف انرژی مسئله‌ای مهم است، زیرا مدل‌هایی که برای عملکرد بهتر نیاز به داده‌های بیشتری دارند، مصرف انرژی بسیار بالایی دارند [۳۳، ۳۴]. علاوه بر این، عدم کارایی نیز مشاهده می‌شود؛ اگرچه با افزایش داده‌ها خطا کاهش می‌یابد، اما میزان کاهش آن به‌طور معمول بسیار کند است و نتایج بهینه به‌دست نمی‌آید [۳۳].

۲.۶.۱ راه‌حل‌های پیشنهادی برای حل مشکلات مقیاس‌پذیری قانون توانی

یکی از رویکردهای نوین، که در این تحقیق نیز بررسی می‌شود، استفاده از هرس داده به‌عنوان ابزاری برای بهبود مقیاس‌پذیری است. با استفاده از پیش‌بینی دقیق از اهمیت داده‌ها و انتخاب هوشمندانه‌تر داده‌ها، می‌توان به مقیاس‌پذیری نمایی دست یافت. به‌طور مثال، در برخی از روش‌ها با استفاده از متریک‌هایی مانند Uncertainty Dynamic یا TDDS می‌توان داده‌هایی را که کمترین اثر را در یادگیری دارند حذف کرد و از داده‌های مهم‌تر استفاده کرد که عملکرد مدل را بهبود می‌دهند.

این رویکرد موجب کاهش هزینه‌های محاسباتی و انرژی می‌شود و از سوی دیگر، می‌تواند منجر به بهبود قابل توجه در سرعت یادگیری و کاهش زمان آموزش شود.

۷.۱ جمع‌بندی

در این فصل مفاهیم کلیدی مرتبط با هرس داده و عملکرد آن بررسی شد. داده‌ها زیربنای اصلی یادگیری ماشین محسوب می‌شوند و کیفیت، تنوع و ساختار آن‌ها تأثیر مستقیم بر عملکرد مدل دارد. با رشد تصاعدی حجم داده‌ها، شناسایی و حذف داده‌های غیرضروری به ضرورتی اجتناب‌ناپذیر بدل شده است. هرس داده و انتخاب هسته داده ابزارهایی کارآمد برای بهبود کارایی داده، کاهش هزینه‌های محاسباتی و حفظ دقت مدل هستند. در فصل‌های بعد، روش‌های پیشرفته‌ی هرس داده به تفصیل بررسی و تحلیل خواهند شد تا راهکاری عملی برای افزایش کارایی داده در یادگیری عمیق ارائه شود.

فصل ۲

پژوهش‌های مرتبط

در این فصل، به بررسی و تحلیل پژوهش‌های مرتبط در زمینه‌ی هرس داده‌ها^۲ و تقطیر دادگان^۳ در حوزه‌ی یادگیری ماشین^۴ پرداخته می‌شود. هدف اصلی این فصل، ارائه‌ی تصویری جامع از رویکردها و روش‌هایی است که به‌منظور کاهش حجم داده‌های آموزشی، بهبود کارایی مدل‌ها، و افزایش بهره‌وری محاسباتی مورد استفاده قرار گرفته‌اند. این دو حوزه‌ی پژوهشی، اگرچه اهداف مشترکی در جهت بهینه‌سازی فرایند یادگیری دارند، اما از نظر رویکرد و پیاده‌سازی با یکدیگر تفاوت‌های اساسی دارند. هرس داده‌ها به‌عنوان یکی از راهکارهای کلیدی در کاهش پیچیدگی مدل‌های یادگیری، بر انتخاب زیرمجموعه‌ای از داده‌های آموزشی متمرکز است که بیشترین تأثیر را بر عملکرد مدل دارند. در این روش، داده‌های کم‌اطلاعات، نویزی یا غیرضروری شناسایی و از مجموعه‌ی آموزشی حذف می‌شوند تا ضمن حفظ دقت مدل، هزینه‌ی محاسباتی و زمان آموزش کاهش یابد. این فرایند می‌تواند بر اساس معیارهای مختلفی مانند اهمیت نمونه‌ها، ویژگی‌های داده‌ها، معیارهای آماری یا ساختار مدل انجام شود.

در مقابل، تقطیر دادگان^۵ (یا فشرده‌سازی داده‌ها^۶) به‌دنبال ایجاد مجموعه‌داده‌ای جدید و کوچک‌تر است که بتواند رفتار آماری و اطلاعاتی مجموعه‌داده‌ی اصلی را بازنمایی کند. در این رویکرد، به‌جای حذف داده‌های موجود، داده‌های نماینده‌ای تولید یا انتخاب می‌شوند که مدل بتواند با استفاده از آن‌ها عملکردی مشابه یا حتی بهتر نسبت به داده‌های کامل داشته باشد. روش‌های تقطیر داده‌ها معمولاً بر مبنای یادگیری فشرده^۷، کدگذاری و رمزگشایی^۸، فاکتوریزه‌سازی داده‌ها^۹ و بهینه‌سازی مبتنی بر گرادیان^{۱۰} طراحی می‌شوند.

^۲Data pruning

^۳Dataset Distillation

^۴Machine learning

^۵Dataset Distillation

^۶Data Compression

^۷Compact Learning

^۸Encoding and Decoding

^۹Data Factorization

^{۱۰}Gradient-based Optimization

در ادامه‌ی این فصل، ابتدا رویکردهای مختلف هرس داده‌ها بر اساس معیارهای مدل، داده، الگوریتم، هندسه، و تحلیل‌های ریاضی معرفی و بررسی می‌شوند. سپس، به روش‌های نوین تقطیر دادگان پرداخته خواهد شد تا مروری یکپارچه بر جدیدترین دستاوردها در زمینه‌ی کاهش حجم داده‌ها و افزایش کارایی مدل‌های یادگیری ماشین ارائه گردد.

۱.۲ هرس داده‌ها بر اساس معیارهای مدل^۱

در این رویکرد تصمیم‌گیری درباره‌ی حذف داده‌ها بر مبنای شاخص‌های داخلی مدل و نحوه‌ی عملکرد آن انجام می‌شود. ایده‌ی اصلی این است که داده‌هایی که تأثیر کمی بر پارامترهای مدل یا خروجی نهایی آن دارند، می‌توانند حذف شوند بدون آنکه دقت مدل به‌طور معناداری کاهش یابد [۲۲، ۳۵، ۶۶].

به‌صورت ریاضی، اگر مجموعه داده‌ی آموزش $D = \{(x_i, y_i)\}_{i=1}^n$ و مدل پارامتری $f(x; \theta)$ باشد، هدف یافتن زیرمجموعه‌ای $D' \subset D$ است به‌طوری‌که:

$$\min_{D' \subset D} |D'| \quad \text{s.t.} \quad \mathcal{L}_{val}(\theta(D')) - \mathcal{L}_{val}(\theta(D)) \leq \varepsilon, \quad (1.2)$$

که در آن $\mathcal{L}_{val}$ تابع خطای مدل روی داده‌های اعتبارسنجی است [۶۱].

۱.۱.۲ هرس مبتنی بر عملکرد مدل^۲

در این رویکرد، هدف حذف داده‌هایی است که تأثیر ناچیزی بر عملکرد نهایی مدل دارند. عملکرد مدل و معیار تصمیم‌گیری بر مبنای شاخص‌های عملکرد مدل مانند خطای پیش‌بینی^۳، اطمینان^۴، پایداری^۵ یا حساسیت^۶ است. روش‌های مختلفی در این حوزه معرفی شده‌اند که در ادامه به مهم‌ترین آن‌ها پرداخته می‌شود.

۱.۱.۱.۲ هرس مبتنی بر خطای پیش‌بینی^۷

در این رویکرد، میزان خطای پیش‌بینی مدل بر روی هر نمونه‌ی آموزشی به‌عنوان شاخصی از اهمیت آن داده در فرآیند یادگیری در نظر گرفته می‌شود. منطق اصلی این روش آن است که داده‌هایی که مدل به‌راحتی آن‌ها را به‌درستی پیش‌بینی می‌کند (دارای خطای پایین هستند) اطلاعات جدید و مفیدی برای

¹Model-based Pruning

²Performance-based Pruning

³Prediction Error

⁴Confidence

⁵Robustness

⁶Sensitivity

⁷Error-based Pruning

بهبود پارامترهای مدل فراهم نمی‌کنند، زیرا مدل از پیش توانایی بازسازی آن‌ها را به‌خوبی دارد. در مقابل، داده‌هایی که مدل در پیش‌بینی آن‌ها دچار خطای زیاد می‌شود، ممکن است حاوی اطلاعات غنی‌تر درباره مرزهای تصمیم یا مناطق دشوار فضای ویژگی باشند؛ هرچند در مواردی، این نمونه‌ها می‌توانند نویزی یا دارای برچسب اشتباه نیز باشند [۶۶، ۲۲].

برای هر نمونه i از داده‌های آموزشی، مقدار خطای پیش‌بینی مدل تعریف می‌شود:

$$e_i = \ell(y_i, f(x_i; \theta)), \quad (2.2)$$

که در آن $f(x_i; \theta)$ خروجی مدل و $\ell(\cdot)$ تابع زیان^۱ است. به عنوان مثال در مسائل طبقه‌بندی، معمولاً از زیان Cross-Entropy استفاده می‌شود:

$$\ell(y_i, f(x_i; \theta)) = - \sum_{c=1}^C y_{i,c} \log f_c(x_i; \theta), \quad (3.2)$$

و در مسائل رگرسیون از میانگین مربعات خطا^۲ بهره گرفته می‌شود:

$$\ell(y_i, f(x_i; \theta)) = \|y_i - f(x_i; \theta)\|^2. \quad (4.2)$$

پس از محاسبه‌ی خطا برای تمام نمونه‌ها، می‌توان آستانه‌ای τ تعریف نمود و داده‌هایی را که دارای خطای کمتر از این آستانه هستند، حذف کرد:

$$\mathcal{D}' = \{(x_i, y_i) \mid e_i \geq \tau\}. \quad (5.2)$$

انتخاب مقدار بهینه‌ی τ معمولاً بر اساس تحلیل توزیع خطاها یا از طریق اعتبارسنجی متقابل^۳ انجام می‌شود [۶۱]. در عمل، داده‌ها را می‌توان بر اساس مقدار e_i مرتب کرده و درصد مشخصی از نمونه‌های دارای کمترین خطا را حذف نمود (مثلاً ۱۰٪ تا ۲۰٪ از داده‌های بسیار «آسان»). برای درک بهتر نقش این داده‌ها، مفهوم Example Forgetting Events را معرفی کردند [۶۶]. بر اساس آن، در طول آموزش مدل، نمونه‌هایی که چندین بار از «درست طبقه‌بندی شدن» به «اشتباه طبقه‌بندی شدن» تغییر وضعیت می‌دهند، نمونه‌های «دشوار و مهم» هستند. در مقابل، داده‌هایی که هرگز اشتباه پیش‌بینی نمی‌شوند، نمونه‌های «آسان» محسوب شده و می‌توان آن‌ها را از فرآیند آموزش حذف کرد بدون آنکه عملکرد مدل کاهش یابد.

به‌طور خلاصه، معیار اصلی این روش را می‌توان به‌صورت زیر بیان کرد:

$$i \propto e_i, \text{ اهمیت داده} \quad (6.2)$$

¹Loss Function

²Mean Squared Error

³Cross-Validation

که بر اساس آن داده‌های با e_i کوچک‌تر اهمیت آموزشی کمتری دارند.
مزایا:

این روش ساده و قابل تفسیر است و برای به‌کارگیری آن نیازی به محاسبه‌ی ماتریس هسین^۱ یا گرادیان‌های مرتبه‌ی دوم^۲ وجود ندارد. علاوه بر این، قابلیت استفاده برای تمامی انواع مدل‌ها از جمله درخت‌های تصمیم^۳، شبکه‌های عصبی^۴ و مدل‌های رگرسیونی^۵ را داراست و از این نظر روشی عمومی و انعطاف‌پذیر محسوب می‌شود.
محدودیت‌ها:

حذف بیش از حد داده‌هایی که دارای خطای پایین هستند می‌تواند منجر به از دست رفتن تنوع آماری داده‌ها شود و در نتیجه بر توان تعمیم‌پذیری مدل اثر منفی بگذارد. از سوی دیگر، داده‌هایی با خطای بالا ممکن است ماهیتی نویزی داشته باشند و نگهداری آن‌ها می‌تواند موجب کاهش پایداری مدل گردد [۵۴، ۲۲].

در نهایت، انتخاب بهینه‌ی سطح آستانه و ترکیب این روش با سایر معیارها (مانند اطمینان یا حساسیت مدل) می‌تواند کارایی فرایند هرس داده را به شکل چشمگیری بهبود دهد.

۲.۱.۱.۲ هرس مبتنی بر معیار اطمینان مدل^۶

در این روش، از میزان اطمینان مدل در پیش‌بینی نمونه‌ها به‌عنوان شاخصی برای سنجش اهمیت آموزشی داده‌ها استفاده می‌شود. فرض بر این است که مدل در مراحل میانی یا پایانی آموزش، برای برخی نمونه‌ها پیش‌بینی‌هایی با احتمال بسیار بالا (اطمینان زیاد) تولید می‌کند. چنین نمونه‌هایی معمولاً از نظر مدل «ساده» تلقی شده و سهم اندکی در بهبود گرادیان‌های یادگیری دارند [۶۶، ۲۹]. اگر خروجی مدل به‌صورت یک توزیع احتمالاتی بر روی کلاس‌ها تعریف شود:

$$p(y|x_i; \theta) = [p(y = 1|x_i; \theta), p(y = 2|x_i; \theta), \dots, p(y = C|x_i; \theta)], \quad (7.2)$$

در این صورت، شاخص اطمینان مدل برای نمونه‌ی i به‌صورت بیشینه‌ی این توزیع تعریف می‌شود:

$$p_{\max,i} = \max_c p(y = c|x_i; \theta). \quad (8.2)$$

نمونه‌هایی که مدل در مورد آن‌ها اطمینان بسیار بالایی دارد (برای مثال $p_{\max,i} > 0.99$)، غالباً در فضای ویژگی‌ها نزدیک به مرکز خوشه‌های مربوط به کلاس خود قرار دارند و اطلاعات چندانی برای

¹Hessian Matrix

²Second-order Derivatives

³Decision tree

⁴Neural network

⁵Regression model

⁶Confidence-based Pruning

بهبود مرزهای تصمیم ارائه نمی‌کنند. از این رو می‌توان آن‌ها را از داده‌های آموزشی حذف کرد:

$$\mathcal{D}' = \{(x_i, y_i) \mid p_{\max, i} \leq \tau_c\}, \quad (9.2)$$

که τ_c آستانه‌ی اطمینان است. انتخاب مقدار مناسب τ_c اهمیت زیادی دارد و معمولاً با استفاده از داده‌های اعتبارسنجی یا با تحلیل توزیع اطمینان نمونه‌ها انجام می‌شود. به‌طور تجربی، [۲۹] نشان داده‌اند که آموزش مدل با حذف نمونه‌های دارای اطمینان بسیار بالا می‌تواند موجب تسریع همگرایی و گاهی بهبود دقت نهایی شود، زیرا تمرکز آموزش به سمت داده‌های دشوارتر سوق می‌یابد (رویکردی مشابه Curriculum Learning معکوس).

از آنجا که احتمال $p_{\max, i}$ به‌تنهایی همیشه قابل اعتماد نیست به‌ویژه در مدل‌هایی که دچار بیش‌اعتمادی^۱ هستند، ترکیب این معیار با شاخص‌های دیگری مانند عدم قطعیت آنتروپیک^۲، حاشیه پیش‌بینی^۳ یا خطای پیش‌بینی توصیه می‌شود:

$$H_i = - \sum_{c=1}^C p(y = c | x_i; \theta) \log p(y = c | x_i; \theta), \quad (10.2)$$

که در آن H_i آنتروپي پیش‌بینی برای نمونه i است. داده‌هایی با آنتروپي پایین (اطمینان بالا) می‌توانند کاندیدای مناسبی برای حذف باشند. مزایا:

این روش از نظر محاسباتی بسیار ساده است، زیرا تنها به خروجی احتمالاتی مدل متکی بوده و نیازی به محاسبه‌ی گرادیان یا ماتریس هسین ندارد. همچنین می‌توان آن را به راحتی با سایر روش‌های هرس داده، از جمله هرس مبتنی بر خطا یا حساسیت مدل، ترکیب کرد. از منظر یادگیری، این معیار به مدل کمک می‌کند تا تمرکز بیشتری بر داده‌های دشوار و نواحی دارای مرزهای تصمیم پیچیده‌تر داشته باشد.

محدودیت‌ها:

در مدل‌هایی که دچار بیش‌اعتمادی هستند، احتمال دارد مقادیر احتمالی غیرواقعی و اغراق‌آمیز تولید شود؛ در چنین شرایطی، شاخص $p_{\max, i}$ می‌تواند گمراه‌کننده باشد [۲۶]. افزون بر این، در مجموعه داده‌های نامتوازن، نمونه‌های متعلق به کلاس‌های پرشمار ممکن است به‌طور مصنوعی دارای سطح اطمینان بالایی باشند و حذف آن‌ها منجر به کاهش تعادل آماری داده‌ها شود. همچنین در مراحل اولیه‌ی آموزش، که مدل هنوز به درستی کالیبره نشده است، استفاده از این معیار ممکن است به حذف نادرست داده‌های مهم و اثرگذار منجر گردد.

به‌طور کلی، هرس مبتنی بر اطمینان مدل یکی از روش‌های مؤثر برای کاهش حجم داده‌های آموزشی در مدل‌های بزرگ است؛ به‌ویژه زمانی که همراه با معیارهای عدم قطعیت و تحلیل حساسیت

¹Overconfidence

²Entropic Uncertainty

³Prediction Margin

ترکیب شود. در چنین حالتی، می‌توان تعادلی میان کارایی محاسباتی و حفظ کیفیت یادگیری برقرار کرد [۲۲، ۱].

۳.۱.۱.۲ هرس مبتنی بر اثر داده بر عملکرد مدل^۱

در این رویکرد، اهمیت هر داده بر اساس میزان تأثیر آن بر عملکرد مدل سنجیده می‌شود. ایده‌ی اصلی از نظریه‌ی Influence Functions در آمار کلاسیک گرفته شده است که در یادگیری ماشین برای تحلیل حساسیت پارامترهای مدل نسبت به داده‌های آموزشی به کار می‌رود [۳۵]. فرض کنید مدل با حل مسئله‌ی بهینه‌سازی زیر آموزش داده شود:

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n L(z_i, \theta), \quad z_i = (x_i, y_i), \quad (11.2)$$

که در آن $L(z_i, \theta)$ تابع زیان و $\hat{\theta}$ پارامتر بهینه‌ی مدل است. اکنون فرض کنید وزن یک داده‌ی خاص z_j اندکی تغییر کند؛ یعنی داده‌ی z_j به اندازه‌ی ϵ بیشتر یا کمتر در فرایند آموزش لحاظ شود. با استفاده از بسط تیلور و تقریب مرتبه‌ی اول، تغییر متناظر در پارامترهای بهینه‌ی مدل را می‌توان به صورت زیر تخمین زد:

$$\left. \frac{d\hat{\theta}_{\epsilon, z_j}}{d\epsilon} \right|_{\epsilon=0} = -H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z_j, \hat{\theta}), \quad (12.2)$$

که در آن $H_{\hat{\theta}}$ ماتریس هسین تابع زیان میانگین است:

$$H_{\hat{\theta}} = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta}^2 L(z_i, \hat{\theta}). \quad (13.2)$$

این رابطه بیان می‌کند که تغییر کوچک در وزن نمونه‌ی z_j ، تغییری متناسب با جهت $-H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z_j, \hat{\theta})$ در پارامترهای مدل ایجاد می‌کند. در نتیجه، میزان تأثیر داده‌ی z_j بر روی زیان حاصل از یک نمونه‌ی آزمون z_{test} به صورت زیر محاسبه می‌شود:

$$\mathcal{I}_{up, loss}(z_j, z_{test}) = -\nabla_{\theta} L(z_{test}, \hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z_j, \hat{\theta}). \quad (14.2)$$

علامت این مقدار نشان می‌دهد که حذف یا تقویت داده‌ی z_j چه اثری بر عملکرد مدل بر روی داده‌ی آزمون دارد:

- اگر $\mathcal{I}_{up, loss}(z_j, z_{test}) > 0$: حذف داده‌ی z_j موجب کاهش خطای آزمون می‌شود (نمونه‌ی مضر یا نویزی).

¹Confidence-based Pruning Influence on Model Performance

• اگر $\mathcal{I}_{up,loss}(z_j, z_{test}) < 0$: حذف داده‌ی z_j موجب افزایش خطای آزمون می‌شود (نمونه‌ی مفید).

بنابراین، نمونه‌هایی با مقدار مطلق تأثیر پایین ($|\mathcal{I}_{up,loss}|$ کوچک) کمترین نقش را در تعیین مرزهای تصمیم مدل دارند و می‌توانند بدون افت محسوس عملکرد حذف شوند [۲۲، ۵۴]:

$$\mathcal{D}' = \{z_i \in \mathcal{D} \mid |\mathcal{I}_{up,loss}(z_i, z_{test})| \geq \tau_I\}, \quad (15.2)$$

که τ_I آستانه‌ی حداقل تأثیر است.

تفسیر هندسی:

در فضای پارامترها، گرادیان $\nabla_{\theta} L(z_j, \hat{\theta})$ نشان‌دهنده‌ی جهت تغییر پارامترهایی است که زیان نمونه‌ی z_j را کاهش می‌دهد. ضرب داخلی آن با $\nabla_{\theta} L(z_{test}, \hat{\theta})$ میزان هم‌راستایی میان داده‌ی آموزشی^۱ و آزمون^۲ را بیان می‌کند؛ در نتیجه، داده‌هایی که گرادیان آن‌ها در خلاف جهت داده‌های آزمون است (زاویه‌ی بزرگ‌تر از ۹۰ درجه)، تأثیر منفی بر یادگیری دارند. مزایا:

این رویکرد امکان ارزیابی کمی و نظری اهمیت داده‌ها را بر مبنای یک چارچوب آماری دقیق فراهم می‌کند و از پشتوانه‌ی تئوریک قوی برخوردار است. علاوه بر این، بدون نیاز به دسترسی به داده‌ی مرجع، می‌تواند داده‌های مضر، پرت یا دارای برچسب^۳ نادرست را شناسایی کند. همچنین، این روش قابلیت استفاده در ترکیب با رویکردهای یادگیری فعال^۴ و تحلیل حساسیت را دارد و از این نظر انعطاف‌پذیری بالایی ارائه می‌دهد. محدودیت‌ها:

محاسبه‌ی ماتریس هسین و وارون آن، یعنی $H_{\hat{\theta}}^{-1}$ ، هزینه‌ی محاسباتی بالایی به همراه دارد که بسته به تعداد پارامترها p ، می‌تواند در بازه‌ی $O(p^2)$ تا $O(p^3)$ قرار گیرد. به همین دلیل، در مدل‌های بسیار بزرگ، به‌ویژه شبکه‌های عمیق، استفاده از تقریب‌های کارآمدی مانند LiSSA یا Hutchinson Approximation ضروری است [۳۵، ۵۴]. افزون بر این، فرضیات مبتنی بر خطی‌سازی ممکن است در نواحی با غیرخطی بودن شدید معتبر نباشند و دقت برآورد را کاهش دهند. همچنین در مجموعه داده‌های نامتوازن، نمونه‌های متعلق به کلاس اقلیت ممکن است به دلیل گرادیان‌های کوچک به اشتباه کم‌اهمیت تلقی شوند.

در عمل، روش‌های مدرن مانند TracIn [۵۴] و Representer Point Selection [۷۱]، نسخه‌های کارآمدتر و تقریبی‌تری از این مفهوم را برای شبکه‌های عصبی بزرگ ارائه کرده‌اند. این رویکردها با استفاده از مسیر گرادیان‌ها در طول آموزش یا بردارهای ویژگی لایه‌های میانی، تخمین مؤثرتری از اهمیت داده‌ها فراهم می‌کنند. در نتیجه، هرس مبتنی بر اثر داده بر عملکرد مدل ابزاری قدرتمند برای حذف هدفمند داده‌های بی‌اثر و افزایش کارایی آموزش در مقیاس بزرگ است.

¹Train set

²Test set

³Label

⁴Active Learning

۴.۱.۱.۲ هرس مبتنی بر حساسیت مدل به داده‌ها^۱

در این رویکرد، تصمیم به حذف یا نگه‌داشت داده‌ها بر اساس میزان حساسیت پارامترهای مدل نسبت به تغییر داده‌ها اتخاذ می‌شود. ایده‌ی اصلی آن است که اگر حذف یا تغییر داده‌ی i تأثیر ناچیزی بر پارامترهای بهینه‌ی مدل داشته باشد، داده‌ی مذکور در فرآیند یادگیری نقش اندکی ایفا کرده و می‌تواند بدون افت محسوس در عملکرد حذف شود [۲۲، ۵۴]. فرض کنید مدل با کمینه‌سازی تابع زیان کل آموزش داده شود:

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n L(z_i, \theta), \quad z_i = (x_i, y_i). \quad (۱۶.۲)$$

پس از حذف داده‌ی z_i ، پارامترهای بهینه‌ی جدید مدل برابر خواهند بود با:

$$\hat{\theta}_{-i} = \arg \min_{\theta} \frac{1}{n-1} \sum_{j \neq i} L(z_j, \theta). \quad (۱۷.۲)$$

حساسیت داده‌ی i نسبت به مجموعه داده‌ی کامل به صورت زیر تعریف می‌شود:

$$S_i = \left\| \hat{\theta} - \hat{\theta}_{-i} \right\|_2, \quad (۱۸.۲)$$

که در آن S_i معیاری از میزان تغییر پارامترها پس از حذف نمونه‌ی i است. هرچه S_i کوچک‌تر باشد، داده‌ی i تأثیر کمتری بر ساختار مدل دارد و می‌تواند کاندیدای مناسبی برای هرس باشد. محاسبه‌ی مستقیم $\hat{\theta}_{-i}$ برای همه‌ی داده‌ها از نظر زمانی بسیار پرهزینه است، زیرا نیازمند بازآموزی^۲ کامل مدل برای هر حذف جزئی است. برای رفع این مشکل، از تقریب‌های مرتبه‌ی اول بر مبنای گرادیان استفاده می‌شود:

$$S_i \approx \left\| H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z_i, \hat{\theta}) \right\|_2, \quad (۱۹.۲)$$

که در آن $H_{\hat{\theta}}$ ماتریس هسین تابع زیان کل است. این تقریب نشان می‌دهد که حساسیت داده‌ها مستقیماً با اندازه‌ی گرادیان هر داده و ساختار انحنای فضای پارامترها^۳ مرتبط است. در عمل، برای مدل‌های بزرگ مانند شبکه‌های عصبی عمیق، از تخمین‌های تقریبی هسین (مانند Diagonal Hessian Approximation یا Fisher Information Matrix) برای محاسبه‌ی سریع‌تر S_i استفاده می‌شود [۷، ۱]. تحلیل مفهومی:

در واقع، حساسیت مدل به داده‌ها بیانگر میزان «وابستگی ساختار پارامترها» به هر داده‌ی خاص

^۱Model Sensitivity-based Pruning

^۲Retrain

^۳Parameter Space Curvature

است. داده‌هایی با حساسیت بالا، در شکل‌گیری مرز تصمیم و به‌ویژه در نمونه‌های نزدیک به نواحی طبقه‌بندی دشوار، تأثیر چشمگیری دارند. در مقابل، داده‌هایی با حساسیت پایین معمولاً تکراری یا ساده‌اند و حذف آن‌ها تغییر قابل توجهی در تابع زیان یا پارامترهای نهایی مدل ایجاد نمی‌کند. مزایا:

این روش معیاری ریاضی و قابل تفسیر برای سنجش اهمیت هر نمونه در فضای پارامترهای مدل ارائه می‌دهد و از این طریق امکان تحلیل ساختار داده‌ها را فراهم می‌سازد. علاوه بر این، بدون اتکا به معیارهای صرفاً تجربی، قادر است داده‌های غیرمؤثر یا تکراری را شناسایی کند. همچنین قابلیت ترکیب با سایر رویکردها، از جمله Influence Function، را دارد که می‌تواند به افزایش دقت و پایداری تحلیل منجر شود. محدودیت‌ها:

به کارگیری این رویکرد مستلزم محاسبه یا تقریب ماتریس هسین است که برای مدل‌های بزرگ هزینه‌ی محاسباتی قابل توجهی به همراه دارد. نتایج حاصل به هموار بودن تابع زیان و پایداری گرادینت‌ها وابسته‌اند و در صورت نقض این فروض، دقت برآورد کاهش می‌یابد. افزون بر این، در مدل‌های غیرمقعر، مانند شبکه‌های عصبی، تخمین $\hat{\theta}_i$ می‌تواند ناپایدار یا حتی چندارزشی باشد. همچنین این روش نسبت به مقیاس‌بندی ویژگی‌ها و انتخاب تابع زیان حساسیت بالایی دارد. به‌طور خلاصه، هرس مبتنی بر حساسیت مدل، ابزاری نظری و قابل تفسیر برای ارزیابی نقش داده‌ها در فرآیند یادگیری است و می‌تواند با روش‌های مبتنی بر اثر داده و اطمینان مدل ترکیب شود تا فرآیند انتخاب داده بهینه گردد [۵۴، ۷، ۱].

۵.۱.۱.۲ هرس مبتنی بر پایداری عملکرد مدل^۱

در این رویکرد، معیار تصمیم‌گیری برای حذف داده‌ها بر اساس پایداری عملکرد مدل در برابر حذف هر نمونه از داده‌ها تعریف می‌شود. ایده‌ی اصلی آن است که داده‌هایی که حذف آن‌ها منجر به تغییر ناچیز در عملکرد کلی مدل می‌شود، از نظر اطلاعاتی اهمیت کمی دارند و می‌توان آن‌ها را حذف کرد [۶۶، ۲۲، ۱].

به‌طور رسمی، پایداری عملکرد مدل نسبت به داده‌ی i از طریق تفاوت در زیان مجموعه‌ی اعتبارسنجی (یا هر معیار عملکردی مانند دقت یا F1) قبل و بعد از حذف داده تعریف می‌شود:

$$\Delta_{\text{perf},i} = |\mathcal{L}_{\text{val}}(\theta(\mathcal{D})) - \mathcal{L}_{\text{val}}(\theta(\mathcal{D} \setminus \{i\}))|, \quad (20.2)$$

در این رابطه، $\mathcal{L}_{\text{val}}$ بیانگر تابع زیان یا معیار ارزیابی مورد استفاده در مجموعه‌ی اعتبارسنجی^۲ است. نماد $\theta(\mathcal{D})$ به پارامترهای مدلی اشاره دارد که بر روی کل مجموعه داده آموزش داده شده است، در حالی که $\theta(\mathcal{D} \setminus \{i\})$ پارامترهای مدل را پس از حذف داده‌ی i نشان می‌دهد.

^۱Performance Stability-based Pruning

^۲Validation set

اگر مقدار $\Delta_{\text{perf},i}$ کوچک باشد، حذف داده‌ی i تغییر قابل توجهی در عملکرد ایجاد نمی‌کند و آن داده را می‌توان کاندیدای حذف دانست. در مقابل، داده‌هایی با مقدار بالای $\Delta_{\text{perf},i}$ نقش کلیدی در حفظ پایداری عملکرد مدل دارند و باید نگه داشته شوند. تقریب محاسباتی:

محاسبه‌ی مستقیم $\Delta_{\text{perf},i}$ برای هر داده، نیازمند بازآموزی کامل مدل n بار است که از نظر محاسباتی بسیار هزینه‌بر است. برای رفع این مشکل، تقریب‌هایی بر اساس گرادیان و تئوری In-fluence Function به کار گرفته می‌شود:

$$\Delta_{\text{perf},i} \approx |\nabla_{\theta} \mathcal{L}_{\text{val}}(\hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z_i, \hat{\theta})|, \quad (21.2)$$

که در آن $H_{\hat{\theta}}$ ماتریس هسین میانگین زیان در داده‌های آموزشی است [۳۵، ۵۴]. این تقریب در واقع نشان می‌دهد که پایداری عملکرد مدل مستقیماً با حساسیت پارامترهای مدل به حذف داده‌ها و همچنین هم‌راستایی گرادیان داده‌ی آموزشی و داده‌های اعتبارسنجی مرتبط است. تفسیر مفهومی:

پایداری عملکرد، معیاری کل‌نگر از نقش هر داده در حفظ رفتار کلی مدل است. داده‌هایی با $\Delta_{\text{perf},i}$ کوچک، معمولاً از نوع داده‌های «آسان» هستند که مدل حتی بدون آن‌ها نیز قادر به تعمیم خوب است. در مقابل، داده‌هایی با $\Delta_{\text{perf},i}$ بالا اغلب شامل نمونه‌های «مرزی» یا «سخت» هستند که برای شکل‌گیری صحیح مرزهای تصمیم حیاتی‌اند. در یادگیری عمیق، مطالعات نشان داده‌اند که حذف سیستماتیک داده‌های با پایداری پایین، می‌تواند سرعت آموزش را تا چندین برابر افزایش دهد بدون کاهش معنی‌دار در دقت نهایی [۱، ۵۱]. مزایا:

این روش تعریفی مستقیم و شهودی از اهمیت داده ارائه می‌دهد که مبتنی بر میزان تغییر عملکرد مدل در اثر حذف هر نمونه است. علاوه بر این، می‌توان آن را با معیارهای دیگر، مانند میزان اطمینان مدل یا تحلیل حساسیت، ترکیب کرد تا دقت فرآیند هرس داده افزایش یابد. از سوی دیگر، این رویکرد برای سنجش پایداری مدل‌های یادگیری عمیق در برابر حذف داده‌ها مناسب است. محدودیت‌ها:

محاسبه‌ی دقیق این معیار مستلزم بازآموزی مدل برای هر حذف جزئی از داده‌ها است که منجر به پیچیدگی محاسباتی $O(n)$ می‌شود. در عمل، استفاده از تقریب‌های مبتنی بر گرادیان در مدل‌های غیرخطی ممکن است با دقت محدودی همراه باشد. افزون بر این، نتایج این روش به انتخاب معیار ارزیابی $\mathcal{L}_{\text{val}}$ و اندازه‌ی مجموعه‌ی اعتبارسنجی حساس است. همچنین در مجموعه‌داده‌های نویزی یا نامتوازن، این احتمال وجود دارد که نمونه‌های پرت به اشتباه به عنوان داده‌های با اهمیت شناسایی شوند.

به‌طور کلی، هرس مبتنی بر پایداری عملکرد، روشی تجربی و مبتنی بر شواهد است که دیدی جامع از اهمیت داده‌ها در حفظ عملکرد مدل ارائه می‌دهد. این رویکرد اغلب به صورت ترکیبی با روش‌های تحلیلی‌تر مانند Influence-based Pruning یا Sensitivity-based Pruning برای دستیابی به تعادلی میان دقت

و کارایی به کار می‌رود.

۶.۱.۱.۲ هرس مبتنی بر معیارهای کلی ارزیابی^۱

در این دسته از روش‌ها، تصمیم‌گیری درباره‌ی حذف یا نگه‌داشت داده‌ها بر مبنای شاخص‌های کلی ارزیابی آماری یا اطلاعاتی انجام می‌شود. هدف اصلی این رویکرد، سنجش میزان اطلاعات مفید یا توان تفکیک‌کنندگی هر داده نسبت به متغیر هدف است. این معیارها عموماً مستقل از ساختار داخلی مدل هستند و به‌عنوان یک دیدگاه^۲ شناخته می‌شوند [۲۲، ۱].

۱. آنتروپی و اطلاعات متقابل:

یکی از متداول‌ترین شاخص‌ها در این گروه، اطلاعات متقابل^۳ بین داده‌ی ورودی x_i و برچسب خروجی Y است:

$$\text{Info}(x_i) = I(x_i; Y) = H(Y) - H(Y|x_i), \quad (22.2)$$

که در آن $H(\cdot)$ آنتروپی شانون^۴ است:

$$H(Y) = - \sum_{y \in \mathcal{Y}} p(y) \log p(y). \quad (23.2)$$

مقدار $I(x_i; Y)$ بیانگر میزان کاهش عدم قطعیت خروجی در صورت دانستن ورودی x_i است. هرچه این مقدار بزرگ‌تر باشد، داده‌ی x_i اطلاعات بیشتری درباره‌ی خروجی فراهم می‌کند. بنابراین، داده‌هایی با اطلاعات متقابل پایین ($I(x_i; Y) \approx 0$) معمولاً تکراری یا غیرمؤثر تلقی می‌شوند و می‌توان آن‌ها را حذف کرد.

در عمل، محاسبه‌ی مستقیم $I(x_i; Y)$ در داده‌های پیوسته یا با ابعاد بالا دشوار است، ازاین‌رو از تقریب‌های کرنلی^۵ یا روش‌های مبتنی بر شبکه‌های عصبی مانند MINE^۶ برای تخمین استفاده می‌شود [۹].

۲. آنتروپی پیش‌بینی مدل:

در مدل‌های احتمالاتی، می‌توان از آنتروپی خروجی مدل برای ارزیابی میزان ابهام در پیش‌بینی استفاده کرد:

$$H_i = - \sum_{c=1}^C p(y = c|x_i; \theta) \log p(y = c|x_i; \theta). \quad (24.2)$$

¹Metric-based Pruning

²Model-agnostic

³Mutual Information

⁴Shannon Entropy

⁵Kernel Density Estimation

⁶Mutual Information Neural Estimator

داده‌هایی با آنتروپی بالا نشان‌دهنده‌ی نمونه‌های دشوار یا نامطمئن هستند که برای آموزش اهمیت بیشتری دارند، درحالی‌که داده‌هایی با آنتروپی پایین معمولاً ساده‌اند و مدل آن‌ها را با اطمینان بالا پیش‌بینی می‌کند. در نتیجه، داده‌هایی با آنتروپی پایین‌تر می‌توانند کاندیدای حذف باشند [۲۹].

۳. وزن اطلاعاتی نمونه‌ها:

در برخی از رویکردها، برای هر داده وزن اطلاعاتی (w_i) تعریف می‌شود که نشان‌دهنده‌ی سهم آن داده در کاهش زیان کلی مدل است:

$$w_i = \frac{\partial \mathcal{L}_{val}}{\partial L(z_i, \hat{\theta})}, \quad (25.2)$$

که در آن $L(z_i, \hat{\theta})$ زیان داده‌ی i و $\mathcal{L}_{val}$ زیان مدل روی داده‌های اعتبارسنجی است. وزن‌های کوچک نشان‌دهنده‌ی داده‌های کم‌اثر هستند و داده‌های متناظر می‌توانند بدون افت عملکرد قابل ملاحظه حذف شوند [۵۱].

۴. معیارهای پیچیدگی و هم‌پوشانی:

معیارهای آماری دیگر شامل چگالی داده‌ها در فضای ویژگی‌ها، شباهت همسایگی^۱ و ضریب هم‌پوشانی^۲ هستند. داده‌هایی که در نواحی پرتراکم یا با نمونه‌های مشابه فراوان قرار دارند، اطلاعات جدیدی برای مدل فراهم نمی‌کنند و حذف آن‌ها می‌تواند منجر به بهبود کارایی بدون آسیب به عملکرد شود [۷].

مزایا:

این روش مستقل از نوع مدل و تابع زیان است و از این جهت به‌طور گسترده قابل استفاده است. همچنین، قابلیت تفسیر از منظر نظریه‌ی اطلاعات و آمار را دارد و برای تحلیل مجموعه‌داده‌های بزرگ یا پرنویز مناسب محسوب می‌شود.

محدودیت‌ها:

اجرای این رویکرد مستلزم تخمین دقیق توزیع‌های احتمالی، یعنی $p(x)$ و $p(y|x)$ ، است که در داده‌های با ابعاد بالا چالش برانگیز می‌باشد. علاوه بر این، معیارهای اطلاعاتی ممکن است همبستگی را با علیت اشتباه بگیرند؛ به این معنا که داده‌ای ممکن است اطلاعات زیادی داشته باشد اما واقعاً برای فرآیند یادگیری مفید نباشد. در مجموعه‌داده‌های نامتوازن، نمونه‌های نادر ممکن است اطلاعات بالایی داشته باشند ولی حذف آن‌ها موجب افت عملکرد مدل گردد.

به‌طور خلاصه، روش‌های مبتنی بر معیارهای کلی ارزیابی با استفاده از شاخص‌های آماری مانند آنتروپی و اطلاعات متقابل، دیدی عمومی از اهمیت داده‌ها ارائه می‌دهند. این رویکرد به‌ویژه زمانی مفید است که ساختار مدل نامشخص یا متغیر باشد، و معمولاً به‌عنوان مرحله‌ی اولیه‌ی هرس داده‌ها یا پیش‌پردازش داده در یادگیری ماشین به کار می‌رود [۱، ۹، ۲۲].

¹Neighborhood Similarity

²Overlap Coefficient

۲.۱.۲ هرس مبتنی بر ویژگی‌های مدل^۱

در این رویکرد، تمرکز بر کاهش ابعاد داده از طریق حذف ویژگی‌های^۲ غیرضروری، کم‌اهمیت یا تکراری است. هدف اصلی این دسته از روش‌ها، بهبود تعمیم‌پذیری مدل، کاهش پیچیدگی محاسباتی، است. هرس ویژگی‌ها معمولاً پیش از آموزش (در مرحله‌ی پیش‌پردازش) یا پس از یادگیری مدل انجام می‌شود و می‌تواند به صورت وابسته به مدل^۳ یا مستقل از مدل^۴ پیاده‌سازی شود [۱۵، ۲۷].

۱.۲.۱.۲ هرس ویژگی‌های کم‌اطلاعات^۵

در مدل‌های پارامتری مانند رگرسیون خطی یا لجستیک، اهمیت هر ویژگی معمولاً با قدر مطلق وزن متناظر آن ($|\theta_j|$) سنجیده می‌شود. اگر مقدار $|\theta_j| < \tau$ (آستانه‌ی ازپیش‌تعیین‌شده) باشد، آن ویژگی تأثیر اندکی بر خروجی مدل دارد و قابل حذف است:

$$\text{Importance: Feature } I_j = |\theta_j|, \quad \text{حذف } I_j < \tau. \quad (۲۶.۲)$$

در مدل‌های غیرخطی مانند شبکه‌های عصبی، روابط پیچیده‌تری میان ورودی‌ها و خروجی وجود دارد. در این حالت، از شاخص‌های مبتنی بر گرادین استفاده می‌شود تا تأثیر هر ویژگی بر پیش‌بینی مدل ارزیابی گردد. دو روش رایج عبارت‌اند از:

Input $\times$ Gradient . ۱

$$I_j = \frac{1}{n} \sum_{i=1}^n \left| \frac{\partial f(x_i)}{\partial x_{ij}} \cdot x_{ij} \right| \quad (۲۷.۲)$$

۲. Integrated Gradients [۶۴]: این روش تأثیر نسبی ویژگی را در طول مسیر بین ورودی پایه (x') و ورودی واقعی (x) اندازه‌گیری می‌کند:

$$IG_j(x) = (x_j - x'_j) \int_{\alpha=0}^1 \frac{\partial f(x' + \alpha(x - x'))}{\partial x_j} d\alpha. \quad (۲۸.۲)$$

ویژگی‌هایی با مقدار اهمیت پایین‌تر از یک آستانه مشخص ($IG_j < \tau$) حذف می‌شوند. این روش‌ها دیدی تفسیرپذیر از سهم هر ویژگی در تصمیم مدل فراهم می‌کنند. مزایا:

این روش به بهبود تفسیرپذیری مدل کمک کرده و امکان کاهش ابعاد ورودی را فراهم می‌کند.

¹Metric-based Pruning

²Feature

³Model-based

⁴Filter-based

⁵Low-informative Feature Pruning

علاوه بر این، برای هر دو نوع مدل‌های پارامتری و شبکه‌های عصبی قابل استفاده است و می‌توان به‌صورت پویا، بر اساس اهمیت محاسبه‌شده، تنظیمات مربوط به هرس داده‌ها را اعمال کرد. محدودیت‌ها:

در شبکه‌های عصبی عمیق، گرادیان‌ها ممکن است نویزی یا ناپایدار باشند و دقت برآورد اهمیت داده‌ها را کاهش دهند. همچنین، انتخاب آستانه‌ی مناسب (τ) حساس است و نیازمند تنظیم دقیق برای دستیابی به عملکرد بهینه می‌باشد.

۲.۲.۱.۲ هرس ویژگی‌های تکراری^۱

در بسیاری از مجموعه‌داده‌ها، ویژگی‌هایی وجود دارند که اطلاعات مشابهی ارائه می‌کنند و عملاً تکراری‌اند. وجود این ویژگی‌ها منجر به هم‌خطی چندگانه^۲ در مدل‌های خطی و کاهش پایداری در یادگیری می‌شود. برای سنجش میزان تکرار، معمولاً از معیار همبستگی پیرسون^۳ ($\rho_{a,b}$) یا اطلاعات متقابل استفاده می‌شود:

$$\rho_{a,b} = \frac{\text{Cov}(X_a, X_b)}{\sigma_a \sigma_b}. \quad (29.2)$$

اگر $|\rho_{a,b}| > 0.95$ ، یکی از ویژگی‌ها می‌تواند بدون افت عملکرد حذف گردد. در داده‌های غیرخطی، همبستگی خطی کافی نیست، بنابراین از فاصله همبستگی^۴ یا معیار استقلال هیلبرت-اشمیت^۵ برای سنجش شباهت بین ویژگی‌ها استفاده می‌شود [۲۵]. مزایا:

این روش موجب کاهش ابعاد مؤثر داده‌ها و حذف هم‌خطی بین ویژگی‌ها می‌شود و در نتیجه پایداری ضرایب مدل‌های خطی افزایش می‌یابد. علاوه بر این، می‌توان با کاهش هزینه‌ی محاسباتی، بدون کاهش دقت مدل، بهره‌وری بالاتری در تحلیل داده‌ها داشت. محدودیت‌ها:

معیارهای مبتنی بر همبستگی تنها روابط خطی بین ویژگی‌ها را اندازه‌گیری می‌کنند و ممکن است الگوهای غیرخطی را نادیده بگیرند. همچنین، حذف نادرست یک ویژگی تکراری ممکن است به از دست رفتن جزئیات مهم و کاهش دقت مدل منجر شود.

¹Redundant Feature Pruning

²Multicollinearity

³Pearson Correlation

⁴Distance Correlation

⁵Hilbert-Schmidt Independence Criterion:HSIC

۳.۲.۱.۲ هرس ویژگی‌های غیرضروری^۱

در این رویکرد، هدف حذف ویژگی‌هایی است که با متغیر هدف^۲ (Y) رابطه‌ی معناداری ندارند. برای ارزیابی این رابطه، از آزمون‌های آماری یا معیارهای اطلاعاتی استفاده می‌شود. رایج‌ترین شاخص، اطلاعات متقابل بین ویژگی و متغیر هدف است:

$$I(X_j; Y) = \sum_{x_j, y} p(x_j, y) \log \frac{p(x_j, y)}{p(x_j)p(y)}. \quad (3.0.2)$$

ویژگی‌هایی که $I(X_j; Y)$ کوچک دارند، تأثیر اندکی بر کاهش عدم قطعیت^۳ خروجی دارند و قابل حذف‌اند. برای داده‌های عددی می‌توان از آزمون‌های همبستگی پیرسون یا اسپیرمن^۴، و برای داده‌های طبقه‌ای از آزمون کای-دو^۵ یا آزمون دقیق فیشر^۶ استفاده کرد. به‌طور پیشرفته‌تر، از روش‌های پوششی^۷ نیز استفاده می‌شود که در آن ویژگی‌ها با توجه به تأثیرشان بر عملکرد نهایی مدل انتخاب یا حذف می‌شوند. در این حالت، مجموعه‌ای از ویژگی‌ها به‌صورت تکراری ارزیابی و ترکیب بهینه از آن‌ها انتخاب می‌شود مانند RFE^۸ [۲۸]. مزایا:

حذف ویژگی‌های نامرتب با باعث افزایش دقت مدل و کاهش نویز می‌شود و این روش برای مجموعه‌داده‌های با ابعاد زیاد و متغیرهای ناهمگن مناسب است. محدودیت‌ها:

روش‌های پوششی، به دلیل این که برای انتخاب ویژگی‌ها، یک زیرمجموعه از ویژگی‌ها را انتخاب می‌کنند و یک مدل یادگیری را روی آن زیرمجموعه آموزش می‌دهند تا عملکرد مدل ارزیابی شود، دارای هزینه محاسباتی بالایی هستند و ممکن است برخی ویژگی‌های غیرمستقیم اما مؤثر به‌اشتباه حذف شوند.

۲.۲ هرس داده‌ها بر اساس معیارهای داده‌ای و آماری^۹

روش‌های هرس داده‌ها بر اساس معیارهای داده‌ای و آماری، بر تحلیل خصوصیات درونی داده‌ها تمرکز دارند، نه بر خروجی یا ساختار مدل‌های یادگیری. در این رویکردها، حذف داده‌ها یا ویژگی‌ها بر پایه‌ی شاخص‌های آماری (مانند میانگین، واریانس، همبستگی) یا ساختار توزیعی آن‌ها (مانند

¹Irrelevant Feature Pruning

²Target Variable

³Uncertainty

⁴Spearman Correlation

⁵Chi-square test

⁶Fisher's Exact Test

⁷Wrapper methods

⁸Recursive Feature Elimination

⁹Data and Statistical-based Pruning

چگالی نقاط، فاصله از مرکز داده و نواحی پرت) انجام می‌شود [۲۵]. به طور کلی، فرض اساسی این است که بخش قابل توجهی از داده‌های واقعی شامل نمونه‌های تکراری، کم‌اطلاعی یا نویزی هستند که حضورشان نه تنها ارزش افزوده‌ای برای مدل ندارد، بلکه موجب افزایش پیچیدگی محاسباتی^۱ و احتمال بیش‌برازش^۲ می‌گردد.

در یک مجموعه داده $D = \{x_i\}_{i=1}^n$ با $x_i \in \mathbb{R}^d$ ، هدف یافتن زیرمجموعه‌ای $D' \subseteq D$ است به گونه‌ای که:

$$D' = \operatorname{argmin}_{S \subseteq D} \|\mathbb{E}_{x \sim D}[f(x)] - \mathbb{E}_{x \sim S}[f(x)]\|, \quad (31.2)$$

که در آن $f(x)$ تابعی از داده‌ها (مثلاً تابع ویژگی یا پیش‌بینی مدل) است. هدف، حفظ توزیع آماری کلی داده‌ها در حالی است که حجم آن کاهش یافته است.

روش‌های آماری مزیت مهمی دارند:

آن‌ها کاملاً از مدل مستقل هستند و در مرحله‌ی پیش‌پردازش^۳ قبل از آموزش هر الگوریتم یادگیری قابل استفاده هستند. با این حال، دقت آن‌ها به کیفیت برآورد توزیع داده‌ها وابسته است و ممکن است در داده‌های غیرایستا یا با ساختارهای غیرخطی دچار افت عملکرد شوند.

۱.۲.۲ هرس مبتنی بر اهمیت نمونه‌ها^۴

در این رویکرد، هدف شناسایی و حذف داده‌هایی است که نقش محدودی در بهبود توزیع آماری یا اطلاعاتی کل مجموعه داده دارند. هر نمونه x_i با یک معیار اهمیت $I(x_i)$ ارزیابی می‌شود که نشان‌دهنده‌ی سهم آن در تنوع یا کیفیت داده‌هاست [۶۶]. به صورت کلی، می‌توان اهمیت نمونه را به شکل زیر تعریف کرد:

$$I(x_i) = \Phi(x_i; D) = \alpha \cdot D(x_i) + (1 - \alpha) \cdot R(x_i), \quad (32.2)$$

که در آن $D(x_i)$ معیاری از «تنوع آماری» نمونه (مثلاً فاصله‌ی آن از میانگین داده‌ها) و $R(x_i)$ معیاری از «نماینده‌ی داده» (مثلاً چگالی محلی یا احتمال حضور در نواحی پراطلاعی) است. ضریب $\alpha \in [0, 1]$ وزن دهی بین این دو جنبه را تنظیم می‌کند.

نمونه‌هایی که مقدار $I(x_i) < \tau_{\text{imp}}$ دارند، به عنوان داده‌های کم‌اهمیت یا تکراری شناسایی و از مجموعه حذف می‌شوند. در عمل، تابع $I(x_i)$ ممکن است با روش‌های آماری، چگالی‌محور یا خوشه‌بندی مانند k -means تخمین زده شود.

¹Computational Complexity

²Overfitting

³Preprocessing

⁴Sample Importance Pruning

۱.۱.۲.۲ هرس بر اساس شاخص‌های آماری^۱

در روش‌های هرس مبتنی بر شاخص‌های آماری، تصمیم حذف ویژگی‌ها یا نمونه‌ها صرفاً بر پایه خواص آماری داده‌ها گرفته می‌شود؛ برای مثال واریانس، میانگین، چولگی^۲، کشیدگی^۳، و ضریب همبستگی. این رویکرد معمولاً به عنوان گام پیش‌پردازش و به صورت مستقل از مدل به کار می‌رود و هدف اصلی آن حذف اطلاعات کم‌اهمیت یا تکراری است تا حجم داده‌ها و هزینه محاسبات کاهش یابد و در عین حال توزیع کلی داده‌ها حفظ شود.

فرض کنید ماتریس داده $X \in \mathbb{R}^{n \times d}$ با n نمونه و d ویژگی داشته باشیم. شاخص‌های آماری پایه برای هر ویژگی j عبارتند از:

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{i,j}, \quad \sigma_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{i,j} - \bar{x}_j)^2,$$

$$\text{skew}_j = \frac{\frac{1}{n} \sum_{i=1}^n (x_{i,j} - \bar{x}_j)^3}{\sigma_j^3}, \quad \text{kurt}_j = \frac{\frac{1}{n} \sum_{i=1}^n (x_{i,j} - \bar{x}_j)^4}{\sigma_j^4}.$$

پایه‌ای‌ترین قاعده هرس این است که ویژگی‌هایی با واریانس بسیار کم (یعنی تقریباً ثابت) حذف شوند:

$$\text{if } \sigma_j^2 < \tau_{\text{var}} \Rightarrow \text{feature drop } j.$$

برای شناسایی ویژگی‌های تکراری یا دارای اطلاعات هم‌مرکز نیز از ضریب همبستگی پیرسون استفاده می‌کنیم:

$$\rho_{j,k} = \frac{\sum_{i=1}^n (x_{i,j} - \bar{x}_j)(x_{i,k} - \bar{x}_k)}{(n-1) \sigma_j \sigma_k}.$$

اگر $|\rho_{j,k}| > \tau_{\text{corr}}$ (مثلاً ۰/۹)، آنگاه یکی از آنها حذف یا ترکیب می‌شود. برای روابط غیرخطی می‌توان از معیارهای وابستگی آماری قوی‌تر مانند معیار استقلال هیلبرت-اشمیت^۴ استفاده کرد که وابستگی‌های غیرخطی بین متغیرها را می‌سنجد. برای دو متغیر X_k و X_j مقدار این معیار را می‌توان بر پایه ماتریس‌های هسته K, L تقریب زد:

$$\text{HSIC}(X_j, X_k) = \frac{1}{(n-1)^2} \text{tr}(KHLH),$$

که $H = I - \frac{1}{n} \mathbf{1}\mathbf{1}^\top$ ماتریس سنترینگ^۵ است. کاربرد این معیار در انتخاب ویژگی و حذف وابستگی‌های غیرخطی مورد مطالعه قرار گرفته است [۲۵].

¹Statistical-based Pruning

²Skewness

³Kurtosis

⁴Hilbert-Schmidt Independence Criterion:HSIC

⁵Centering Matrix

مزایا:

این روش محاسبات ساده و سریعی دارد و برای داده‌های بزرگ در مراحل اولیه بسیار مناسب است. علاوه بر این، از مدل مستقل بوده و می‌توان آن را پیش از آموزش هر مدل اجرا کرد. استفاده از این روش موجب کاهش نویز و حذف ویژگی‌های تقریباً ثابت می‌شود که به ندرت اطلاعات مفید ارائه می‌دهند. در صورت بهره‌گیری از معیارهای پیشرفته مانند معیار استقلال هیلبرت-اشمیت، امکان شناسایی وابستگی‌های غیرخطی نیز فراهم می‌گردد.

محدودیت‌ها:

معیارهای آماری ساده، مانند واریانس، قادر به شناسایی تعاملات پیچیده یا اثرات غیرخطی نیستند و حذف ویژگی‌ها بر پایه واریانس ممکن است باعث از دست رفتن ویژگی‌های کلیدی اما کم‌تغییر شود. انتخاب آستانه‌ها $(\tau_{\text{var}}, \tau_{\text{corr}})$ اغلب مسئله‌محور و تجربی است و نیاز به اعتبارسنجی دارد. علاوه بر این، محاسبه معیارهای پیچیده‌تر مانند معیار استقلال هیلبرت-اشمیت برای داده‌های با ابعاد بسیار بالا هزینه‌بر است. در نهایت، اگر داده‌ها نرمالیزه یا استاندارد نشوند، شاخص‌ها ممکن است همراه‌کننده باشند و پیش‌پردازش مناسب ضروری است.

۲.۱.۲.۲ هرس بر اساس شباهت داده‌ها^۱

در هرس بر اساس شباهت، معیار تصمیم‌گیری بر پایه میزان شباهت (یا اختلاف) بین نمونه‌ها یا بین ویژگی‌ها است. ایده کلیدی این است که نمونه‌های بسیار مشابه اطلاعات تکراری فراهم می‌کنند و حذف برخی از آن‌ها می‌تواند بدون افت قابل توجه در عملکرد، اندازه مجموعه آموزشی را کاهش دهد. این روش‌ها معمولاً در دو سطح کاربرد دارند: (۱) حذف نمونه‌های آموزشی تکراری/مشابه و (۲) حذف ویژگی‌ها/فیلترهایی که خروجی‌شان شباهت زیادی به یکدیگر دارد. برای هر جفت نمونه x_i, x_j می‌توان یک معیار فاصله یا شباهت تعریف کرد، مثلاً فاصله اقلیدسی^۲:

$$\text{dist}(x_i, x_j) = \|x_i - x_j\|_2,$$

یا شباهت کسینوسی^۳:

$$\text{sim}_{\text{cos}}(x_i, x_j) = \frac{x_i^\top x_j}{\|x_i\|_2 \|x_j\|_2},$$

هسته گوسی^۴ یا هسته تابع پایه شعاعی^۵:

$$k(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right).$$

¹Similarity-based Pruning

²Euclidean Distance

³Cosine Similarity

⁴Gaussian Kernel

⁵Radial Basis Function Kernel:RBF Kernel

چند شاخص متداول محاسبه شده برای نمونه i :

$$\bar{d}_i = \frac{1}{n-1} \sum_{j \neq i} \text{dist}(x_i, x_j)$$

میانگین فاصله به سایر نمونه‌ها و

$$s_i = \sum_{j=1}^n k(x_i, x_j)$$

مجموع شباهت‌ها؛ بیانگر «تکرارپذیری» یا مرکزیت.
قاعده حذف نمونه‌ها می‌تواند به صورت زیر باشد:

$$\text{if } \bar{d}_i < \tau_{\text{sim}} \quad (\text{یا}) \quad s_i > \tau_{\text{redun}} \Rightarrow \text{drop } x_i.$$

روش‌های متداول:

یکی از روش‌های رایج، نمونه‌برداری مبتنی بر خوشه‌بندی است که ابتدا خوشه‌بندی^۱ روی داده‌ها انجام شده و سپس یک نماینده مرکزی از هر خوشه نگه داشته می‌شود؛ این روش پیچیدگی محاسباتی را از n به تعداد خوشه‌ها کاهش می‌دهد. روش دیگر، نمونه‌برداری وابسته به هسته یا ماتریس شباهت است که با استفاده از ماتریس شباهت $S \in \mathbb{R}^{n \times n}$ و معیارهایی مانند اهرم^۲ (در رگرسیون خطی، این معیار نشان می‌دهد که یک نمونه چقدر در تعیین برازش مدل تاثیر دارد). یا درجه^۳ از گراف شباهت، نمونه‌های مرکزی مشخص و بقیه حذف می‌شوند. همچنین برای شبکه‌های کانولوشنی، حذف فیلترهای شبکه بر اساس شباهت ویژگی‌ها کاربرد دارد؛ در این روش خروجی فیلترها^۴ با یکدیگر مقایسه شده و فیلترهایی که شباهت بالایی با دیگران دارند حذف می‌شوند [۴۰].

مزایا:

این رویکردها امکان حذف نمونه‌های تکراری و کاهش قابل توجه اندازه مجموعه آموزش بدون افت شدید عملکرد را فراهم می‌کنند. همچنین با انتخاب نماینده‌های مناسب در روش‌های خوشه‌بندی، تنوع اطلاعاتی بهتر از حذف تصادفی حفظ می‌شود. علاوه بر این، می‌توان این روش‌ها را با تکنیک‌های کاهش بُعد^۵ ترکیب کرد تا آموزش در مجموعه داده‌های وب-اسکیل^۶ بهینه‌سازی شود.

محدودیت‌ها:

محاسبه مستقیم ماتریس شباهت برای مقادیر بزرگ n هزینه‌بر و نیازمند حافظه زیادی است و معمولاً به روش‌های تقریبی نیاز دارد. انتخاب معیار شباهت، مانند فاصله اقلیدسی، کسینوس یا هسته، تاثیر زیادی بر نتایج دارد و مسئله‌محور است. علاوه بر این، نزدیکی در فضای ویژگی لزوماً به

¹Clustering

²Leverage

³Degree

⁴Feature maps

⁵Dimensionality Reduction Techniques

⁶Web-Scale Datasets

نزدیکی در دیدگاه برچسب یا وظیفه یادگیری ترجمه نمی‌شود و ممکن است نمونه‌هایی با برچسب‌های متفاوت در فضای ویژگی نزدیک باشند، به‌ویژه در مجموعه داده‌های سرشار از نویز.

۲.۲.۲ هرس بر اساس توزیع داده‌ها^۱

در روش‌های مبتنی بر توزیع داده‌ها، ایده‌ی اصلی این است که داده‌های موجود در نواحی کم‌احتمال (از دیدگاه توزیع آماری داده‌ها) یا دارای چگالی پایین، احتمالاً حاوی نویز، اشتباه اندازه‌گیری یا داده‌های غیرنماینده هستند. این دسته از روش‌ها تلاش می‌کنند با تقریب زدن توزیع اصلی داده‌ها $p(x)$ و حذف نمونه‌هایی که احتمال وقوع آن‌ها کمتر از آستانه‌ی معینی است، مجموعه داده را به نواحی پراطلاحی و متراکم محدود کنند [۴].

به‌طور کلی، اگر داده‌ها از توزیع $p(x)$ تبعیت کنند، می‌توان احتمال شرطی هر نمونه را برآورد کرد:

$$p(x_i) \approx \frac{1}{n} \sum_{j=1}^n K_h(x_i - x_j), \quad (33.2)$$

که در آن $K_h(\cdot)$ تابع هسته^۲ با پهنای h است. نمونه‌هایی که $p(x_i) < \tau_{\text{prob}}$ دارند، به عنوان داده‌های نادر یا پرت در نظر گرفته می‌شوند و حذف می‌گردند. انتخاب تابع K (مانند هسته گاوسی) و پارامتر h نقش تعیین‌کننده‌ای در دقت تخمین دارد.

۱.۲.۲.۲ هرس بر اساس نواحی پرت داده‌ها^۳

در این روش، نمونه‌هایی که رفتار آماری آن‌ها به‌طور قابل توجهی با بقیه داده‌ها متفاوت است، به عنوان نقاط پرت^۴ در نظر گرفته شده و از مجموعه حذف می‌شوند. تشخیص این نقاط معمولاً بر اساس فاصله از مرکز توزیع داده‌ها یا نمرات ناهنجاری^۵ انجام می‌شود. یکی از روش‌های کلاسیک، استفاده از نمره Z ^۶ است:

$$Z_i = \frac{x_i - \mu}{\sigma}, \quad (34.2)$$

که در آن μ میانگین و σ انحراف معیار داده‌هاست. داده‌هایی با $|Z_i| > \tau_z$ (معمولاً $\tau_z = 3$) به عنوان نقاط پرت در نظر گرفته و حذف می‌شوند.

¹Distribution-based Pruning

²Kernel function

³Outlier Detection-based Pruning

⁴Outliers

⁵Anomaly scores

⁶Z-score

در حالت چندبعدی، از فاصله‌ی ماحالانوبیس^۱ استفاده می‌شود:

$$D_M(x_i) = \sqrt{(x_i - \mu)^\top \Sigma^{-1} (x_i - \mu)}, \quad (35.2)$$

که در آن μ میانگین و Σ ماتریس کوواریانس^۲ داده‌هاست. مقادیر $D_M(x_i)$ که از حد بحرانی توزیع^۳ χ_d^2 فراتر روند، به عنوان نقاط پرت شناسایی می‌شوند [۵۸]. رویکردهای مدرن‌تر از مدل‌های ناپارامتری^۴ مانند عامل نقاط پرت محلی^۵ یا جنگل جداسازی^۶ بهره می‌برند. در روش عامل نقاط پرت محلی، چگالی محلی هر نقطه با همسایگانش مقایسه می‌شود و نقاطی با چگالی غیرمعمول حذف می‌گردند:

$$\text{LOF}(x_i) = \frac{1}{|N_k(x_i)|} \sum_{x_j \in N_k(x_i)} \frac{\text{lrd}(x_j)}{\text{lrd}(x_i)}, \quad (36.2)$$

که در آن $\text{lrd}(x)$ چگالی محلی معکوس^۷ است. مزایا:

این روش قادر است داده‌های نویزی یا اشتباه برچسب‌خورده را که می‌توانند عملکرد مدل را کاهش دهند، حذف کند و در نتیجه کیفیت داده و پایداری مدل‌های یادگیری بهبود می‌یابد. علاوه بر این، با انتخاب معیار مناسب، این رویکرد برای هر نوع داده، اعم از عددی، متنی یا تصویری، قابل استفاده است.

محدودیت‌ها:

روش‌های تشخیص داده‌های پرت یا نویزی به شدت به انتخاب آستانه‌ها (τ_z)، حساس هستند. در مجموعه داده‌های غیرایستا یا چندتوزیعی، شناسایی نمونه‌های پرت دشوارتر می‌شود. همچنین، روش‌های محلی مانند عامل نقاط پرت محلی برای داده‌های بزرگ دارای هزینه محاسباتی بالایی هستند.

۲.۲.۲.۲ هرس بر اساس چگالی داده‌ها^۸

در این روش، تصمیم حذف داده‌ها بر پایه‌ی میزان تراکم (چگالی) نقاط در فضای ویژگی گرفته می‌شود. فرض اساسی این است که نواحی با چگالی بسیار پایین حاوی داده‌های نویزی، نادر یا غیرنماینده هستند، در حالی که نواحی با چگالی بالا نماینده‌ی ساختار اصلی داده‌اند [۱۹].

¹Mahalanobis Distance

²Covariance Matrix

³Critical Threshold of the Distribution

⁴Nonparametric Models

⁵Local Outlier Factor:LOF

⁶Isolation Forest

⁷Local reachability density

⁸Density-based Pruning

مدل‌های چگالی محور معمولاً از تخمین چگالی محلی استفاده می‌کنند:

$$\rho(x_i) = \frac{k}{V_d(r_i)}, \quad (37.2)$$

که در آن r_i شعاع کره‌ای است که شامل k همسایه‌ی نزدیک x_i بوده و $V_d(r_i)$ حجم آن در بعد d است. داده‌هایی با $\rho(x_i) < \tau_\rho$ حذف می‌شوند.

در عمل، الگوریتم‌های خوشه‌بندی مبتنی بر چگالی با قابلیت تشخیص نویز^۱ [۲۰] و مرتب‌سازی نقاط برای شناسایی ساختار خوشه‌ها^۲ [۵] به طور گسترده برای تفکیک نواحی پرت از نواحی پرتراکم استفاده می‌شوند. در روش خوشه‌بندی مبتنی بر چگالی با قابلیت تشخیص نویز، دو پارامتر ε (شعاع همسایگی) و minPts تعیین می‌کنند که کدام نقاط متعلق به خوشه‌های پرتراکم‌اند:

$$x_i \text{ if point core } |N_\varepsilon(x_i)| \geq \text{minPts}.$$

نقاطی که در هیچ خوشه‌ای قرار نمی‌گیرند به عنوان داده‌های غیرضروری حذف می‌شوند. مزایا:

این روش توانایی شناسایی خودکار ساختار داده‌ها را بدون نیاز به فرض توزیع خاص دارد و در برابر نویز و داده‌های نامتوازن مقاوم است. همچنین برای داده‌های چندبعدی و غیرخطی مناسب بوده و می‌تواند ساختار پیچیده مجموعه داده‌ها را به خوبی کشف کند. محدودیت‌ها:

اجرای این روش نیازمند تنظیم دقیق پارامترهای ε و minPts است. علاوه بر این، حساسیت بالایی به مقیاس ویژگی‌ها دارد و بنابراین نرمال‌سازی داده‌ها قبل از اعمال الگوریتم ضروری می‌باشد.

۳.۲ هرس داده‌ها بر اساس الگوریتم‌ها و مدل‌های خاص^۳

در این دسته از روش‌ها، استراتژی هرس به‌طور ویژه متناسب با ساختار و ویژگی‌های الگوریتم یادگیری طراحی می‌شود. برخلاف روش‌های آماری یا مبتنی بر داده، این رویکردها از اطلاعات درونی مدل نظیر پارامترها، وزن‌ها، گره‌ها یا شاخص‌های خطا برای حذف داده‌ها یا اجزای غیرضروری استفاده می‌کنند.

هدف نهایی این نوع هرس، بهینه‌سازی عملکرد مدل از طریق کاهش پیچیدگی، جلوگیری از بیش‌برازش، و افزایش قابلیت تعمیم^۴ است. در ادامه، دو خانواده‌ی اصلی از این روش‌ها معرفی می‌شوند: (۱) هرس در درخت‌های تصمیم‌گیری و (۲) هرس در شبکه‌های عصبی.

¹Density-Based Spatial Clustering of Applications with Noise:DBSCAN

²Ordering Points To Identify the Clustering Structure:OPTICS

³Algorithm-specific Pruning

⁴Generalization

۱.۳.۲ هرس در درخت‌های تصمیم‌گیری^۱

درخت‌های تصمیم، اگر بدون محدودیت رشد کنند، تمایل دارند داده‌ها را بیش از حد برازش دهند. برای جلوگیری از این مسئله، فرآیند هرس با هدف حذف گره‌ها^۲ یا شاخه‌هایی^۳ که تأثیر ناچیزی بر دقت کلی مدل دارند انجام می‌شود. دو رویکرد اصلی در هرس درخت تصمیم وجود دارد: هرس پیش‌ساختی و هرس پس‌ساختی [۵۵].

۱.۱.۳.۲ هرس پیش‌ساختی^۴

در این رویکرد، رشد درخت در زمان آموزش به‌صورت زودهنگام متوقف می‌شود، به‌گونه‌ای که از ایجاد گره‌هایی با سود اطلاعاتی پایین جلوگیری گردد. شرط توقف معمولاً بر اساس معیارهایی چون آستانه‌ی حداقل سود اطلاعاتی، حداقل تعداد نمونه در هر گره یا آزمون‌های آماری تعیین می‌شود. اگر $I(S)$ معیار سود اطلاعاتی برای تقسیم مجموعه S باشد (مثلاً بر اساس آنتروپی یا شاخص جینی^۵)، آنگاه هرس پیش‌ساختی انجام می‌شود اگر:

$$I(S) < \tau_{\text{split}}, \quad (38.2)$$

که در آن τ_{split} آستانه‌ی سود اطلاعاتی است.

مزایا: این روش از رشد بیش‌ازحد درخت جلوگیری کرده و زمان آموزش را کاهش می‌دهد. علاوه بر این، برای داده‌های بزرگ یا دارای نویز مناسب است و می‌تواند عملکرد مدل را در چنین شرایطی بهبود بخشد.

محدودیت‌ها: یکی از محدودیت‌های این روش احتمال توقف زودهنگام است که ممکن است منجر به از دست رفتن الگوهای مفید در داده‌ها شود. همچنین نتایج آن به شدت به انتخاب پارامتر آستانه وابسته است و نیازمند تنظیم دقیق می‌باشد.

۲.۱.۳.۲ هرس پس‌ساختی^۶

در این روش، ابتدا درخت به‌طور کامل رشد می‌کند و سپس شاخه‌های غیرضروری حذف می‌شوند. هرس پس‌ساختی معمولاً دقیق‌تر است زیرا تصمیمات آن بر اساس درخت نهایی و ارزیابی عملکرد واقعی (مثلاً روی داده‌های اعتبارسنجی) اتخاذ می‌شود.

یکی از روش‌های معروف، هرس کاهش خطا^۷ است [۵۶]، که در آن هر گره بررسی می‌شود و

¹Decision Tree Pruning

²Nodes

³Branches

⁴Pre-Pruning

⁵Gini Index

⁶Post-Pruning

⁷Reduced Error Pruning

اگر حذف آن موجب افزایش خطای اعتبارسنجی نشود، آن گره حذف می‌گردد:

$$E_{\text{val}}(T_{\text{pruned}}) \leq E_{\text{val}}(T), \quad (39.2)$$

که در آن E_{val} خطای مجموعه‌ی اعتبارسنجی و T_{pruned} درخت پس از حذف گره است. روش دیگر، هرس پیچیدگی هزینه^۱ است که با افزودن جریمه‌ای برای تعداد گره‌ها انجام می‌شود:

$$R_{\alpha}(T) = R(T) + \alpha|T|, \quad (40.2)$$

که در آن $R(T)$ خطای درخت و $|T|$ تعداد گره‌های پایانی است. مقدار α سطح تعادل بین دقت و پیچیدگی را کنترل می‌کند [۱۲].

مزایا: این روش دقت بالاتری نسبت به هرس پیش‌ساختی ارائه می‌دهد و امکان کنترل مستقیم پیچیدگی مدل را فراهم می‌کند، که به بهبود عملکرد و جلوگیری از بیش‌برازش کمک می‌کند. محدودیت‌ها: اجرای این روش مستلزم داشتن مجموعه‌ای مجزا برای اعتبارسنجی است و هزینه‌ی محاسباتی آن به‌ویژه برای درخت‌های بزرگ بالاتر می‌باشد.

۲.۳.۲ هرس در شبکه‌های عصبی^۲

در شبکه‌های عصبی، هدف از هرس، کاهش تعداد پارامترها (وزن‌ها یا نورون‌ها) بدون افت محسوس در دقت مدل است. با حذف اتصالات یا واحدهای غیرمؤثر، می‌توان مدل را فشرده‌تر، سریع‌تر و با مصرف حافظه کمتر ساخت. دو رویکرد اصلی در این زمینه عبارت‌اند از: حذف وزن‌ها و حذف نورون‌ها [۳۸، ۳۰].

۱.۲.۳.۲ حذف وزن‌ها^۳

در این روش، اتصالاتی (وزن‌هایی) که تأثیر کمی بر خروجی شبکه دارند شناسایی و حذف می‌شوند. وزن‌هایی با قدر مطلق کوچک معمولاً اهمیت کمتری دارند:

$$W' = \{w_{ij} \mid |w_{ij}| \geq \tau_w\}, \quad (41.2)$$

که در آن τ_w آستانه‌ی اهمیت وزن است.

رویکردهای پیشرفته‌تر از گرادینان لاگرانژی^۴ یا تقریب هسین برای ارزیابی حساسیت وزن‌ها استفاده می‌کنند. روش معروف Optimal Brain Damage (OBD) [۳۸] اهمیت هر وزن را بر اساس

¹Cost-Complexity Pruning

²Neural Network Pruning

³Weight Pruning

⁴Lagrangian Gradient

تأثیر آن بر تابع هزینه تقریب می‌زند:

$$S_{ij} = \frac{1}{\gamma} H_{ijj} w_{ij}^2, \quad (42.2)$$

که H_{ijj} المان قطری ماتریس هسین تابع هزینه است. مزایا: این روش امکان کاهش چشمگیر تعداد پارامترها را بدون افت قابل توجه دقت فراهم می‌کند و برای فشرده‌سازی مدل و استقرار در سیستم‌های کم‌منبع مناسب است. محدودیت‌ها: اجرای این روش مستلزم بازآموزی مدل پس از هرس برای بازیابی دقت است و هزینه‌ی محاسبه‌ی ماتریس هسین یا گرادیان‌های مرتبه دوم نیز از دیگر محدودیت‌های آن محسوب می‌شود.

۲.۲.۳.۲ حذف نورون‌ها^۱

در این رویکرد، به جای حذف وزن‌های منفرد، کل نورون‌هایی که سهم اندکی در خروجی شبکه دارند حذف می‌شوند. این روش معمولاً با ارزیابی اهمیت هر نورون بر اساس پاسخ فعال‌سازی^۲ انجام می‌شود:

$$I_j = \mathbb{E}_{x \sim \mathcal{D}} [|a_j(x)|], \quad (43.2)$$

که در آن $a_j(x)$ خروجی نورون j برای ورودی x است. نورون‌هایی که $I_j < \tau_n$ دارند حذف می‌شوند. [۴۶].

روش‌های مبتنی بر مقیاس‌دهی نرمال‌سازی دسته‌ای^۳ یا L1-regularization نیز برای وادار کردن شبکه به تولید نورون‌های کم‌اهمیت و قابل حذف استفاده می‌شوند. مزایا: این روش موجب کاهش قابل توجه زمان استنتاج^۴ می‌شود و در مقایسه با حذف وزن‌ها، پیاده‌سازی ساده‌تر و تفسیرپذیری بهتری دارد.

محدودیت‌ها: یکی از محدودیت‌های این روش، خطر حذف نورون‌های مفید در لایه‌های میانی شبکه است. علاوه بر این، نتایج به معیار اهمیت انتخاب‌شده حساس بوده و نیازمند تعیین دقیق آن می‌باشد.

¹Neuron Pruning

²Activation

³Scaling BatchNorm

⁴Inference

۴.۲ هرس داده‌ها بر اساس معیارهای ریاضی و تابعی^۱

در این گروه از روش‌ها، فرآیند هرس داده‌ها با بهره‌گیری از تحلیل‌های ریاضی، مشتقات تابع هزینه^۲، و مفاهیم مشتق‌گیری در فضای پارامترها انجام می‌شود. هدف اصلی، اندازه‌گیری کمی میزان تأثیر هر نمونه داده بر پارامترهای مدل یا مقدار تابع هزینه است تا بتوان داده‌های کم‌تأثیر یا مضر را شناسایی و حذف کرد.

این رویکردها به‌ویژه در یادگیری عمیق و مدل‌های پارامتری پیچیده، کاربرد گسترده‌ای دارند زیرا اجازه می‌دهند هرس داده‌ها به‌صورت مبتنی بر گرادیان، نرم یا تابع اثر انجام شود [۵۴، ۳۵].

۱.۴.۲ هرس مبتنی بر گرادیان^۳

در این روش، تأثیر هر نمونه از داده‌ها بر اساس تغییراتی که در گرادیان تابع هزینه ایجاد می‌کند، اندازه‌گیری می‌شود. اگر داده‌ای موجب تغییر قابل‌توجهی در جهت یا بزرگی گرادیان شود، احتمالاً برای آموزش مدل حیاتی است؛ در حالی که داده‌هایی با گرادیان‌های هم‌راستا یا با اندازه‌ی بسیار کوچک ممکن است تکراری یا کم‌اهمیت باشند [۶۰].

۱.۱.۴.۲ هرس مبتنی بر تغییرات گرادیان^۴

در این رویکرد، اهمیت نمونه i با توجه به تأثیر آن بر تغییر گرادیان کل تابع هزینه تعریف می‌شود:

$$\Delta g_i = \|\nabla_{\theta} \mathcal{L}(\theta; \mathcal{D}) - \nabla_{\theta} \mathcal{L}(\theta; \mathcal{D} \setminus \{x_i\})\|_2, \quad (۴۴.۲)$$

که در آن $\nabla_{\theta} \mathcal{L}$ گرادیان تابع هزینه نسبت به پارامترهای θ است. اگر مقدار Δg_i کوچک باشد، داده x_i تأثیر اندکی بر گرادیان کل دارد و می‌تواند حذف شود. مزایا:

این روش با فرآیند واقعی آموزش مدل هم‌راستا بوده و مبتنی بر گرادیان‌ها است و همچنین نیازی به داشتن مجموعه داده‌ی اعتبارسنجی مجزا ندارد. محدودیت‌ها:

اجرای این روش برای مجموعه‌های داده بزرگ دارای هزینه‌ی محاسباتی بالایی است و در مدل‌های غیرخطی، گرادیان‌ها ممکن است نوسان زیادی داشته باشند که دقت برآورد اهمیت داده‌ها را کاهش می‌دهد.

^۱Mathematical and Influence Function-based Pruning

^۲Loss Function Derivatives

^۳Gradient-based Pruning

^۴Gradient Change-based Pruning

۲.۱.۴.۲ هرس مبتنی بر اهمیت گرادیان^۱

ایده‌ی اصلی در این روش، استفاده از اندازه‌ی گرادیان به عنوان شاخصی از اهمیت داده است. داده‌هایی با گرادیان‌های بزرگ معمولاً اطلاعات بیشتری برای به‌روزرسانی پارامترها فراهم می‌کنند. اهمیت داده‌ی i به‌صورت زیر تعریف می‌شود:

$$I_i = \|\nabla_{\theta} \mathcal{L}(\theta; x_i, y_i)\|_p, \quad (45.2)$$

که در آن p معمولاً برابر با ۲ یا ۱ است (نرم L_2 یا L_1). نمونه‌هایی که $I_i < \tau_g$ دارند، برای یادگیری کم‌اهمیت در نظر گرفته شده و حذف می‌شوند [۵۱].
مزایا:

این روش ساده و قابل محاسبه در فرآیند آموزش است و می‌تواند هم‌افزایی خوبی با بهینه‌سازی‌های مبتنی بر گرادیان داشته باشد.

محدودیت‌ها:

روش موردنظر نسبت به نرخ یادگیری و مقیاس تابع هزینه حساس است و گرادیان‌های کوچک ممکن است در مراحل اولیه‌ی آموزش به‌اشتباه حذف شوند.

۲.۴.۲ هرس مبتنی بر نرم‌ها و خطاها^۲

این دسته از روش‌ها بر اساس اندازه‌ی نرم بردارهای گرادیان یا خطای پیش‌بینی عمل می‌کنند. منطق اصلی آن است که نمونه‌هایی با مقدار نرم پایین در گرادیان یا خطا، تأثیر اندکی بر بهبود عملکرد مدل دارند [۶۵].

۱.۲.۴.۲ هرس بر اساس نرم گرادیان^۳

در این روش، مقدار نرم گرادیان برای هر داده محاسبه می‌شود و نمونه‌هایی که گرادیان‌های آن‌ها بسیار کوچک است، حذف می‌گردند:

$$\|\nabla_{\theta} \mathcal{L}(\theta; x_i, y_i)\|_2 < \tau_{\text{grad}}. \quad (46.2)$$

این داده‌ها معمولاً یا در نواحی اشباع تابع فعال‌سازی قرار دارند یا در نقاطی هستند که مدل پیش‌بینی دقیقی ارائه می‌دهد، بنابراین حضور آن‌ها در آموزش سودمند نیست.
مزایا:

¹Gradient Importance-based Pruning

²Norm-based Pruning

³Gradient Norm-based Pruning

این روش موجب کاهش هزینه‌ی محاسباتی و تسریع فرآیند آموزش می‌شود و برای مجموعه داده‌هایی با تکرار زیاد مناسب است. محدودیت‌ها:

اجرای این روش نیازمند تنظیم دقیق آستانه τ_{grad} است و در مراحل اولیه‌ی آموزش ممکن است داده‌های مهم به اشتباه حذف شوند.

۲.۲.۴.۲ هرس بر اساس نرم خطا^۱

در این رویکرد، تصمیم به حذف داده‌ها بر اساس اندازه‌ی خطای مدل در آن‌ها گرفته می‌شود. اگر خطای پیش‌بینی $\mathcal{L}(x_i, y_i)$ بسیار کوچک باشد، داده احتمالاً تکراری یا ساده است و می‌توان آن را حذف کرد:

$$\mathcal{L}(x_i, y_i) < \tau_{\text{err}}. \quad (۴۷.۲)$$

در مقابل، داده‌هایی با خطای بسیار بالا نیز ممکن است نویزی باشند و حذف آن‌ها می‌تواند پایداری مدل را افزایش دهد [۶۶]. مزایا:

این روش دارای تفسیرپذیری بالاست زیرا مبتنی بر خطای مدل است و علاوه بر این، برای انواع مدل‌ها قابل استفاده می‌باشد. محدودیت‌ها:

اجرای این روش نیازمند تکرارهای متعدد برای پایدارسازی برآورد خطا است و همچنین خطر حذف نمونه‌های آموزشی سخت اما مهم وجود دارد.

۳.۴.۲ هرس مبتنی بر تابع اثر^۲

توابع اثر ابزاری قدرتمند در آمار و یادگیری ماشین هستند که تغییرات در پارامترهای مدل را در نتیجه‌ی حذف یا تغییر یک داده‌ی خاص تخمین می‌زنند. اگر اثر داده‌ای بر پارامترهای مدل ناچیز باشد، می‌توان آن داده را بدون تأثیر محسوس بر عملکرد حذف کرد [۳۵].

۱.۳.۴.۲ هرس بر اساس اثر محلی^۳

در این روش، هدف تحلیل میزان تأثیر محلی هر داده‌ی آموزشی بر تابع هزینه یا خروجی مدل در ناحیه‌ای نزدیک به پارامترهای فعلی θ است. ایده‌ی اصلی از آمار مقاوم و تحلیل حساسیت گرفته

^۱Error Norm-based Pruning

^۲Influence Function-based Pruning

^۳Local Influence Pruning

شده و بعدها در یادگیری ماشین برای سنجش اثر حذف یا تغییر جزئی یک نمونه بر پارامترهای مدل گسترش یافته است [۳۵].

برای هر داده $z_i = (x_i, y_i)$ ، تابع اثر محلی به صورت زیر تعریف می‌شود:

$$I_{\text{local}}(z_i) = -\nabla_{\theta} \mathcal{L}(\theta; z_i)^{\top} H_{\theta}^{-1} \nabla_{\theta} \mathcal{L}(\theta; D_{\text{val}}), \quad (۴۸.۲)$$

در اینجا، $\nabla_{\theta} \mathcal{L}(\theta; z_i)$ گرادیان تابع هزینه نسبت به پارامترهای مدل برای داده z_i را نشان می‌دهد، و $H_{\theta} = \nabla_{\theta}^2 \mathcal{L}(\theta; D)$ ماتریس هسین تابع هزینه است که انحناى سطح خطا را بیان می‌کند. همچنین، D_{val} مجموعه داده‌ی اعتبارسنجی است که برای ارزیابی تغییر عملکرد مدل استفاده می‌شود. مقدار $I_{\text{local}}(z_i)$ بیانگر این است که اگر داده z_i حذف شود، گرادیان تابع هزینه در نقاط اطراف θ تا چه حد تغییر می‌کند. داده‌هایی با $|I_{\text{local}}(z_i)| < \tau_{\text{inf}}$ تأثیر ناچیزی بر رفتار محلی مدل دارند و برای هرس انتخاب می‌شوند. تفسیر هندسی:

بردار $\nabla_{\theta} \mathcal{L}(\theta; z_i)$ جهت حرکت به سمت بهبود مدل با توجه به داده z_i را مشخص می‌کند، و ضرب آن در H_{θ}^{-1} میزان حساسیت پارامترها نسبت به تغییرات در این جهت را تعیین می‌نماید. بنابراین، تابع اثر محلی تقریب مرتبه‌اولی از تأثیر داده بر تغییر پارامترها فراهم می‌کند. کاربردها:

این روش برای شناسایی داده‌های پرت یا ناسازگار در یادگیری نظارت‌شده^۱ کاربرد دارد و می‌تواند داده‌هایی که تأثیر منفی بر مدل‌های حساس مانند شبکه‌های عمیق دارند را حذف کند. علاوه بر این، امکان تحلیل حساسیت مدل نسبت به داده‌های خاص نیز فراهم است که به تفسیرپذیری مدل کمک می‌کند. مزایا:

روش مورد نظر تحلیل دقیقی در سطح نمونه ارائه می‌دهد و قابلیت شناسایی داده‌های مضر، پرت یا تأثیرگذار را داراست. این رویکرد مبتنی بر چارچوب ریاضی دقیق و تحلیل تفاضلی مرتبه‌دوم^۲ است و از این نظر قابل تفسیر و معتبر می‌باشد. محدودیت‌ها:

محاسبه و وارون‌سازی H_{θ} برای مدل‌های بزرگ بسیار پرهزینه است ($O(n^3)$) و در شبکه‌های عمیق، تخمین تقریبی H_{θ}^{-1} معمولاً با خطای عددی همراه است. همچنین در صورت وجود نویز زیاد در داده‌ها یا گرادیان‌ها، نتایج ممکن است ناپایدار شود. برای حل این مشکلات، روش‌هایی چون LiSSA برای تقریب مؤثر H_{θ}^{-1} پیشنهاد شده‌اند [۲]، که با کاهش پیچیدگی محاسباتی، کاربرد این روش را در مدل‌های بزرگ‌تر ممکن می‌سازند.

^۱Supervised Learning

^۲Second-Order Differential Analysis

۲.۳.۴.۲ هرس بر اساس اثر جهانی^۱

در حالی که تابع اثر محلی تنها تأثیر یک داده را در همسایگی پارامتر فعلی مدل می‌سنجد، تابع اثر جهانی به بررسی تأثیر کلی حذف داده بر عملکرد مدل در سطح کل داده‌های اعتبارسنجی یا حتی بر تابع هدف نهایی می‌پردازد. این معیار نشان می‌دهد که حذف داده‌ی z_i چگونه تعمیم مدل را در مقیاس کلان تغییر می‌دهد [۵۴].

اثر جهانی داده‌ی z_i به صورت زیر محاسبه می‌شود:

$$I_{\text{global}}(z_i) = \frac{1}{|\mathcal{D}_{\text{val}}|} \sum_{z_j \in \mathcal{D}_{\text{val}}} \left(-\nabla_{\theta} \mathcal{L}(\theta; z_i)^{\top} H_{\theta}^{-1} \nabla_{\theta} \mathcal{L}(\theta; z_j) \right). \quad (۴۹.۲)$$

به بیان دیگر، این مقدار میانگینی از تأثیر داده‌ی z_i بر عملکرد مدل روی کل داده‌های اعتبارسنجی است. اگر $I_{\text{global}}(z_i)$ منفی و با قدر مطلق بالا باشد، داده به بهبود عملکرد مدل کمک می‌کند؛ در حالی که مقادیر مثبت نشان‌دهنده‌ی داده‌های مضر یا گمراه‌کننده هستند (مانند داده‌های نویزی). کاربردها:

این روش برای حذف داده‌های مضر یا داده‌های اشتباه برچسب‌خورده کاربرد دارد و می‌تواند تعمیم مدل را با حذف نمونه‌هایی که تأثیر منفی بر عملکرد نهایی دارند، بهبود بخشد. همچنین، امکان ارزیابی پایداری مدل نسبت به حذف داده‌ها نیز فراهم است. مزایا:

روش مورد نظر امکان درک جامع از تأثیر هر داده بر کل فضای عملکرد مدل را فراهم می‌کند و به حفظ داده‌های مفید و حذف داده‌های مضر کمک می‌کند، که منجر به بهبود تعمیم مدل می‌شود. این رویکرد برای کاربردهای حساس مانند تشخیص حملات داده‌ای یا پاک‌سازی داده‌ها مناسب است. محدودیت‌ها:

اجرای این روش نیازمند محاسبه‌ی اثر هر داده روی کل مجموعه‌ی داده‌های اعتبارسنجی است ($\mathcal{O}(n \times m)$) و وابسته به تقریب‌های گرادیانی دقیق و هسین پایدار می‌باشد. همچنین، محاسبه‌ی آن در شبکه‌های بسیار بزرگ، مانند ترنسفورمرها، دشوار و پرهزینه است. برای تسریع محاسبات، پژوهش‌هایی نظیر [۸] و [۶] از تقریب‌های مبتنی بر زیرنمونه‌گیری داده‌ها یا تخمین برداری کم‌رتبه‌ی H_{θ}^{-1} استفاده کرده‌اند که دقت بالایی را با هزینه‌ی کمتر فراهم می‌کنند.

۵.۲ هرس داده‌ها بر اساس هندسه داده‌ها^۲

روش‌های هندسی بر پایه‌ی تحلیل موقعیت نسبی داده‌ها در فضای ویژگی‌ها^۳ عمل می‌کنند. در این رویکرد، ساختار فضایی داده‌ها از طریق اندازه‌گیری فاصله‌ها، زاویه‌ها، تراکم و خوشه‌ها بررسی

^۱Global Influence Pruning

^۲Geometric-based Pruning

^۳Feature space

می‌شود تا داده‌های پرت، تکراری یا کم‌اهمیت شناسایی و حذف گردند. ایده‌ی اصلی آن است که داده‌هایی که در فضای ویژگی‌ها موقعیت مشابه یا هم‌پوشان دارند، اطلاعات افزونه فراهم می‌کنند و می‌توان آن‌ها را بدون افت عملکرد مدل حذف کرد [۲۱، ۳]. این دسته از روش‌ها معمولاً مستقل از مدل هستند و پیش از فرآیند یادگیری به عنوان مرحله‌ی پیش‌پردازش داده‌ها به کار می‌روند.

۱.۵.۲ هرس مبتنی بر تحلیل هندسی^۱

در این رویکرد، داده‌ها به صورت نقاطی در فضای ویژگی‌ها در نظر گرفته می‌شوند و ویژگی‌های هندسی میان آن‌ها مانند فاصله‌ی اقلیدسی، زاویه‌ی کسینوسی یا چگالی موضعی تحلیل می‌شود. هدف، یافتن ساختار هندسی پنهان در داده‌هاست تا نمونه‌های غیرمتمايز یا پرت شناسایی گردند. به‌طور کلی، هر داده $x_i \in \mathbb{R}^d$ با برداری در فضای d -بعدی نمایش داده می‌شود. اگر x_i در ناحیه‌ای با تراکم زیاد از داده‌ها قرار داشته باشد یا نسبت به سایر داده‌ها فاصله‌ی اندکی داشته باشد، احتمالاً تکراری است و می‌تواند حذف شود. این ویژگی با استفاده از تابع تراکم موضعی $p(x_i)$ قابل اندازه‌گیری است:

$$p(x_i) = \frac{1}{k} \sum_{j=1}^k \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right), \quad (50.2)$$

که در آن k تعداد همسایه‌ها و σ پارامتر پهنا^۲ است [۵۹]. داده‌هایی با $p(x_i) > \tau_{\text{dense}}$ معمولاً افزونه محسوب شده و حذف می‌شوند.

۱.۱.۵.۲ هرس بر اساس خوشه‌بندی هندسی^۳

در این روش، داده‌ها ابتدا با استفاده از الگوریتم‌های خوشه‌بندی مانند k -means، DBSCAN یا Clus-tering Spectral گروه‌بندی می‌شوند. سپس، در هر خوشه تنها داده‌های نماینده^۴ حفظ شده و سایر داده‌ها حذف می‌شوند [۴۳، ۱۹]. فرآیند کلی به صورت زیر است:

۱. داده‌ها را در K خوشه گروه‌بندی کنید:

$$\mathcal{D} = \bigcup_{k=1}^K C_k, \quad C_i \cap C_j = \emptyset. \quad (51.2)$$

¹Geometric Analysis-based Pruning

²Kernel bandwidth

³Geometric Clustering-based Pruning

⁴Centroids

۲. مرکز هندسی هر خوشه را محاسبه کنید:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i. \quad (52.2)$$

۳. داده‌هایی با فاصله‌ی اندک از مرکز خوشه ($\|x_i - \mu_k\| < \tau_c$) حذف می‌شوند.

مزایا:

این روش حجم داده‌ها را به‌طور مؤثر کاهش می‌دهد و در عین حال تنوع هندسی مجموعه داده را حفظ می‌کند. علاوه بر این، برای داده‌هایی که دارای ساختار خوشه‌ای هستند مناسب است. محدودیت‌ها: روش مذکور نسبت به انتخاب پارامتر K حساس است و عملکرد ضعیفی در داده‌هایی با مرزهای هم‌پوشان^۱ دارد.

۲.۱.۵.۲ هرس بر اساس هندسه‌ی فضای ویژگی‌ها^۲

در این روش، ساختار هندسی داده‌ها در فضای ویژگی‌ها تحلیل می‌شود، که معمولاً از طریق نگاشت غیرخطی داده‌ها به فضای نهفته انجام می‌شود. برای داده‌هایی که با تابع نگاشت $\phi(\cdot)$ به فضای کرنل منتقل می‌شوند، فاصله‌ی هندسی بین دو داده x_i و x_j برابر است با:

$$d_\phi(x_i, x_j) = \|\phi(x_i) - \phi(x_j)\|_2 = \sqrt{k(x_i, x_i) + k(x_j, x_j) - 2k(x_i, x_j)}, \quad (53.2)$$

که در آن $k(\cdot, \cdot)$ تابع کرنل مانند RBF یا هسته چندجمله‌ای^۳ است [۲۵]. داده‌هایی که در فضای ویژگی‌ها فاصله‌ی بسیار کم دارند، از نظر اطلاعاتی مشابه‌اند و می‌توان یکی از آن‌ها را حذف کرد. مزایا:

این روش قادر است داده‌های تکراری را حتی در فضاهای غیرخطی شناسایی کند و با مدل‌های مبتنی بر کرنل مانند SVM^۴ و GPR^۵ سازگار است. محدودیت‌ها:

اجرای این روش مستلزم تعریف مناسب کرنل است و با افزایش تعداد داده‌ها، هزینه‌ی محاسباتی آن به‌طور چشمگیری افزایش می‌یابد ($O(n^2)$).

¹Overlapping Boundary

²Feature Space Geometry-based Pruning

³Polynomial Kernel

⁴Support Vector Machine

⁵Gaussian Process Regression

۲.۵.۲ هرس مبتنی بر خوشه‌بندی فاصله‌ای^۱

در این رویکرد، داده‌ها بر اساس معیارهای فاصله‌ای مانند فاصله‌ی اقلیدسی، کسینوسی یا ماهالانویس تحلیل می‌شوند و نمونه‌هایی که فاصله‌ی زیادی از مرکز توزیع دارند، به‌عنوان داده‌های پرت یا کم‌اهمیت حذف می‌شوند [۵۷]. میزان انحراف داده x_i از مرکز داده‌ها به‌صورت زیر تعریف می‌شود:

$$D(x_i) = \|x_i - \mu\|_{\Sigma^{-1}} = \sqrt{(x_i - \mu)^\top \Sigma^{-1} (x_i - \mu)}, \quad (۵۴.۲)$$

که در آن μ میانگین داده‌ها و Σ ماتریس کوواریانس است. داده‌هایی که $D(x_i) > \tau_d$ دارند، در نواحی دور از مرکز خوشه قرار گرفته و حذف می‌شوند.

۱.۲.۵.۲ هرس مبتنی بر خوشه‌بندی فاصله‌ای^۲

در این روش، ابتدا خوشه‌ها تعیین می‌شوند با k -means یا DBSCAN و سپس در هر خوشه، داده‌هایی که فاصله‌ی آن‌ها از مرکز خوشه از آستانه‌ای مشخص بیشتر باشد، حذف می‌شوند:

$$O(C_k) = \{x_i \in C_k \mid \|x_i - \mu_k\|_2 > \tau_{\text{out}}\}. \quad (۵۵.۲)$$

این داده‌ها معمولاً در مرزهای خوشه یا نواحی کم‌تراکم قرار دارند و حذف آن‌ها موجب افزایش خلوص خوشه‌ها و کاهش نویز می‌شود [۱۳].

مزایا: این روش قادر است داده‌های پرت را با استفاده از ساختار هندسی درون خوشه‌ای شناسایی و حذف کند و برای مجموعه داده‌هایی که دارای خوشه‌های ناهمگن هستند مناسب است. محدودیت‌ها: انتخاب نادرست آستانه τ_{out} ممکن است منجر به حذف بیش از حد داده‌ها شود و این روش نسبت به شکل و اندازه‌ی خوشه‌ها حساسیت دارد.

۶.۲ هرس داده‌ها بر اساس معیارهای فراموشی^۳

در فرآیند آموزش شبکه‌های عصبی، مدل در هر دوره آموزشی^۴ برخی داده‌ها را یاد می‌گیرد و ممکن است در دوره‌های بعدی آن‌ها را از یاد ببرد. مطالعه‌ی [۶۶] نشان داد که پویایی یادگیری^۵ و فراموشی داده‌ها شاخصی کلیدی برای ارزیابی اهمیت هر نمونه است. برخی داده‌ها به‌سرعت یاد گرفته می‌شوند و مدل هرگز آن‌ها را فراموش نمی‌کند؛ این داده‌ها معمولاً ساده یا تکراری هستند. در مقابل، برخی

^۱Distance-based Clustering Pruning

^۲Outlier Clustering Pruning

^۳Forgetting-based Pruning

^۴Epoch

^۵Learning Dynamics

داده‌ها بارها یاد گرفته و سپس فراموش می‌شوند، که نشان‌دهنده‌ی نویز، ابهام یا ناسازگاری در آن‌ها است. در روش‌های هرس مبتنی بر فراموشی، داده‌هایی که مدل در طی آموزش بارها از یاد می‌برد یا تأثیر آن‌ها بر یادگیری ناپایدار است، حذف می‌شوند تا فرآیند یادگیری کارآمدتر گردد. به‌صورت ریاضی، اگر وضعیت پیش‌بینی مدل روی نمونه‌ی x_i در دوره آموزش t با متغیر دودویی زیر نشان داده شود:

$$\mathcal{A}_t(x_i) = \begin{cases} 1, & \text{اگر } \hat{y}_t(x_i) = y_i, \\ 0, & \text{در غیر این صورت} \end{cases} \quad (56.2)$$

آنگاه تعداد دفعات فراموشی برای نمونه‌ی i برابر است با:

$$F_i = \sum_{t=2}^T \mathbb{I}[\mathcal{A}_{t-1}(x_i) = 1 \wedge \mathcal{A}_t(x_i) = 0], \quad (57.2)$$

که در آن T تعداد کل دوره‌های آموزش و $\mathbb{I}[\cdot]$ تابع اندیکاتور^۱ است. به‌طور شهودی، F_i تعداد دفعاتی را می‌شمارد که مدل نمونه‌ای را درست پیش‌بینی کرده و سپس مجدداً اشتباه کرده است. نمونه‌هایی با $F_i > \tau_f$ دارای ناپایداری یادگیری بالا هستند و به‌عنوان داده‌های ضعیف یا کم‌اهمیت برای هرس در نظر گرفته می‌شوند.

۱.۶.۲ هرس بر اساس فراموشی تدریجی^۲

در فراموشی تدریجی، به‌جای تمرکز صرف بر شمارش دفعات فراموشی، شدت و نرخ تغییرات یادگیری داده‌ها در طول زمان تحلیل می‌شود. ایده‌ی کلیدی این است که برخی داده‌ها، اگرچه در نهایت توسط مدل یاد گرفته می‌شوند، اما مسیر یادگیری آن‌ها ناپایدار است و در طی آموزش دچار نوسانات مکرر می‌شوند. چنین داده‌هایی ممکن است باعث ناپایداری گرادیان‌ها، افت سرعت همگرایی، و افزایش بیش‌برازشی شوند.

شاخص فراموشی تدریجی برای هر داده x_i به‌صورت زیر تعریف می‌شود:

$$G_i = \frac{1}{T-1} \sum_{t=2}^T [\max(0, p_{t-1}(x_i) - p_t(x_i))], \quad (58.2)$$

که در آن $p_t(x_i)$ احتمال پیش‌بینی درست نمونه x_i در تکرار t ام است. در نتیجه، G_i میانگین کاهش‌های پیوسته در اطمینان مدل نسبت به نمونه‌ی x_i را اندازه می‌گیرد. تحلیل:

¹Indicator Function

²Gradual Forgetting-based Pruning

اگر $G_i \approx 0$ ، نمونه‌ی x_i به صورت پایدار آموخته می‌شود (نمونه‌ی مفید). در مقابل، اگر G_i بزرگ باشد، مدل در یادگیری نمونه ناپایدار است و احتمالاً داده نویزی یا دارای برچسب اشتباه است. بنابراین داده‌هایی با $G_i > \tau_G$ حذف می‌شوند.
مزایا:

این روش قادر است داده‌های ناپایدار یا دارای نویز تدریجی را تشخیص دهد و موجب افزایش پایداری گرادیان و سرعت همگرایی مدل می‌شود. علاوه بر این، برای تنظیم مجموعه داده‌های بزرگ در یادگیری عمیق مناسب است.
محدودیت‌ها:

اجرای این روش نیازمند ثبت تاریخچه‌ی اطمینان پیش‌بینی‌ها در طول آموزش است و نسبت به نرخ یادگیری (η) و نوسانات ناشی از تصادفی بودن ریزدسته‌ها^۱ حساس می‌باشد. پژوهش‌هایی مانند [۵۱] و [۴۴] نشان داده‌اند که حذف تدریجی داده‌های با نرخ بالای فراموشی، منجر به بهبود پایداری آموزش و کاهش بیش‌برازشی می‌شود، به‌ویژه در مدل‌های عمیق نظیر رزنت^۲ و ترنسفورمرها^۳.

۲.۶.۲ هرس بر اساس فراموشی تصادفی^۴

در روش فراموشی تصادفی، حذف داده‌ها به صورت احتمالاتی و متناسب با نرخ فراموشی انجام می‌شود. این رویکرد از ایده‌ی نمونه‌گیری اهمیتی تصادفی^۵ الهام گرفته است و هدف آن جلوگیری از حذف سخت‌گیرانه‌ی داده‌هایی است که ممکن است در برخی مراحل آموزش مفید باشند. احتمال حذف داده x_i بر اساس شاخص فراموشی F_i به صورت زیر تعریف می‌شود:

$$P_{\text{drop}}(x_i) = \min \left(1, \alpha \cdot \frac{F_i}{F_{\text{max}}} \right), \quad (۵۹.۲)$$

در اینجا، $F_{\text{max}} = \max_i F_i$ نشان‌دهنده‌ی بیشترین تعداد فراموشی در بین داده‌ها است و $\alpha \in [0, 1]$ ضریب کنترل احتمال حذف را مشخص می‌کند.

در هر دوره‌ی هرس، داده‌ها با احتمال $P_{\text{drop}}(x_i)$ از مجموعه‌ی آموزشی حذف می‌شوند. این استراتژی از حذف کامل داده‌های مرزی جلوگیری کرده و در عین حال نمونه‌های پرت یا نویزی را با احتمال بالا حذف می‌کند.
مزایا:

این روش امکان حذف کنترل‌شده و تطبیقی داده‌های مضر را بدون از بین بردن تنوع داده‌ها فراهم می‌کند و برای مجموعه داده‌های نامتوازن یا دارای نویز تصادفی مناسب است. همچنین با حفظ

^۱Mini-batches

^۲ResNet

^۳Transformers

^۴Stochastic Forgetting-based Pruning

^۵Stochastic Importance Sampling

داده‌های بحرانی، تعمیم مدل بهبود می‌یابد.

محدودیت‌ها:

نتایج این روش ممکن است به انتخاب پارامتر α حساس باشند و حذف تصادفی داده‌ها می‌تواند موجب نوسان در عملکرد مدل شود. علاوه بر این، بازتولید دقیق نتایج در تنظیمات تصادفی دشوار است.

تحقیقات اخیر از جمله [۱۰] و [۴۹] نشان داده‌اند که هرس تصادفی داده‌ها بر اساس شاخص فراموشی، تعادلی میان حذف نویز و حفظ داده‌های مفید برقرار می‌کند و کارایی شبکه‌های عمیق را تا ۲۰٪ در زمان آموزش بهبود می‌دهد.

۳.۶.۲ مقایسه‌ی روش‌های فراموشی تدریجی و فراموشی تصادفی

در این بخش، این دو روش را از نظر معیارهای کلیدی مانند نوع معیار، تمرکز اصلی، پایداری نتایج، هزینه محاسباتی و مناسب بودن برای انواع داده‌ها مورد مقایسه قرار می‌گیرند. هدف ارائه دیدی جامع نسبت به مزایا و محدودیت‌های هر روش است. جدول ۱.۲ خلاصه‌ای از این مقایسه را ارائه می‌دهد.

جدول ۱.۲: مقایسه‌ی روش‌های فراموشی تدریجی و فراموشی تصادفی در هرس داده‌ها

ویژگی	فراموشی تدریجی	فراموشی تصادفی
نوع معیار	قطعی (پیوسته)	احتمالاتی
تمرکز اصلی	نرخ تغییر یادگیری	احتمال حذف متناسب با فراموشی
پایداری نتایج	بالا	متوسط
هزینه محاسباتی	زیاد	کمتر
مناسب برای	داده‌های پرنویز و پرت	داده‌های نامتوازن و متنوع

۷.۲ تقطیر دادگان^۱

تقطیر دادگان فرآیندی است که در آن یک مجموعه‌ی داده‌ی بزرگ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ به یک مجموعه‌ی فشرده $\tilde{\mathcal{D}} = \{(\tilde{x}_j, \tilde{y}_j)\}_{j=1}^M, M \ll N$ کاهش می‌یابد، به‌طوری که مدل θ آموزش دیده روی $\tilde{\mathcal{D}}$ بتواند عملکردی مشابه آموزش روی مجموعه کامل داشته باشد [۶۹]. هدف اصلی را می‌توان به صورت بهینه‌سازی زیر بیان کرد:

$$\tilde{\mathcal{D}}^* = \arg \min_{\tilde{\mathcal{D}}} \mathcal{L}(\theta^*(\tilde{\mathcal{D}}), \mathcal{D}), \quad (۶۰.۲)$$

^۱Dataset Distillation

که در آن $\theta^*(\tilde{D})$ پارامترهای مدل آموزش دیده روی داده‌های فشرده هستند. در ادامه به توضیح روش‌های مختلفی می‌پردازیم.

۱.۷.۲ روش‌های مختلف تقطیر دادگان

۱.۱.۷.۲ یادگیری فشرده^۱

مفهوم کلی:

یادگیری فشرده روشی برای کاهش مجموعه داده‌های بزرگ به یک مجموعه کوچک‌تر و نماینده است، به طوری که مدل آموزش دیده روی این مجموعه فشرده، عملکردی مشابه مدل آموزش دیده روی مجموعه کامل داشته باشد [۶۳]. ایده اصلی این است که نمونه‌های فشرده $\tilde{D} = \{(\tilde{x}_j, \tilde{y}_j)\}_{j=1}^M$ بیشترین اطلاعات یادگیری را از مجموعه اصلی $D = \{(x_i, y_i)\}_{i=1}^N$ حفظ کنند. فرایند ریاضیاتی:

برای هر نمونه فشرده $\tilde{x}_j$ ، مجموعه‌ای از نمونه‌های مشابه $C_j \subset D$ تعریف می‌شود. هدف، تولید $\tilde{x}_j$ به گونه‌ای است که فاصله اقلیدسی با نمونه‌های مرتبط کمینه شود:

$$\tilde{x}_j = \arg \min_x \sum_{i \in C_j} w_i \|x - x_i\|_2^2, \quad (61.2)$$

که در آن w_i وزن اهمیت نمونه x_i در حفظ اطلاعات است و معمولاً $w_i = 1/|C_j|$. در قالب کلی‌تر، می‌توان فرایند فشرده‌سازی را به صورت یک مسئله بهینه‌سازی تابع هزینه بیان کرد:

$$\tilde{D}^* = \arg \min_{\tilde{D}} \mathcal{L}_{\text{compress}}(\tilde{D}, D) + \lambda \Omega(\tilde{D}), \quad (62.2)$$

در این رابطه، $\mathcal{L}_{\text{compress}}$ معیار خطای بازنمایی داده‌ها است، مانند مجموع مربعات فاصله‌ها یا خطای پیش‌بینی مدل. همچنین، $\Omega(\tilde{D})$ تابع منظم‌سازی^۲ است که برای جلوگیری از بیش‌برازشی به نمونه‌های فشرده استفاده می‌شود و λ ضریب کنترل اهمیت منظم‌سازی را تعیین می‌کند. پیاده‌سازی:

فرایند فشرده‌سازی داده‌ها به صورت زیر انجام می‌شود: ابتدا نمونه‌های مشابه با الگوریتم‌هایی مانند K-means خوشه‌بندی می‌شوند تا خوشه‌های C_j مشخص گردد. سپس هر خوشه به یک نمونه فشرده تبدیل می‌شود، معمولاً با استفاده از میانگین وزنی نمونه‌ها. در نهایت، می‌توان نمونه‌های فشرده را با گرادینانگیری نسبت به تابع هزینه مدل بهینه کرد تا حفظ عملکرد یادگیری بهبود یابد.

^۱Compressed Learning

^۲Regularization Function

مزایا:

این روش باعث کاهش حجم داده‌ها می‌شود، به طوری که مجموعه فشرده $\tilde{D}$ به طور قابل توجهی کوچک‌تر از مجموعه اصلی است. کاهش تعداد نمونه‌ها همچنین سرعت آموزش مدل را افزایش می‌دهد و روش خوشه‌بندی و میانگین‌گیری نسبتاً ساده و مستقیم است. محدودیت‌ها:

از محدودیت‌های این روش می‌توان به احتمال از دست رفتن جزئیات مهم اشاره کرد، چرا که نمونه‌های نادر یا دارای ویژگی‌های خاص ممکن است حذف شوند. علاوه بر این، کیفیت نمونه‌های فشرده به الگوریتم و پارامترهای خوشه‌بندی بستگی دارد و برای حفظ عملکرد مدل، ممکن است لازم باشد نمونه‌های فشرده با معماری مدل خاصی بهینه شوند.

۲.۱.۷.۲ کدگذاری و رمزگشایی^۱

روش کدگذاری و رمزگشایی در تقطیر دادگان بر پایه نگاشت داده‌ها به یک فضای فشرده و بازسازی آن‌ها است. هدف، تولید مجموعه فشرده $\tilde{D}$ است که مدل آموزش‌دیده روی آن، عملکردی مشابه آموزش روی مجموعه اصلی D داشته باشد [۶۳].

این روش مشابه خودرمزگذار^۲ است که از دو بخش تشکیل شده است:

• Encoder $\mathcal{E}_\phi : \mathbb{R}^d \rightarrow \mathbb{R}^k$ با $k \ll d$ ، داده‌ها را به فضای فشرده نگاشت می‌کند:

$$z_i = \mathcal{E}_\phi(x_i), \quad (۶۳.۲)$$

که $z_i \in \mathbb{R}^k$ بردار فشرده‌ی نمونه x_i است.

• Decoder $\mathcal{D}_\psi : \mathbb{R}^k \rightarrow \mathbb{R}^d$ سعی می‌کند نمونه اصلی را بازسازی کند:

$$\tilde{x}_i = \mathcal{D}_\psi(z_i) = \mathcal{D}_\psi(\mathcal{E}_\phi(x_i)). \quad (۶۴.۲)$$

فرایند بهینه‌سازی: پارامترهای کدگذار^۳ و رمزگشا^۴ با کمینه کردن خطای بازسازی بهینه می‌شوند:

$$(\phi^*, \psi^*) = \arg \min_{\phi, \psi} \sum_{i=1}^N \|x_i - \mathcal{D}_\psi(\mathcal{E}_\phi(x_i))\|_2^2 + \lambda \Omega(\phi, \psi), \quad (۶۵.۲)$$

که $\Omega(\phi, \psi)$ یک منظم‌سازی برای جلوگیری از بیش‌برازشی و تولید نویز است و λ ضریب کنترل آن است.

^۱Encoder-Decoder Approach

^۲Autoencoder

^۳Encoder

^۴Decoder

مزایا: این روش قابلیت بازسازی داده‌های پیچیده را دارد و نگاشت به فضای فشرده، اطلاعات مهم و الگوهای ساختاری داده‌ها را حفظ می‌کند. همچنین، استفاده از داده‌های فشرده در مدل‌های مختلف یا محیط‌های با حافظه محدود امکان‌پذیر است و می‌توان این روش را با سایر تکنیک‌ها مانند همسان‌سازی گرادیان‌ها^۱ یا نمونه‌گیری ویژگی‌ها^۲ ترکیب کرد تا عملکرد بهبود یابد. محدودیت‌ها: هزینه‌ی محاسباتی آموزش کدگذار و رمزگشا بالا است و بازسازی ناقص ممکن است جزئیات مهم داده‌ها را از دست بدهد. علاوه بر این، کیفیت داده‌های فشرده به طراحی شبکه، معماری کدگذاری و رمزگشایی و اندازه فضای فشرده وابسته است.

۳.۱.۷.۲ تکنیک‌های فاکتوریزه^۳

در این روش، هدف اصلی آن است که ماتریس داده‌های اصلی $X \in \mathbb{R}^{N \times d}$ شامل N نمونه و d ویژگی به دو یا چند ماتریس کم‌بعدتر فاکتور شود، به‌طوری که ساختار اصلی داده حفظ گردد ولی اطلاعات تکراری حذف شود [۴۱، ۷۳]. ایده‌ی اصلی بر پایه‌ی فاکتوریزه‌سازی ماتریسی^۴ و تجزیه‌ی تنسوری است که در یادگیری فشرده و تقطیر داده‌ها برای بازنمایی بهینه به کار می‌رود. مدل پایه: فرآیند فاکتوریزه به‌صورت زیر بیان می‌شود:

$$X \approx UV, \quad X \in \mathbb{R}^{N \times d}, \quad U \in \mathbb{R}^{N \times k}, \quad V \in \mathbb{R}^{k \times d}, \quad k \ll \min(N, d) \quad (۶۶.۲)$$

در اینجا، U ماتریس پایه‌های نمونه‌ای^۵ است که ساختار میان داده‌ها را مدل می‌کند و V ماتریس پایه‌های ویژگی^۶ است که ویژگی‌های کلیدی را بازنمایی می‌کند. ماتریس‌های U و V با بهینه‌سازی تابع خطا بین داده‌های اصلی و بازسازی‌شده تخمین زده می‌شوند:

$$\min_{U, V} \|X - UV\|_F^2 + \lambda(\|U\|_F^2 + \|V\|_F^2), \quad (۶۷.۲)$$

که $\|\cdot\|_F$ نرم فرابنی^۷ و λ ضریب تنظیم منظم‌سازی است. در فرآیند تقطیر داده‌ها، پس از تخمین U و V ، داده‌های تقطیری از ترکیب بردارهای پایه‌ای ساخته می‌شوند:

$$\tilde{X} = U_r V, \quad U_r \subseteq U, \quad |U_r| = M \ll N \quad (۶۸.۲)$$

به عبارت دیگر، تنها زیرمجموعه‌ای از ردیف‌های U (نمونه‌های کلیدی) و ستون‌های V (ویژگی‌های

^۱Gradient Matching

^۲Feature Sampling

^۳Factorized Distillation

^۴Matrix Factorization

^۵Sample Bases

^۶Feature Bases

^۷Frobenius norm

کلیدی) برای تشکیل داده‌های تقطیری انتخاب می‌شود [۴۱].
 فاکتوریزه‌سازی غیرمنفی و تانسوری:
 برای داده‌های غیرمنفی (مانند تصاویر یا هیستوگرام‌ها)، از فاکتوریزه‌سازی غیرمنفی (NMF) استفاده می‌شود:

$$X \approx U^+ V^+, \quad U^+, V^+ \geq 0 \quad (۶۹.۲)$$

که موجب تفسیرپذیری بهتر ویژگی‌ها می‌شود. در داده‌های چندبعدی مانند ویدیو یا داده‌های چندکاناله، از فاکتوریزه‌سازی تانسوری^۱ مانند تجزیه CP^۲ یا تجزیه تاکر^۳ استفاده می‌شود:

$$\mathcal{X} \approx \sum_{r=1}^R a_r \otimes b_r \otimes c_r, \quad (۷۰.۲)$$

که در آن ضرب تانسوری و R رتبه‌ی فاکتور است [۴۷].
 فاکتوریزه‌سازی مبتنی بر شبکه‌های عصبی: در کارهای اخیر مانند [۷۳، ۳۹]، فرآیند فاکتوریزه به‌صورت یادگیری‌پذیر^۴ با شبکه‌های عصبی پارامتریزه می‌شود:

$$U = f_\phi(X), \quad V = g_\psi(X), \quad (۷۱.۲)$$

که در آن f_ϕ و g_ψ شبکه‌هایی هستند که بازنمایی‌های فشرده و قابل یادگیری را از داده‌ها استخراج می‌کنند. در این حالت، بهینه‌سازی به‌صورت هم‌زمان بر پارامترهای ϕ, ψ و داده‌های فشرده انجام می‌شود.

کاربردهای کلیدی:

این روش برای کاهش ابعاد داده‌ها کاربرد دارد و با حذف افزونگی ویژگی‌ها، ساختار داده حفظ می‌شود. علاوه بر این، با کاهش حجم داده‌ها، زمان آموزش در مدل‌های بزرگ کاهش یافته و کارایی یادگیری افزایش می‌یابد. داده‌های فاکتوریزه‌شده همچنین قابلیت استفاده در دامنه‌های جدید را دارند و امکان انتقال دانش فراهم می‌شود.

مزایا:

فاکتورهای پایه موجب حفظ ساختار درونی داده‌ها می‌شوند و حجم داده‌ها را به‌طور چشمگیری کاهش می‌دهند در حالی که محتوای اطلاعاتی حفظ می‌شود. این روش برای داده‌های چندبعدی یا با ساختار سلسله‌مراتبی نیز قابل استفاده است.

محدودیت‌ها:

تخمین فاکتورها به‌ویژه برای داده‌های بزرگ هزینه محاسباتی بالایی دارد و نتایج به مقدار اولیه‌سازی

¹Tensor Decomposition

²CANDECOMP Decomposition

³Tucker Decomposition

⁴Learnable Factorization

U, V حساس هستند. علاوه بر این، تفسیرپذیری داده‌ها در صورت وجود نویز زیاد یا همبستگی بالا محدود می‌شود.

۴.۱.۷.۲ الگوریتم‌های بهینه‌سازی^۱

در رویکرد الگوریتم‌های بهینه‌سازی، به جای انتخاب یا فشرده‌سازی داده‌های موجود، داده‌های تقطیری $\tilde{D}$ مستقیماً به صورت پارامترهای قابل یادگیری در یک مسئله بهینه‌سازی تعریف می‌شوند. هدف اصلی این است که داده‌های فشرده‌شده، مسیر یادگیری مدل را در هنگام آموزش روی داده‌های اصلی به خوبی بازتولید کنند [۱۴، ۳۹، ۶۹، ۷۳]. در این روش، داده‌های تقطیری با حل مسئله‌ی زیر به دست می‌آیند:

$$\tilde{D}^* = \arg \min_{\tilde{D}} \sum_{t=1}^T \mathcal{L}(\theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t, \tilde{D}), \mathcal{D}), \quad (۷۲.۲)$$

در این رابطه، $\mathcal{L}$ تابع هزینه مانند cross-entropy است، θ_t پارامترهای مدل در گام t از آموزش را نشان می‌دهد، و η نرخ یادگیری^۲ است. همچنین، $\tilde{D}$ مجموعه داده‌های فشرده شامل برچسب‌های مصنوعی یا واقعی^۳ می‌باشد.

این معادله بیانگر آن است که داده‌های فشرده باید به گونه‌ای بهینه شوند که جهت گرادیان به دست آمده از آموزش بر روی آن‌ها، بیشترین شباهت را با جهت گرادیان حاصل از داده‌های واقعی داشته باشد. تقطیر بر اساس تطبیق مسیر آموزش: در کار [۱۴]، تابع هدف به صورت تطبیق مسیرهای آموزش^۴ بازنویسی شد:

$$\min_{\tilde{D}} \sum_{t=1}^T \|\theta_t(\tilde{D}) - \theta_t(\mathcal{D})\|_2^2, \quad (۷۳.۲)$$

که در آن هدف این است که پارامترهای مدل آموزش دیده با داده‌های تقطیری، در هر گام آموزشی، بیشترین نزدیکی را به پارامترهای مدل آموزش دیده با داده‌های واقعی داشته باشند. این روش موجب پایداری بیشتر در تقطیر داده‌ها و حفظ بهتر اطلاعات زمانی^۵ در طول آموزش می‌شود. تقطیر با تطبیق گرادیان:

نسخه‌ی پرکاربرد دیگر مبتنی بر تطبیق گرادیان^۶ است [۷۳، ۷۵]، که در آن تابع هدف به شکل

^۱Optimization-based Dataset Distillation

^۲Learning rate

^۳Synthetic or Real Labels

^۴Training Trajectory Matching

^۵Temporal information

^۶Gradient Matching

زیر تعریف می‌شود:

$$\min_{\tilde{D}} \sum_{c=1}^C \left\| \nabla_{\theta} \mathcal{L}(\theta; \tilde{D}_c) - \nabla_{\theta} \mathcal{L}(\theta; D_c) \right\|_2^2, \quad (74.2)$$

که در آن C تعداد کلاس‌هاست. این روش باعث می‌شود داده‌های تقطیری جهت به‌روزرسانی مدل را همانند داده‌های اصلی حفظ کنند، بدون نیاز به بازسازی مسیر کامل آموزش. بهینه‌سازی سطح دو^۱:

بهینه‌سازی داده‌های تقطیری معمولاً به‌صورت مسئله‌ی دو سطحه فرموله می‌شود:

$$\theta^*(\tilde{D}) = \arg \min_{\theta} \mathcal{L}_{\text{train}}(\theta, \tilde{D}), \quad (75.2)$$

$$\tilde{D}^* = \arg \min_{\tilde{D}} \mathcal{L}_{\text{val}}(\theta^*(\tilde{D}), D_{\text{val}}), \quad (76.2)$$

که در آن تابع بیرونی^۲ عملکرد نهایی مدل را روی داده‌های اعتبارسنجی بهینه می‌کند، در حالی که تابع درونی^۳ فرآیند آموزش مدل بر داده‌های تقطیری را مدل می‌کند [۴۸].

مزایا: این روش امکان دستیابی به داده‌های تقطیری بسیار دقیق را فراهم می‌کند که مسیر یادگیری مدل را بازتولید می‌کنند. علاوه بر این، ساختار زمانی داده‌ها حفظ شده و همگرایی مشابه با داده‌های واقعی برقرار می‌ماند. داده‌های تقطیری تولیدشده قابلیت استفاده در مدل‌های مختلف از جمله CNN^۴، ViT^۵ و MLP^۶ را دارند.

محدودیت‌ها: اجرای این روش هزینه‌ی محاسباتی بالایی دارد زیرا نیاز به محاسبه‌ی گرادیان‌های مرتبه دوم است. همچنین، نتایج به نرخ یادگیری و انتخاب ابرپارامترها حساس بوده و مقیاس‌دهی آن برای داده‌های بزرگ دشوار است.

الگوریتم‌های بهینه‌سازی در تقطیر دادگان پایه‌گذار دقیق‌ترین رویکردهای مدرن مانند Gradient Matching و Trajectory Matching بوده‌اند و نشان داده‌اند که با استفاده از چند درصد از داده‌های اصلی، می‌توان عملکردی تا ۹۵٪ – ۹۰٪ از مدل آموزش‌دیده بر داده‌های کامل را بازتولید کرد [۷۳، ۶۹، ۳۹].

¹Bilevel Optimization

²Outer objective

³Inner objective

⁴Convolutional Neural Network

⁵Vision Transformer

⁶Multi-Layer Perceptron

۵.۱.۷.۲ نمونه برداری از ویژگی‌ها^۱

در روش نمونه برداری از ویژگی‌ها، هدف انتخاب زیرمجموعه‌ای از ویژگی‌ها یا نمونه‌ها از داده‌های اصلی است که بیشترین اطلاعات را نسبت به کل مجموعه داده حفظ کنند. به عبارت دیگر، داده‌های تقطیری $\tilde{D}$ باید تا حد ممکن از نظر آماری نماینده‌ی کل مجموعه‌ی اصلی D باشند [۷۵، ۳۹، ۱۸]. فرمول‌بندی آماری:

معیار انتخاب معمولاً بر پایه‌ی اطلاعات متقابل تعریف می‌شود:

$$\tilde{D}^* = \arg \max_{\tilde{D} \subseteq D} \text{MI}(\tilde{D}, D), \quad (۷۷.۲)$$

که در آن $\text{MI}(A, B)$ میزان اطلاعات مشترک بین دو مجموعه‌ی تصادفی A و B است و به صورت زیر تعریف می‌شود:

$$\text{MI}(A, B) = \int \int p(a, b) \log \frac{p(a, b)}{p(a)p(b)} da db, \quad (۷۸.۲)$$

که در آن $p(a, b)$ توزیع مشترک ویژگی‌ها و $p(a), p(b)$ توزیع‌های حاشیه‌ای هستند. به طور شهودی، هرچه مقدار $\text{MI}(\tilde{D}, D)$ بیشتر باشد، داده‌های فشرده شده $\tilde{D}$ اطلاعات بیشتری از داده‌های اصلی حفظ کرده‌اند. در عمل، محاسبه‌ی اطلاعات متقابل به صورت دقیق ممکن نیست. بنابراین معمولاً از تقریب‌های مبتنی بر شباهت ویژگی‌ها یا هسته‌های کرنل^۲ استفاده می‌شود [۴۸]:

$$\text{MI}(\tilde{D}, D) \approx \frac{1}{|\tilde{D}||D|} \sum_{\tilde{x}_i \in \tilde{D}} \sum_{x_j \in D} k(\tilde{x}_i, x_j), \quad (۷۹.۲)$$

که در آن $k(\cdot, \cdot)$ تابع کرنل است و ارتباط هندسی میان داده‌های فشرده و داده‌های اصلی را می‌سنجد. در برخی نسخه‌های پیشرفته‌تر مانند [۱۸]، نمونه برداری مستقیماً در فضای ویژگی‌های شبکه انجام می‌شود:

$$\tilde{D} = \arg \max_{\tilde{D} \subseteq D} \sum_{i \in \tilde{D}} \sum_{j \in D} \text{sim}(f_{\theta}(x_i), f_{\theta}(x_j)), \quad (۸۰.۲)$$

که در آن $f_{\theta}(\cdot)$ نگاشت ویژگی‌ها توسط مدل و $\text{sim}(\cdot, \cdot)$ تابع شباهت (مانند ضرب داخلی^۳ یا کسینوس) است.

برای حل این مسئله، معمولاً از روش‌های نمونه برداری زیر استفاده می‌شود:

^۱Feature Sampling

^۲Kernel-based similarity

^۳Inner Product

نمونه‌گیری تدریجی^۱ که ویژگی‌هایی را به‌طور تدریجی انتخاب می‌کند که بیشترین افزایش در اطلاعات متقابل ایجاد می‌کنند؛ فرایندهای نقطه‌ای دترمینانتی^۲ که زیرمجموعه‌های متنوعی را برای جلوگیری از هم‌پوشانی داده‌ها انتخاب می‌کند؛ و کرنل هر دینگ^۳ که نمونه‌برداری تکراری با به‌روزرسانی تدریجی توزیع داده‌ها در فضای ویژگی انجام می‌دهد.

مزایا: این روش‌ها از سادگی و سرعت بالایی در مقایسه با روش‌های گرادیان‌محور برخوردارند و برای داده‌های با ابعاد بالا یا داده‌های بدون برچسب مناسب هستند. محدودیت‌ها: با این حال، محاسبه‌ی تقریبی اطلاعات متقابل می‌تواند منجر به از دست رفتن اطلاعات دقیق شود، داده‌های کلیدی^۴ ممکن است نادیده گرفته شوند، و عملکرد روش‌ها به انتخاب تابع کرنل یا معیار شباهت حساس است.

روش نمونه‌برداری از ویژگی‌ها به‌عنوان رویکردی سبک و مؤثر برای تقطیر داده‌ها، در شرایطی که محاسبه‌ی گرادیان پرهزینه است، کاربرد گسترده‌ای دارد. مطالعات اخیر [۱۸، ۳۹، ۷۳] نشان داده‌اند که این روش با ترکیب با تطبیق توزیع^۵ می‌تواند تا ۹۰٪ دقت داده‌های اصلی را در یادگیری شبکه‌های CNN و Transformer حفظ کند.

۶.۱.۷.۲ تقطیر مبتنی بر گرادیان^۶

در روش تقطیر مبتنی بر گرادیان، ایده‌ی اصلی این است که داده‌های فشرده‌شده $\tilde{D}$ باید منجر به گرادیان‌هایی مشابه با گرادیان حاصل از داده‌های اصلی D شوند. به عبارت دیگر، هدف آن است که مسیر به‌روزرسانی پارامترهای مدل در هنگام آموزش روی $\tilde{D}$ ، تا حد ممکن به مسیر واقعی یادگیری روی D نزدیک باشد [۱۴، ۳۹، ۶۹، ۷۵].

فرایند بهینه‌سازی داده‌های تقطیری به‌صورت زیر تعریف می‌شود:

$$\tilde{D}^* = \arg \min_{\tilde{D}} \sum_{t=1}^T \left\| \nabla_{\theta} \mathcal{L}(\theta_t, \tilde{D}) - \nabla_{\theta} \mathcal{L}(\theta_t, D) \right\|_2^2, \quad (۸۱.۲)$$

که در آن $\mathcal{L}(\theta_t, D)$ تابع زیان مدل در گام t از آموزش و بر روی داده‌های اصلی است، $\tilde{D}$ مجموعه داده‌های فشرده یا مصنوعی^۷ را نشان می‌دهد، ∇_{θ} گرادیان نسبت به پارامترهای مدل است، و T تعداد گام‌های آموزشی است که در آن‌ها گرادیان‌های حاصل از داده‌های اصلی و داده‌های فشرده با یکدیگر مقایسه می‌شوند.

هدف، هم‌ترازسازی جهت و بزرگی گرادیان‌ها میان دو مجموعه داده است تا شبکه، مسیر یادگیری مشابهی طی کند.

^۱Greedy Sampling

^۲Determinantal Point Processes:DPP

^۳Herding Kernel

^۴Critical samples

^۵Distribution Matching

^۶Gradient-based Data Distillation

^۷Synthetic Dataset

تفسیر گرادیانی:
اگر از روش به روزرسانی SGD^۱ استفاده شود:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t, \mathcal{D}), \quad (۸۲.۲)$$

در روش تقطیر مبتنی بر گرادیان، داده‌های فشرده طوری بهینه می‌شوند که:

$$\Delta \theta_t(\tilde{\mathcal{D}}) \approx \Delta \theta_t(\mathcal{D}), \quad (۸۳.۲)$$

یعنی تغییرات پارامترهای مدل در اثر یادگیری روی داده‌های تقطیری، تقریباً همان تغییراتی باشند که یادگیری روی داده‌های واقعی ایجاد می‌کند. این موضوع سبب می‌شود $\tilde{\mathcal{D}}$ نوعی نماینده‌ی دینامیکی از کل فرآیند یادگیری شود.

پیاده‌سازی و بهبودهای جدید: Zhao و Bilin (۲۰۲۱) نخستین بار مفهوم Gradient Matching را معرفی کردند و نشان دادند که می‌توان داده‌های بسیار کوچک مثلاً ۱۰ تصویر برای کل مجموعه CIFAR تولید کرد که دقتی نزدیک به مجموعه اصلی دارند. بهبودهای بعدی این چارچوب شامل روش‌های متعددی بوده‌اند؛ از جمله Trajectory Matching [۱۴] که به جای تطبیق گرادیان در یک گام، مسیر کامل آموزش مدل را هم‌تراز می‌کند، Distribution Matching [۷۳] که بر هم‌ترازی توزیع ویژگی‌ها در فضای گرادیان تمرکز دارد، و Feature Alignment [۶۸] که با استفاده از نمایش‌های عمیق در فضای ویژگی، تطبیق گرادیان‌ها را در سطوح بالاتری از شبکه انجام می‌دهد. گرادیان‌های سطح دوم:

در نسخه‌های پیشرفته‌تر، برای محاسبه‌ی دقیق‌تر هم‌ترازی گرادیان‌ها از گرادیان‌های مرتبه دوم استفاده می‌شود:

$$\left\| \nabla_{\tilde{x}} \left\| \nabla_{\theta} \mathcal{L}(\theta_t, \tilde{x}) - \nabla_{\theta} \mathcal{L}(\theta_t, x) \right\|_2 \right\|_2^2, \quad (۸۴.۲)$$

که سبب افزایش دقت، اما در عوض افزایش هزینه‌ی محاسباتی می‌شود. مزایا:

این روش‌ها قادر به حفظ دقیق مسیر یادگیری شبکه بوده و امکان بازسازی دینامیک به روزرسانی پارامترها را فراهم می‌کنند؛ از این رو، حتی در داده‌های پیچیده‌ای مانند ImageNet یا CIFAR نیز عملکرد بالایی از خود نشان می‌دهند. محدودیت‌ها:

با این وجود، نیاز به ذخیره و محاسبه‌ی گرادیان‌ها در چندین گام آموزشی، پیچیدگی محاسباتی بالایی را به‌ویژه برای مدل‌های بزرگ تحمیل می‌کند و همچنین نتایج به‌شدت به انتخاب نرخ یادگیری η و نقطه‌ی شروع^۲ مدل حساس هستند.

روش تقطیر مبتنی بر گرادیان از دقیق‌ترین و مؤثرترین روش‌های تقطیر دادگان است، زیرا ساختار

^۱Stochastic Gradient Descent

^۲Initialization

آموزش مدل را در فضای گرادیان حفظ می‌کند. مطالعات اخیر [۷۳، ۳۹، ۱۴] نشان داده‌اند که ترکیب این روش با هم‌ترازی توزیع یا حافظه‌های آدرس‌پذیر^۱ می‌تواند بازدهی یادگیری را تا ۹۵٪ دقت مجموعه اصلی حفظ کند، در حالی که حجم داده‌ها تا یک صدم کاهش یافته است.

۷.۱.۷.۲ ترکیب ویژگی‌ها^۲

در این روش، هدف آن است که داده‌های مشابه در فضای ویژگی با یکدیگر ادغام شوند تا نمایش فشرده‌تری از کل مجموعه داده حاصل گردد. به صورت کلی، برای هر نمونه‌ی فشرده‌شده $\tilde{x}_i$ ، مجموعه‌ای از نمونه‌های مشابه $\mathcal{S}_i \subset \mathcal{D}$ در فضای ویژگی (مثلاً بر اساس معیار شباهت کسینوسی یا فاصله‌ی اقلیدسی) انتخاب می‌شود و ویژگی‌های آن‌ها با وزن‌دهی مناسب تجمیع می‌گردد:

$$\tilde{x}_i = \frac{\sum_{x_j \in \mathcal{S}_i} w_{ij} x_j}{\sum_{x_j \in \mathcal{S}_i} w_{ij}}, \quad w_{ij} = \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right), \quad (۸۵.۲)$$

که در آن w_{ij} وزن شباهت بین نمونه‌های x_i و x_j است و σ پارامتر تنظیم پهنای باند شباهت می‌باشد. در حالت ساده‌تر، اگر همه‌ی وزن‌ها برابر باشند، فرمول به میانگین ساده تبدیل می‌شود:

$$\tilde{x}_i = \frac{1}{|\mathcal{S}_i|} \sum_{x_j \in \mathcal{S}_i} x_j. \quad (۸۶.۲)$$

این فرآیند باعث می‌شود داده‌های تقطیرشده $\tilde{D} = \{\tilde{x}_i\}_{i=1}^M$ بازنمایی میانگینی از نواحی متراکم داده‌ها در فضای ویژگی باشند، و بنابراین تنوع غیرضروری حذف شود در حالی که ساختار آماری اصلی حفظ گردد [۷۶، ۷۴، ۶۳].

مزایا:

این روش با میانگین‌گیری در فضای ویژگی قادر به کاهش نویز و حذف داده‌های پرت است، ابعاد داده‌ها را کاهش می‌دهد و پایداری آموزش مدل‌های یادگیری عمیق را افزایش می‌دهد. همچنین، این روش با سایر تکنیک‌ها مانند خوشه‌بندی و تقطیر تدریجی^۳ سازگار است.

محدودیت‌ها:

با این حال، ممکن است نمونه‌های نادر یا اقلیت در داده‌ها از دست بروند، انتخاب اندازه‌ی بهینه‌ی خوشه‌ها و پارامتر σ دشوار است، و عملکرد روش به معیار شباهت انتخابی حساس است.

^۱Addressable Memories

^۲Feature Aggregation

^۳Hierarchical distillation

۸.۱.۷.۲ روش‌های ترکیبی^۱

در این رویکرد، چندین روش تقطیر (مانند گرادیان‌محور، بازسازی و فاکتوریزه) به صورت ترکیبی به کار می‌روند تا نقاط قوت هر کدام حفظ و ضعف‌ها پوشش داده شود. تابع تقطیر کلی به شکل زیر تعریف می‌شود:

$$\tilde{D}^* = \arg \min_{\tilde{D}} \left[\alpha \mathcal{L}_{\text{grad}}(\tilde{D}) + \beta \mathcal{L}_{\text{dist}}(\tilde{D}) + \gamma \mathcal{L}_{\text{recon}}(\tilde{D}) \right], \quad (۸۷.۲)$$

که در آن ضرایب α, β, γ میزان اهمیت هر مؤلفه (هم‌ترازی گرادیان، هم‌ترازی توزیع، و بازسازی نمونه) را تعیین می‌کنند [۷۳، ۶۸، ۱۴].

به عنوان مثال، روش CAFE [۶۸] از ترکیب هم‌ترازی ویژگی^۲ و گرادیان برای فشرده‌سازی داده‌ها استفاده می‌کند. همچنین Trajectory Matching [۱۴] مسیر یادگیری مدل را در طول آموزش تطبیق می‌دهد تا داده‌های تقطیری اثر مشابهی بر گرادیان‌ها داشته باشند. مزایا:

این روش‌ها قادر به ترکیب نقاط قوت چند روش مختلف، مانند دقت گرادیانی و بازسازی بهتر، هستند و در نتیجه موجب بهبود پایداری و تعمیم مدل می‌شوند. محدودیت‌ها:

با این حال، نیاز به تنظیم هم‌زمان پارامترهای چند تابع زیان مختلف وجود دارد و هزینه محاسباتی نیز افزایش می‌یابد.

۹.۱.۷.۲ تقطیر مبتنی بر یادگیری تقویتی^۳

در این رویکرد، انتخاب یا تولید داده‌های تقطیری به صورت پویا با استفاده از یک عامل یادگیری تقویتی^۴ انجام می‌شود که هدف آن پیشنهادسازی عملکرد مدل نهایی است. عامل سیاست $\pi_{\theta}(a|s)$ تصمیم می‌گیرد که در حالت s_t (نمایانگر وضعیت آموزش یا ویژگی داده‌ها)، کدام نمونه a_t را به عنوان داده‌ی تقطیری انتخاب کند:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=1}^T R_t(\tilde{D}_t) \right], \quad (۸۸.۲)$$

که R_t تابع پاداش مبتنی بر بهبود دقت مدل یا کاهش زیان اعتبارسنجی است [۳۷، ۱۸]. در برخی کارها (مانند RL-Distill) پاداش به صورت زیر تعریف می‌شود:

^۱Hybrid Approaches

^۲Feature Alignment

^۳Reinforcement Learning-based Dataset Distillation

^۴RL agent

$$R_t = \Delta \text{Acc}_t - \lambda \|\tilde{\mathcal{D}}_t\|, \quad (۸۹.۲)$$

که در آن ΔAcc_t تغییر دقت مدل و λ عامل تنظیم برای جلوگیری از افزایش بیش از حد حجم داده است. مزایا:

این روش‌ها امکان انتخاب هوشمندانه داده‌ها را بر اساس بازخورد یادگیری فراهم می‌کنند و با داده‌های پویا، ترتیبی و وابسته به زمان سازگار هستند. محدودیت‌ها: با این حال، آموزش عامل یادگیری تقویتی ممکن است زمان‌بر باشد و طراحی دقیق تابع پاداش و سیاست بهینه برای عملکرد مطلوب ضروری است.

۱۰.۱.۷.۲ شبیه‌سازی نمونه‌ها^۱

در این دسته از روش‌ها، هدف تولید داده‌های مصنوعی $\tilde{x}$ است که از نظر آماری، ساختاری و معنایی با داده‌های واقعی $x \sim p_{\text{data}}(x)$ سازگار باشند. در این روش‌ها، یک مدل مولد پارامتری $p_\theta(x)$ (مانند GAN^۲، VAE^۳ یا Diffusion Model) آموزش می‌بیند تا توزیع تولیدی خود را به توزیع داده‌های واقعی نزدیک کند. به‌طور کلی، فرمول بهینه‌سازی به‌صورت زیر تعریف می‌شود:

$$\min_{\theta} D(p_\theta(x) \| p_{\text{data}}(x)), \quad D \in \{\text{KL}^۴, \text{JS}^۵, \text{Wasserstein}^۶\}, \quad (۹۰.۲)$$

که در آن $D(\cdot, \cdot)$ معیاری برای اندازه‌گیری واگرایی یا فاصله بین دو توزیع است و $p_\theta(x)$ توزیع داده‌های مصنوعی تولید شده توسط مولد G_θ را نشان می‌دهد. انتخاب معیار D تعیین‌کننده حساسیت به نواحی کم‌تراکم یا پرت داده‌ها و همچنین همگرایی الگوریتم است. در حالت کلاسیک GAN [۲۴]، آموزش به صورت یک بازی مین-مکس بین مولد G_θ و تمیزدهنده D_ϕ انجام می‌شود:

$$\min_{\theta_G} \max_{\theta_D} \left[\mathbb{E}_{x \sim p_{\text{data}}} [\log D_\phi(x)] + \mathbb{E}_{z \sim p_z} [\log (1 - D_\phi(G_\theta(z)))] \right], \quad (۹۱.۲)$$

^۱Synthetic Sample Generation

^۲Generative Adversarial Network

^۳Variational Autoencoder

^۴Kullback–Leibler Divergence

^۵Jensen-Shannon Divergence

^۶Wasserstein Distance

که در آن $z \sim \mathcal{N}(0, I)$ بردار نویز ورودی به مولد است و هدف G_θ تولید نمونه‌هایی است که D_ϕ نتواند آن‌ها را از داده‌های واقعی تمییز دهد.

در نسخه‌های پیشرفته‌تر مانند GTN^۱ [۶۲] و روش‌های Dataset Distillation by Matching Training Trajectories [۱۴]، هدف مولد تنها تولید داده‌های مصنوعی نیست؛ بلکه داده‌ها به گونه‌ای بهینه می‌شوند که بیشترین تأثیر را بر ارامترهای مدل دانش‌آموز^۲ در طول فرآیند آموزش داشته باشند:

$$\min_{\theta_G, \theta_S} \mathbb{E}_{z \sim p_z} \left[\mathcal{L}_S(\theta_S - \eta \nabla_{\theta_S} \mathcal{L}_S(\theta_S; G_{\theta_G}(z))) \right], \quad (۹۲.۲)$$

که در آن $\mathcal{L}_S$ تابع زیان مدل دانش‌آموز و η نرخ یادگیری است. این فرمول بیانگر آن است که داده‌های مصنوعی تولید شده، مسیر گرایان مدل دانش‌آموز را به سمت یادگیری مؤثر هدایت می‌کنند. در این رویکرد، به جای فشردسازی مستقیم داده‌های واقعی، مجموعه داده‌های مصنوعی $\tilde{D} = \{G_\theta(z_i)\}_{i=1}^M$ تولید می‌شود که هدف آن شبیه‌سازی اطلاعات آماری و مسیرهای یادگیری داده‌های اصلی است. این تکنیک امکان کاهش حجم داده‌ها، افزایش سرعت آموزش و حفظ عملکرد مدل را فراهم می‌کند.
مزایا:

استفاده از مدل‌های مولد پیشرفته امکان تولید داده‌های بی‌نهایت متنوع و کنترل‌پذیر را فراهم می‌کند، وابستگی به داده‌های واقعی در حوزه‌هایی با داده‌های کم نمونه را کاهش می‌دهد و قابلیت سازگاری با ساختارهای پیچیده مانند ویدیو، گفتار و داده‌های چندوجهی را دارد.
محدودیت‌ها:

با این حال، کیفیت و پایداری داده‌های مصنوعی به دقت مدل مولد، به‌ویژه در GAN، وابسته است. همچنین، در صورت وجود انحراف آماری بین توزیع تولیدی و واقعی، مدل آموزش‌دیده ممکن است دچار Distribution Shift شود و هزینه محاسباتی در مدل‌های مولد بزرگ مانند Diffusion Models بالا است.

۲.۷.۲ مقایسه‌ی روش‌های مختلف تقطیر دادگان

در این بخش، روش‌های مختلف تقطیر دادگان از نظر معیارهای کلیدی مانند نوع معیار، تمرکز اصلی، پایداری نتایج، هزینه محاسباتی و مناسب بودن برای انواع داده‌ها مورد مقایسه قرار می‌گیرند. جدول ۲.۲ خلاصه‌ای از این مقایسه را ارائه می‌دهد.

^۱Generative Teaching Networks

^۲Student Model

جدول ۲.۲: مقایسه‌ی روش‌های مختلف تقطیر دادگان

روش تقطیر	نوع معیار	تمرکز اصلی	پایداری نتایج	هزینه محاسباتی	نوع داده
یادگیری فشرده	زیان بازسازی	کاهش حجم داده با حفظ ویژگی‌های مشترک	متوسط تا بالا	پایین	داده‌های تکراری یا دارای همپوشانی زیاد
کدگذاری و رمزگشایی	بازسازی نهفته	یادگیری نمایش‌های فشرده از داده‌های پیچیده	بالا	زیاد (آموزش دو شبکه)	داده‌های تصویری و متنی
تکنیک‌های فاکتوریزه	تجزیه ماتریسی	کاهش بعد با حفظ ساختار هندسی داده‌ها	بالا	متوسط تا زیاد	داده‌های عددی یا برداری
الگوریتم‌های بهینه‌سازی	بهینه‌سازی تابع زیان	هم‌ترازسازی مدل آموزش دیده با داده‌های تقطیری	بسیار بالا	بسیار زیاد	داده‌های کوچک و حساس
نمونه برداری از ویژگی‌ها	اطلاعات متقابل	انتخاب زیرمجموعه بایسته‌ترین اطلاعات آماری	متوسط	کم	داده‌های بزرگ با افزونگی زیاد
تقطیر مبتنی بر گرادیان	هم‌ترازی گرادیان‌ها	حفظ مسیر یادگیری مشابه داده‌های اصلی	بسیار بالا	بسیار زیاد	مدل‌های CNN و Transformer
ترکیب ویژگی‌ها	میانگین‌گیری در فضای ویژگی	تجميع داده‌های مشابه برای پایداری آموزش	بالا	متوسط	داده‌های نویزی یا متنوع

ادامه در صفحه بعد

ادامه جدول ۲.۲ از صفحه قبل

روش تقطیر	نوع معیار	تمرکز اصلی	پایداری نتایج	هزینه محاسباتی	نوع داده
روش‌های ترکیبی	ترکیب چند معیار	توازن بین دقت و سرعت تقطیر	بسیار بالا	زیاد	داده‌های متنوع و بزرگ
یادگیری تقویتی	سیگنال پاداش	انتخاب پویا و یادگیرنده داده‌ها	بسیار بالا	زیاد	داده‌های ترتیبی یا زمانی
شبیه‌سازی نمونه‌ها	زیان تولیدی	تولید داده‌های مصنوعی با حفظ توزیع اصلی	متوسط تا بالا	زیاد	داده‌های تصویر، ویدیو و گفتار

۸.۲ هرس داده‌ها با امتیازدهی دوعمقی زمانی^۱

در روش‌های کلاسیک هرس داده، اهمیت هر نمونه معمولاً بر اساس یک تصویر لحظه‌ای از فرآیند آموزش^۲ محاسبه می‌شود [۴۴، ۵۱]. این رویکرد اگرچه ساده است، اما قادر به درک پویایی‌های زمانی آموزش نبوده و در نرخ‌های بالای هرس^۳ یا تغییر معماری شبکه، تعمیم‌پذیری ضعیفی از خود نشان می‌دهد.

روش TDDS که توسط ژانگ و همکاران [۷۲] ارائه شده است، با هدف رفع این محدودیت، یک معیار امتیازدهی مبتنی بر پویایی زمانی آموزش معرفی این روش به صورت هم‌زمان سهم واقعی هر نمونه در فرآیند بهینه‌سازی را در هر دوره آموزش تخمین می‌زند و نمونه‌هایی با قابلیت تعمیم‌پذیری بالا را بر اساس نوسانات رفتاری آن‌ها در طول زمان شناسایی می‌کند. ایده‌ی کلیدی TDDS استفاده از یک ساختار دوعمقی^۴ است که شامل عمق درونی و عمق بیرونی می‌باشد.

^۱Temporal Dual-Depth Scoring (TDDS)

^۲Snapshot-based

^۳Pruning ratio

^۴Dual-Depth

۱.۸.۲ فرمول بندی مسئله

فرض می شود مجموعه داده آموزشی به صورت

$$\mathcal{U} = \{(x_n, y_n)\}_{n=1}^N$$

و شبکه عصبی با پارامترهای θ به صورت $f_{\theta}(\cdot)$ تعریف شده است. تابع هزینه تجربی برابر است با:

$$\mathcal{L}(\mathcal{U}; \theta) = \frac{1}{N} \sum_{n=1}^N \ell(f_{\theta}(x_n), y_n). \quad (93.2)$$

در دروه آموزش t ، به روزرسانی پارامترها با گرادیان نزولی انجام می شود:

$$\theta_{t+1} = \theta_t - \eta \sum_{n=1}^N \mathbf{g}_t(x_n), \quad (94.2)$$

که در آن:

$$\mathbf{g}_t(x_n) = \nabla_{\theta_t} \ell(f_{\theta_t}(x_n), y_n). \quad (95.2)$$

هدف هرس داده، انتخاب زیرمجموعه $\mathcal{S} \subset \mathcal{U}$ است به گونه ای که رفتار آموزشی آن تقریب مناسبی از مجموعه کامل باشد.

۲.۸.۲ عمق بیرونی: بیشینه سازی واریانس زمانی

در عمق بیرونی TDDS، تعمیم پذیری نمونه ها با تحلیل نوسانات سهم آن ها در طول آموزش ارزیابی می شود. گرادیان کل داده ها در دوره آموزش t به صورت زیر تعریف می شود:

$$\mathbf{G}_{t, \mathcal{U}} = \frac{1}{|\mathcal{U}|} \sum_{n=1}^{|\mathcal{U}|} \mathbf{g}_t(x_n). \quad (96.2)$$

هدف انتخاب زیرمجموعه ای است که گرادیان آن در طول زمان بیشترین تغییرات معنادار را داشته باشد:

$$\mathcal{S}^* = \arg \max_{\mathcal{S} \subset \mathcal{U}} R(\mathcal{S}), \quad (97.2)$$

که در آن معیار واریانس زمانی به صورت زیر تعریف می شود:

$$R(\mathcal{S}) = \sum_{t=1}^T \|G_{t,\mathcal{S}} - \bar{G}_{\mathcal{S}}\|_2^2, \quad (98.2)$$

و:

$$\bar{G}_{\mathcal{S}} = \frac{1}{T} \sum_{t=1}^T G_{t,\mathcal{S}}. \quad (99.2)$$

به طور شهودی، نمونه‌هایی که رفتار گرادسانی متغیرتری دارند، اطلاعات غنی‌تری برای مدل فراهم کرده و تعمیم‌پذیری بالاتری ایجاد می‌کنند.

۳.۸.۲ عمق درونی: تخمین سهم واقعی نمونه‌ها

در TDDS، سهم واقعی هر نمونه با فرافکنی گرادسان آن بر جهت گرادسان تجمع‌یافته کل داده‌ها محاسبه می‌شود:

$$c_t(x_n) = \left| \mathbf{g}_t(x_n) \cdot \sum_{j=1}^{|\mathcal{U}|} \mathbf{g}_t(x_j) \right|. \quad (100.2)$$

به منظور کاهش هزینه محاسباتی، این مقدار با استفاده از تغییرات تابع هزینه بین دو دوره آموزش متوالی تقریب زده می‌شود:

$$c_t(x_n) \approx \frac{1}{\eta} \left| \ell(f_{\theta_{t+1}}(x_n), y_n) - \ell(f_{\theta_t}(x_n), y_n) \right|. \quad (101.2)$$

برای لحاظ کردن اطلاعات کلاس‌های غیرهدف، TDDS از واگرایی کولبک-لایبلا^۱ استفاده می‌کند:

$$\Delta \ell_n^t = D_{KL}(f_{\theta_{t+1}}(x_n) \parallel f_{\theta_t}(x_n)), \quad (102.2)$$

که به صورت صریح برابر است با:

$$\Delta \ell_n^t = f_{\theta_{t+1}}(x_n)^\top \log \frac{f_{\theta_{t+1}}(x_n)}{f_{\theta_t}(x_n)}. \quad (103.2)$$

¹Kullback-Leibler Divergence

۴.۸.۲ تجميع زمانی با پنجره لغزان

برای هر نمونه x_n ، واریانس تغییرات زیان در یک پنجره زمانی K^1 به صورت زیر محاسبه می شود:

$$R_t(x_n) = \sum_{i=t-K+1}^t \left(|\Delta \ell_n^i| - \overline{|\Delta \ell_n|} \right)^2, \quad (104.2)$$

که در آن:

$$\overline{|\Delta \ell_n|} = \frac{1}{K} \sum_{i=t-K+1}^t |\Delta \ell_n^i|. \quad (105.2)$$

اهمیت نهایی هر نمونه با میانگین گیری نمایی^۲ به روزرسانی می شود:

$$R(x_n) \leftarrow \beta R_t(x_n) + (1 - \beta) R(x_n). \quad (106.2)$$

۵.۸.۲ آموزش آگاه از اهمیت نمونه ها

پس از انتخاب زیرمجموعه S ، آموزش شبکه با وزن دهی به نمونه ها انجام می شود:

$$\theta_{t+1} = \theta_t - \eta \sum_{x_m \in S} R(x_m) \mathbf{g}_t(x_m). \quad (107.2)$$

این کار موجب انتقال ساختار اهمیت نمونه ها از مجموعه کامل به زیرمجموعه می شود. مزایا: این روش امکان درک دقیق پویایی های زمانی آموزش را فراهم می کند، عملکرد پایدار در نرخ های بالای هرس داده دارد و تعمیم پذیری مناسبی در معماری های مختلف شبکه ارائه می دهد. محدودیت ها: با این حال، نیاز به ثبت خروجی مدل در طول آموزش وجود دارد و عملکرد روش به انتخاب اندازه پنجره زمانی K و ضریب β حساس است.

۹.۲ هرس داده ها بر اساس عدم قطعیت پویا^۳

در روش های مبتنی بر عدم قطعیت^۴، فرض بر این است که نمونه هایی که مدل نسبت به آن ها اطمینان پایینی دارد، یا هنوز به درستی آموخته نشده اند و یا دارای نویز و برچسب نادرست هستند. با این حال،

¹Sliding window

²Exponential Moving Average:EMA

³Dynamic Uncertainty-based Dataset Pruning

⁴Uncertainty

بیشتر روش‌های پیشین عدم قطعیت را تنها در یک مرحله‌ی خاص از آموزش اندازه‌گیری می‌کنند که این امر باعث نادیده گرفتن پویایی زمانی یادگیری می‌شود. روش هرس داده مبتنی بر عدم قطعیت پویا که توسط هی و همکاران [۳۲] ارائه شده است، با تحلیل تغییرات عدم قطعیت پیش‌بینی مدل در طول آموزش، معیار دقیق‌تری برای شناسایی نمونه‌های کم‌اهمیت یا گمراه‌کننده فراهم می‌کند. این روش نشان می‌دهد که مسیر تغییر عدم قطعیت یک نمونه، اطلاعات غنی‌تری نسبت به مقدار آن در یک دوره آموزش خاص ارائه می‌دهد.

۱.۹.۲ تعریف عدم قطعیت پیش‌بینی

فرض می‌شود خروجی مدل برای نمونه‌ی x_i در دوره آموزش t یک توزیع احتمالی روی C کلاس به صورت

$$\mathbf{p}_t(x_i) = (p_t^{(1)}(x_i), \dots, p_t^{(C)}(x_i))$$

باشد. عدم قطعیت پیش‌بینی^۱ با استفاده از آنروپی شانون تعریف می‌شود:

$$U_t(x_i) = - \sum_{c=1}^C p_t^{(c)}(x_i) \log p_t^{(c)}(x_i). \quad (10.8.2)$$

مقادیر بزرگ‌تر $U_t(x_i)$ بیانگر اطمینان کمتر مدل و ابهام بیشتر در پیش‌بینی نمونه هستند [۳۲].

۲.۹.۲ عدم قطعیت پویا و تحلیل زمانی

برای بررسی رفتار نمونه‌ها در طول فرآیند آموزش، تغییرات عدم قطعیت در دوره آموزش‌های متوالی تحلیل می‌شود. نرخ تغییر عدم قطعیت برای نمونه‌ی x_i به صورت زیر تعریف می‌گردد:

$$\Delta U_t(x_i) = U_t(x_i) - U_{t-1}(x_i). \quad (10.9.2)$$

نمونه‌هایی که عدم قطعیت آن‌ها به صورت یکنواخت کاهش می‌یابد، معمولاً داده‌های آموزنده و قابل یادگیری هستند. در مقابل، نمونه‌هایی که دارای عدم قطعیت بالا یا نوسانات شدید در طول زمان هستند، اغلب داده‌های نویزی، پرت یا دارای برجستگی نادرست محسوب می‌شوند [۳۲].

¹Predictive Uncertainty

۳.۹.۲ امتیازدهی پویا به نمونه‌ها

برای تجميع اطلاعات زمانی، یک امتیاز عدم قطعیت پویا برای هر نمونه تعریف می‌شود:

$$S(x_i) = \frac{1}{T} \sum_{t=1}^T w_t U_t(x_i), \quad (110.2)$$

که در آن T تعداد کل دوره‌های آموزش و w_t وزن زمانی مربوط به دوره آموزش t است. به‌منظور تأکید بیشتر بر رفتار نهایی مدل، وزن‌ها به‌صورت افزایشی تعریف می‌شوند:

$$w_t = \frac{t}{T}. \quad (111.2)$$

این وزن‌دهی باعث می‌شود عدم قطعیت نمونه‌ها در مراحل پایانی آموزش نقش پررنگ‌تری در تصمیم‌گیری ایفا کند [۳۲].

۴.۹.۲ معیار هرس داده‌ها

پس از محاسبه امتیاز $S(x_i)$ برای تمام نمونه‌ها، داده‌ها بر اساس این مقدار مرتب می‌شوند. زیرمجموعه‌ی نهایی داده‌ها به‌صورت زیر انتخاب می‌شود:

$$\mathcal{S} = \{x_i \mid S(x_i) \leq \tau_u\}, \quad (112.2)$$

که در آن τ_u یک آستانه‌ی از پیش تعیین‌شده برای عدم قطعیت است. به این ترتیب، نمونه‌هایی با عدم قطعیت پویا بالا حذف شده و داده‌هایی که مدل آن‌ها را به‌صورت پایدار آموخته است، حفظ می‌شوند. مزایا: این روش‌ها از پویایی‌های زمانی یادگیری بهره می‌برند و به‌جای استفاده از معیارهای ایستا، قادر به شناسایی مؤثر داده‌های نویزی و دارای برچسب نادرست هستند. علاوه بر این، مقیاس‌پذیری مناسبی برای مجموعه‌داده‌های بزرگ ارائه می‌دهند. محدودیت‌ها: با این حال، نیاز به ذخیره توزیع خروجی مدل در طول آموزش وجود دارد و عملکرد روش به انتخاب آستانه τ_u و نحوه وزن‌دهی زمانی حساس است.

۱۰.۲ جمع‌بندی

در این فصل، مروری جامع بر رویکردهای مختلف هرس داده‌ها و تقطیر دادگان ارائه شد. بررسی‌ها نشان داد که هر یک از این روش‌ها با تمرکز بر جنبه‌های خاصی از داده‌ها یا مدل، می‌توانند نقش

مؤثری در بهبود کارایی، کاهش هزینه‌های محاسباتی و افزایش دقت مدل‌های یادگیری ماشین ایفا کنند. در فصل بعد، روش پیشنهادی این پژوهش به صورت تفصیلی معرفی خواهد شد.

فصل ۳

روش پیشنهادی

۱.۳ توضیح معماری الگوریتم

۱.۱.۳ صورت بندی مسئله

فرض شود یک مسئله طبقه بندی نظارت شده با C کلاس در اختیار است و مجموعه داده آموزشی به صورت زیر تعریف می شود:

$$\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N, \quad y_n \in \{1, 2, \dots, C\}, \quad (1.3)$$

که در آن $x_n \in \mathbb{R}^d$ نمایش دهنده نمونه ورودی و y_n برچسب^۲ صحیح متناظر با آن است. همچنین N تعداد کل نمونه های آموزشی می باشد. هدف آموزش، یادگیری یک تابع پیش بینی

$$f_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^C \quad (2.3)$$

با پارامترهای θ است، به گونه ای که با کمینه سازی تابع خطا $\ell(\cdot, \cdot)$ ، عملکرد مناسبی بر روی داده های مشاهده نشده حاصل شود.

در مسئله هرس داده^۳، هدف انتخاب زیرمجموعه ای از نمونه های آموزشی به صورت

$$\mathcal{S} \subset \mathcal{D}, \quad |\mathcal{S}| = (1 - p)N, \quad (3.3)$$

است، که در آن $p \in (0, 1)$ نسبت هرس داده ها^۴ را مشخص می کند. هدف اصلی آن است که آموزش مدل تنها با استفاده از زیرمجموعه $\mathcal{S}$ ، منجر به یادگیری پارامترهایی $\theta_{\mathcal{S}}$ شود که از نظر عملکرد نهایی،

²Label

³Data pruning

⁴Pruning ratio

قابل مقایسه با پارامترهای θ_D حاصل از آموزش بر روی مجموعه داده کامل باشند. به صورت دقیق تر، انتظار می رود امید ریاضی^۱ تابع خطا بر روی توزیع داده ها در هر دو حالت تقریباً برابر باشد:

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{\theta_S}(x), y)] \approx \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{\theta_D}(x), y)]. \quad (۴.۳)$$

نکته کلیدی در این مسئله آن است که تمامی نمونه های موجود در D از اهمیت یکسانی در فرآیند یادگیری برخوردار نیستند. برخی نمونه ها دارای اطلاعات تکراری، نویز برچسب، یا تأثیر ناچیز بر به روزرسانی پارامترهای مدل هستند، در حالی که برخی دیگر نقش تعیین کننده ای در شکل گیری مرزهای تصمیم ایفا می کنند.

در این پژوهش، مسئله هرس داده به عنوان یک مسئله امتیازدهی به نمونه ها صورت بندی می شود، به طوری که به هر نمونه x_n یک امتیاز اهمیت S_n اختصاص داده می شود. این امتیاز بر اساس تحلیل رفتار زمانی خروجی مدل در طول فرآیند آموزش محاسبه می گردد. به طور خاص، با بررسی تغییرات عدم قطعیت پیش بینی مدل و نوسانات توزیع احتمال خروجی در طول دوره های آموزش^۲، نمونه هایی که یادگیری آن ها دشوارتر یا پر اطلاعات تر هستند، شناسایی می شوند. در نهایت، نمونه هایی با بیشترین امتیاز^۳ اهمیت انتخاب شده و زیرمجموعه S را تشکیل می دهند، در حالی که نمونه های کم اهمیت تر از فرآیند آموزش حذف می شوند. این رویکرد امکان کاهش قابل توجه حجم داده های آموزشی را بدون افت محسوس در عملکرد نهایی مدل فراهم می سازد.

۲.۱.۳ ثبت دینامیک خروجی مدل در طول آموزش

به منظور تحلیل دقیق رفتار یادگیری مدل و استخراج اطلاعات زمانی مرتبط با هر نمونه آموزشی، لازم است دینامیک^۴ خروجی مدل در طول فرآیند آموزش به صورت صریح ثبت و ذخیره شود. برخلاف رویکردهای ایستا که تنها به خروجی نهایی مدل متکی هستند، روش پیشنهادی بر این فرض استوار است که مسیر تکامل پیش بینی های مدل در طول آموزش، حاوی اطلاعات ارزشمندی درباره میزان دشواری، عدم قطعیت و اهمیت هر نمونه می باشد.

بدین منظور، یک مدل پایه با پارامترهای اولیه $\theta^{(0)}$ به مدت T دوره آموزش بر روی مجموعه داده کامل D آموزش داده می شود. در پایان هر دوره آموزشی $t \in \{1, \dots, T\}$ ، خروجی مدل برای تمامی نمونه های آموزشی به صورت همگن و با ترتیب ثابت محاسبه و ذخیره می گردد. به طور خاص، برای هر نمونه آموزشی x_n و هر دوره t ، بردار لاجیت خروجی مدل به صورت

$$\mathbf{z}_n^{(t)} = (z_{n,1}^{(t)}, z_{n,2}^{(t)}, \dots, z_{n,C}^{(t)}) \in \mathbb{R}^C \quad (۵.۳)$$

^۱Expected value

^۲Epochs

^۳Score

^۴Dynamic

تعریف می‌شود که در آن $z_{n,c}^{(t)}$ مقدار پیش‌فعال‌سازی متناظر با کلاس c در انتهای دوره t است. انتخاب لاجیت‌ها به‌جای خروجی‌های نهایی Softmax از این جهت صورت می‌گیرد که لاجیت‌ها نسبت به مسائل ناپایداری عددی مقاوم‌تر بوده و اطلاعات کامل‌تری از فاصله نسبی بین کلاس‌ها را در خود حفظ می‌کنند. این ویژگی به‌ویژه در مراحل اولیه آموزش که توزیع خروجی مدل ناپایدار است، اهمیت ویژه‌ای دارد.

مجموعه تمامی لاجیت‌های ثبت‌شده را می‌توان به‌صورت یک تانسور^۱ سه‌بعدی نمایش داد:

$$\mathcal{Z} = \{\mathbf{z}_n^{(t)}\}_{n=1, t=1}^{N, T} \in \mathbb{R}^{N \times T \times C}, \quad (6.3)$$

که در آن، بعد اول متناظر با شاخص نمونه، بعد دوم متناظر با زمان (دوره آموزش) و بعد سوم متناظر با کلاس‌های مسئله می‌باشد.

این تانسور زمانی، مبنای اصلی محاسبه کلیه معیارهای پیشنهادی برای هرس داده در این پژوهش را تشکیل می‌دهد. در بخش‌های بعدی نشان داده خواهد شد که چگونه با تحلیل تغییرات زمانی عناصر این تانسور، می‌توان معیارهای عدم قطعیت پویا^۲ و نوسانات توزیع خروجی مدل را استخراج و از آن‌ها برای امتیازدهی و انتخاب نمونه‌های آموزشی استفاده کرد.

۳.۱.۳ نگاشت لاجیت به توزیع احتمال

به‌منظور انجام تحلیل معنادار بر روی خروجی مدل و امکان مقایسه پیش‌بینی‌ها^۳ در طول زمان، لازم است لاجیت‌های ذخیره‌شده به توزیع‌های احتمال نرمال‌شده^۴ نگاشت شوند. از آن‌جا که مقادیر لاجیت فاقد قید نرمال‌سازی بوده و تفسیر مستقیم آن‌ها دشوار است، از تابع Softmax برای تبدیل آن‌ها به توزیع احتمال بر روی کلاس‌ها استفاده می‌شود.

به‌طور خاص، برای هر نمونه آموزشی x_n و هر دوره آموزش $t \in \{1, \dots, T\}$ ، توزیع احتمال پیش‌بینی‌شده مدل به‌صورت زیر تعریف می‌گردد:

$$p_{n,c}^{(t)} = \frac{\exp(z_{n,c}^{(t)})}{\sum_{k=1}^C \exp(z_{n,k}^{(t)})}, \quad c = 1, \dots, C, \quad (7.3)$$

که در آن $p_{n,c}^{(t)}$ بیانگر احتمال انتساب نمونه x_n به کلاس c در پایان دوره آموزش t است. بدیهی است

¹Tensor

²Dynamic Uncertainty

³Predicts

⁴Proper probability distributions

که برای هر نمونه و هر دوره، قیود یک توزیع احتمال برقرار می‌باشد:

$$\sum_{c=1}^C p_{n,c}^{(t)} = 1, \quad p_{n,c}^{(t)} \in [0, 1]. \quad (8.3)$$

در ادامه تحلیل، تمرکز اصلی بر احتمال اختصاص یافته به کلاس صحیح هر نمونه خواهد بود. از آنجا که هدف یادگیری، افزایش اطمینان مدل نسبت به برچسب صحیح است، این کمیت نقش کلیدی در توصیف روند یادگیری ایفا می‌کند. بدین منظور، برای هر نمونه x_n ، احتمال پیش‌بینی کلاس صحیح در دوره t به صورت زیر تعریف می‌شود:

$$p_n^{(t)} = p_{n,y_n}^{(t)}. \quad (9.3)$$

کمیت $p_n^{(t)}$ نشان‌دهنده میزان اطمینان مدل نسبت به پیش‌بینی صحیح نمونه x_n در دوره t بوده و تغییرات زمانی آن بازتابی از میزان دشواری یادگیری، پایداری پیش‌بینی^۱ و حساسیت مدل^۲ نسبت به آن نمونه می‌باشد. در بخش‌های بعدی نشان داده خواهد شد که چگونه با تحلیل نوسانات و تغییرات زمانی این احتمال، می‌توان معیارهای مؤثری برای سنجش عدم قطعیت پویا و اهمیت نمونه‌ها استخراج نمود.

۴.۱.۳ عدم قطعیت پویا وزن‌دار

یکی از ویژگی‌های بارز نمونه‌های پراطلاع^۳، ناپایداری پیش‌بینی مدل نسبت به آن‌ها در طول فرآیند آموزش است. به‌طور شهودی، نمونه‌هایی که یادگیری آن‌ها برای مدل دشوارتر است، معمولاً باعث نوسان در میزان اطمینان مدل نسبت به کلاس صحیح می‌شوند، در حالی که نمونه‌های ساده یا تکراری، به سرعت با اطمینان بالا و پایدار پیش‌بینی می‌گردند. بر این اساس، تحلیل تغییرات زمانی احتمال کلاس صحیح می‌تواند معیار مناسبی برای سنجش میزان اهمیت هر نمونه فراهم آورد. در این پژوهش، برای اندازه‌گیری این ناپایداری، معیار عدم قطعیت پویا وزن‌دار^۴ مبتنی بر تغییرات احتمال کلاس صحیح در طول زمان تعریف می‌شود. بدین منظور، برای هر نمونه آموزشی x_n ، یک پنجره زمانی لغزان^۵ به طول J در نظر گرفته می‌شود که به صورت زیر تعریف می‌گردد:

$$\mathcal{W}_t^{(n)} = \{p_n^{(t)}, p_n^{(t+1)}, \dots, p_n^{(t+J-1)}\}, \quad t = 1, \dots, T - J + 1, \quad (10.3)$$

که در آن $p_n^{(t)}$ احتمال پیش‌بینی کلاس صحیح نمونه x_n در دوره آموزش t می‌باشد.

¹Predictive robustness

²Model sensitivity

³Informative

⁴Dynamic weighted uncertainty

⁵Sliding time window

از آنجا که رفتار مدل در دوره‌های متأخر آموزش معمولاً بازتاب دقیق‌تری از فرآیند همگرایی^۱ و یادگیری نهایی است، در محاسبه معیار عدم قطعیت، وزن بیشتری به مقادیر زمانی جدیدتر اختصاص داده می‌شود. بدین منظور، وزن‌های زمانی غیرمنفی به صورت خطی افزایشی تعریف می‌شوند:

$$\tilde{w}_j = 0.5 + \frac{j-1}{J-1} \times 0.5, \quad j = 1, \dots, J, \quad (11.3)$$

که در آن، مقادیر متناظر با موقعیت‌های انتهایی پنجره زمانی از وزن بالاتری برخوردار هستند. سپس، برای اطمینان از مقیاس‌پذیری و تفسیرپذیری، این وزن‌ها نرمال‌سازی می‌شوند:

$$w_j = \frac{\tilde{w}_j}{\sum_{k=1}^J \tilde{w}_k}, \quad \sum_{j=1}^J w_j = 1. \quad (12.3)$$

با استفاده از وزن‌های فوق، میانگین وزن‌دار احتمال کلاس صحیح در پنجره زمانی $\mathcal{W}_t^{(n)}$ به صورت زیر محاسبه می‌شود:

$$\mu_n^{(t)} = \sum_{j=1}^J w_j p_n^{(t+j-1)}. \quad (13.3)$$

در ادامه، میزان ناپایداری پیش‌بینی مدل^۲ در هر پنجره زمانی از طریق انحراف معیار وزن‌دار احتمال کلاس صحیح تعریف می‌شود:

$$\sigma_n^{(t)} = \sqrt{\sum_{j=1}^J w_j \left(p_n^{(t+j-1)} - \mu_n^{(t)} \right)^2}. \quad (14.3)$$

مقدار $\sigma_n^{(t)}$ بیانگر شدت نوسان پیش‌بینی مدل نسبت به نمونه x_n در بازه زمانی مشخص بوده و مقادیر بزرگ‌تر آن نشان‌دهنده عدم قطعیت^۳ بیشتر و دشواری یادگیری نمونه می‌باشد. در نهایت، به منظور به دست آوردن یک معیار کلی برای هر نمونه، عدم قطعیت پویا وزن‌دار با میانگین‌گیری از مقادیر انحراف معیار در تمامی پنجره‌های زمانی محاسبه می‌شود:

$$U_n = \frac{1}{T-J+1} \sum_{t=1}^{T-J+1} \sigma_n^{(t)}. \quad (15.3)$$

کمیت U_n به عنوان معیار نهایی عدم قطعیت پویا وزن‌دار نمونه x_n در نظر گرفته می‌شود و در مراحل

¹Convergence process

²Model prediction instability

³Uncertainty

بعدی، به عنوان یکی از مؤلفه‌های اصلی امتیازدهی و هرس مجموعه داده مورد استفاده قرار می‌گیرد.

۵.۱.۳ امتیازدهی دو عمقی زمانی هموار شده

اگرچه تحلیل نوسانات احتمال کلاس صحیح اطلاعات مستقیمی درباره میزان اطمینان مدل فراهم می‌کند، اما این تحلیل تنها بخشی از رفتار یادگیری مدل را منعکس می‌نماید. در بسیاری از موارد، تغییرات مهم در فرآیند یادگیری نه در احتمال کلاس صحیح، بلکه در شکل کلی توزیع خروجی مدل رخ می‌دهند. به عبارت دیگر، حتی در حالتی که احتمال کلاس صحیح تقریباً ثابت باقی می‌ماند، ممکن است توزیع احتمال سایر کلاس‌ها دستخوش تغییرات معناداری شود که نشان‌دهنده بازآرایی نمایش‌های درونی مدل و تنظیم مجدد مرزهای تصمیم‌گیری است. از این رو، تحلیل دینامیک کل توزیع خروجی مدل، مکمل ضروری تحلیل مبتنی بر کلاس صحیح محسوب می‌شود.

در این پژوهش، برای سنجش تغییرات زمانی توزیع خروجی مدل، از معیار واگرایی کولبک-لایبلر (KL)^۱ میان توزیع‌های احتمال متوالی در طول فرآیند آموزش استفاده می‌شود. واگرایی و اگرایی کولبک-لایبلر که ریشه در نظریه اطلاعات دارد، میزان افزایش امید ریاضی طول کد یا، به طور معادل، میزان اتلاف اطلاعات ناشی از تقریب یک توزیع احتمال با توزیع دیگر را اندازه‌گیری می‌کند. به طور خاص، برای دو توزیع گسسته^۲ P و Q بر روی فضای کلاس‌ها، واگرایی کولبک-لایبلر به صورت

$$D_{KL}(P \parallel Q) = \sum_c P(c) \log \frac{P(c)}{Q(c)} \quad (۱۶.۳)$$

تعریف می‌شود و مقدار آن تنها در صورتی صفر است که دو توزیع دقیقاً برابر باشند.

در زمینه این پژوهش، توزیع P متناظر با خروجی مدل در دوره آموزش t و توزیع Q متناظر با خروجی مدل در دوره آموزش قبلی $t-1$ است. بدین ترتیب، واگرایی کولبک-لایبلر اندازه‌گیری می‌کند که تا چه حد توزیع پیش‌بینی مدل در دوره آموزش جاری نسبت به دوره آموزش قبلی تغییر کرده است. مقدار بزرگ‌تر واگرایی نشان‌دهنده آن است که مدل برای نمونه مورد نظر ناچار به اعمال تغییرات اطلاعاتی قابل توجهی در خروجی خود شده است؛ امری که معمولاً با نمونه‌های دشوار، مرزی یا به شدت پراطلاع همراه است.

با این حال، محاسبه مستقیم واگرایی می‌تواند از نظر عددی ناپایدار باشد، به ویژه در حالتی که برخی مؤلفه‌های توزیع احتمال در دوره آموزش قبلی مقادیر صفر یا بسیار کوچک داشته باشند. در چنین شرایطی، جمله لگاریتمی می‌تواند منجر به مقادیر نامتناهی^۳ یا بسیار بزرگ شود. برای جلوگیری از این مسئله و تضمین پایداری عددی، توزیع احتمال دوره آموزش قبلی به صورت هموار شده در نظر

^۱Kullback-Leibler Divergence

^۲Discrete distribution

^۳Infinite values

گرفته می شود:

$$\tilde{p}_{n,c}^{(t-1)} = (1 - \epsilon) p_{n,c}^{(t-1)} + \epsilon \frac{1}{C}, \quad (17.3)$$

که در آن $\epsilon \in (0, 1)$ پارامتر هموارسازی^۱ بوده و افزودن مؤلفه یکنواخت^۲ $\frac{1}{C}$ تضمین می کند که تمامی مؤلفه های توزیع دارای کران پایین مثبت باشند. این هموارسازی را می توان به عنوان اعمال یک پیشین یکنواخت^۳ ضعیف بر توزیع خروجی مدل تفسیر کرد. بر این اساس، واگرایی KL برای هر نمونه x_n و هر دوره آموزش t به صورت زیر محاسبه می شود:

$$D_n^{(t)} = \sum_{c=1}^C p_{n,c}^{(t)} \log \frac{p_{n,c}^{(t)}}{\tilde{p}_{n,c}^{(t-1)}}. \quad (18.3)$$

از آن جا که واگرایی KL یک معیار غیرمقارن است و علامت آن جهت تغییر توزیع را نشان می دهد، در این پژوهش تمرکز صرفاً بر شدت تغییرات اطلاعاتی است و نه جهت آن. بدین منظور، قدرمطلق مقادیر واگرایی در نظر گرفته می شود. سپس، برای استخراج ناپایداری این تغییرات در مقیاس زمانی محلی، واریانس مقادیر قدرمطلق واگرایی در یک پنجره زمانی لغزان به طول K_t محاسبه می گردد:

$$R_n^{(w)} = \text{Var} \left(|D_n^{(w)}|, \dots, |D_n^{(w+K_t-1)}| \right), \quad (19.3)$$

که در آن $w = 1, \dots, T - K_t + 1$ شاخص پنجره زمانی است. این واریانس بیانگر شدت نوسان تغییرات توزیعی خروجی مدل در بازه های زمانی کوتاه بوده و می توان آن را به عنوان عمق اول تحلیل زمانی در نظر گرفت.

با این حال، نوسانات کوتاه مدت ممکن است ناشی از نویز تصادفی فرآیند بهینه سازی باشند و لزوماً بازتاب دهنده رفتار پایدار یادگیری نباشند. از این رو، برای استخراج روند بلندمدت و پایدار تغییرات توزیعی، یک لایه هموارسازی زمانی ثانویه از طریق میانگین نمایی اعمال می شود:

$$R_n^{(i)} = \beta R_n^{(i-1)} + (1 - \beta) R_n^{(w_i)}, \quad i = 1, \dots, T - K_t + 1, \quad (20.3)$$

که در آن $\beta \in (0, 1)$ ضریب هموارسازی نمایی^۴ است. این مرحله عمق دوم تحلیل زمانی را تشکیل داده و با کاهش اثر نوسانات لحظه ای، رفتار پایدار هر نمونه در طول آموزش را آشکار می سازد. در نهایت، مقدار نهایی معیار امتیازدهی دو عمقی زمانی هموار شده^۵ برای هر نمونه x_n به صورت

¹Smoothing parameter

²Constant

³Uniform prior

⁴Exponential smoothing coefficient

⁵Temporally Smoothed Dual-Depth Scoring

زیر تعریف می‌شود:

$$R_n = R_n^{(T-K_t+1)}. \quad (21.3)$$

کمیت R_n بازتاب‌دهنده میزان ناپایداری پایدار در توزیع خروجی مدل نسبت به نمونه x_n است. نمونه‌هایی با مقادیر بزرگ‌تر R_n ، تغییرات اطلاعاتی شدیدتر و مداوم‌تری را به مدل تحمیل می‌کنند و در نتیجه، از دیدگاه یادگیری، نمونه‌هایی پراطلاح و تأثیرگذار محسوب می‌شوند. این معیار در ادامه، به‌عنوان دومین مؤلفه اصلی در ترکیب امتیاز نهایی نمونه‌ها مورد استفاده قرار می‌گیرد.

۶.۱.۳ نرمال‌سازی و ترکیب معیارها

دو معیار استخراج‌شده در این پژوهش، یعنی عدم قطعیت پویا وزن‌دار (U_n) و امتیازدهی دو عمقی زمانی هموارشده (R_n)، هرچند هر دو مبتنی بر دینامیک زمانی خروجی مدل هستند، اما ماهیت آماری و دامنه عددی متفاوتی دارند. معیار U_n مستقیماً نوسانات احتمال کلاس صحیح را اندازه‌گیری می‌کند، در حالی که R_n بازتابی از ناپایداری تغییرات کل توزیع احتمال خروجی مدل در طول فرآیند آموزش است. از این رو، ترکیب مستقیم این دو معیار بدون هم‌مقیاس‌سازی می‌تواند منجر به غلبه ناخواسته یکی از آن‌ها در امتیازدهی نهایی شود.

به‌منظور رفع این مسئله و ایجاد امکان مقایسه منصفانه میان نمونه‌ها، از نرمال‌سازی خطی حداقل-حداکثر^۱ استفاده می‌شود تا مقادیر هر معیار به بازه مشترک [۰, ۱] نگاشت شوند. به‌طور خاص، برای هر نمونه x_n ، نسخه نرمال‌شده معیارها به‌صورت زیر تعریف می‌شود:

$$\hat{U}_n = \frac{U_n - \min_m U_m}{\max_m U_m - \min_m U_m}, \quad (22.3)$$

$$\hat{R}_n = \frac{R_n - \min_m R_m}{\max_m R_m - \min_m R_m}. \quad (23.3)$$

این نرمال‌سازی یک نگاشت یکنواخت است که ترتیب نسبی نمونه‌ها را در هر معیار حفظ کرده و در عین حال، حساسیت به مقیاس عددی معیارها را حذف می‌کند. در نتیجه، هر دو معیار به‌صورت متوازن در فرآیند ترکیب نقش ایفا می‌نمایند.

پس از نرمال‌سازی، هدف استخراج یک امتیاز واحد برای هر نمونه است که به‌صورت همزمان دو جنبه مکمل یادگیری را در نظر بگیرد: (۱) ناپایداری پیش‌بینی مدل نسبت به کلاس صحیح، و (۲) شدت تغییرات ساختاری در توزیع خروجی مدل.

بدین منظور، از یک ترکیب غیرخطی^۲ به‌صورت RMS^۳ مانند استفاده می‌شود که امتیاز نهایی

^۱Min-Max Linear Normalization

^۲Nonlinear combination

^۳Root Mean Square

هر نمونه را به صورت زیر تعریف می‌کند:

$$S_n = \sqrt{\alpha \hat{U}_n^2 + (1 - \alpha) \hat{R}_n^2}, \quad \alpha \in [0, 1]. \quad (24.3)$$

این فرم ترکیب دارای چند ویژگی کلیدی است. نخست، به دلیل استفاده از توان دوم، نمونه‌هایی که حداقل در یکی از دو معیار مقدار بزرگی دارند، امتیاز نهایی بالاتری دریافت می‌کنند؛ امری که با هدف شناسایی نمونه‌های پراطلاع سازگار است. دوم، ساختار RMS مانند از خنثی شدن سیگنال‌های قوی جلوگیری کرده و نسبت به ترکیب خطی ساده حساسیت بیشتری به مقادیر بزرگ دارد. سوم، این ترکیب به طور طبیعی تعادلی میان دو مؤلفه برقرار می‌کند، به گونه‌ای که هیچ‌یک از معیارها به تنهایی تعیین‌کننده امتیاز نهایی نخواهد بود.

پارامتر α نقش یک ضریب تنظیم‌کننده را ایفا می‌کند که میزان اهمیت نسبی هر یک از دو معیار را کنترل می‌نماید. در حالت $\alpha = 1$ ، امتیاز نهایی صرفاً بر اساس عدم قطعیت پویا وزن‌دار تعیین می‌شود، در حالی که در حالت $\alpha = 0$ ، تنها تغییرات توزیعی خروجی مدل مدنظر قرار می‌گیرند. مقادیر میانی α امکان بهره‌گیری همزمان از هر دو منبع اطلاعاتی را فراهم می‌سازند. در این پژوهش، مقدار α به گونه‌ای انتخاب می‌شود که توازن مناسبی میان این دو جنبه از دینامیک یادگیری برقرار گردد. در نهایت، مقادیر S_n به عنوان امتیاز نهایی اهمیت نمونه‌ها در نظر گرفته شده و مبنای رتبه‌بندی نزولی نمونه‌های آموزشی و انتخاب زیرمجموعه هرس شده S در مرحله بعد قرار می‌گیرند.

۷.۱.۳ انتخاب نمونه‌ها و هرس داده

پس از محاسبه امتیاز نهایی اهمیت هر نمونه آموزشی، مسئله هرس داده را می‌توان به صورت انتخاب یک زیرمجموعه بهینه از داده‌های آموزشی فرموله کرد. هدف این انتخاب، حفظ بیشترین اطلاعات مؤثر برای یادگیری مدل در عین کاهش اندازه مجموعه داده است. به طور مشخص، با در اختیار داشتن امتیاز اهمیت S_n برای هر نمونه x_n ، مسئله هرس را می‌توان به صورت زیر در نظر گرفت:

$$\max_{S \subset \mathcal{D}} \sum_{(x_n, y_n) \in S} S_n \quad \text{to subject} \quad |S| = (1 - p)N, \quad (25.3)$$

که در آن $p \in (0, 1)$ نسبت هرس داده را مشخص می‌کند. این فرموله‌سازی نشان می‌دهد که هدف، انتخاب زیرمجموعه‌ای از نمونه‌ها است که مجموع اهمیت آن‌ها بیشینه باشد.

از آنجا که امتیاز S_n یک کمیت اسکالر و قابل مرتب‌سازی است، حل این مسئله به صورت صریح با مرتب‌سازی نزولی امتیازها امکان‌پذیر می‌باشد. بدین منظور، ابتدا یک جایگشت از شاخص‌های نمونه‌ها به صورت زیر تعریف می‌شود:

$$\pi = \text{argsort}(\{S_n\}_{n=1}^N)_{\text{desc}}, \quad (26.3)$$

به گونه ای که:

$$S_{\pi_1} \geq S_{\pi_2} \geq \dots \geq S_{\pi_N}. \quad (27.3)$$

سپس، زیرمجموعه نهایی داده های آموزشی با انتخاب نمونه هایی که دارای بالاترین امتیاز اهمیت هستند، تعریف می شود:

$$\mathcal{S} = \{(x_{\pi_i}, y_{\pi_i}) \mid i = 1, \dots, \lfloor (1-p)N \rfloor\}. \quad (28.3)$$

نمونه هایی که شاخص آن ها در بازه

$$i > \lfloor (1-p)N \rfloor$$

قرار می گیرد، به عنوان نمونه های کم اطلاعات تر، ساده، یا تکراری در نظر گرفته شده و از فرآیند آموزش نهایی حذف می شوند. از دیدگاه یادگیری آماری، حذف این نمونه ها معادل با حذف نمونه هایی است که سهم ناچیزی در تغییر گرادیان تابع هزینه و به روزرسانی پارامترهای مدل دارند. به صورت دقیق تر، اگر گرادیان تابع هزینه نسبت به پارامترهای مدل θ برای نمونه x_n در دوره آموزش t به صورت

$$g_n^{(t)} = \nabla_{\theta} \ell(f_{\theta}^{(t)}(x_n), y_n) \quad (29.3)$$

تعریف شود، نمونه هایی با امتیاز S_n بزرگ تر معمولاً دارای تغییرات زمانی بزرگ تری در توزیع خروجی مدل بوده و در نتیجه، رفتار گرادیان آن ها در طول آموزش پایدار نیست. این ویژگی نشان می دهد که چنین نمونه هایی نقش فعال تری در بازتنظیم مسیر بهینه سازی و شکل دهی مرزهای تصمیم مدل ایفا می کنند.

در مقابل، نمونه هایی با امتیاز S_n کوچک، غالباً یا نمونه های بسیار ساده هستند که مدل در دوره های آموزش ابتدایی به درستی آن ها را یاد می گیرد، یا نمونه هایی تکراری که اطلاعات جدیدی به فرآیند یادگیری اضافه نمی کنند. حذف این نمونه ها منجر به کاهش اندازه مجموعه داده بدون افت محسوس در کیفیت یادگیری می شود.

در نهایت، مدل نهایی تنها با استفاده از زیرمجموعه منتخب $\mathcal{S}$ بازآموزی^۱ می گردد و انتظار می رود که:

$$\mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{\theta_S}(x), y)] \approx \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{\theta_D}(x), y)], \quad (30.3)$$

که این رابطه بیانگر حفظ عملکرد مدل علی رغم کاهش اندازه داده های آموزشی است. تحقق این

¹Retrain

شرط نشان‌دهنده اثربخشی راهبرد پیشنهادی هرس داده مبتنی بر تحلیل دینامیک زمانی خروجی مدل می‌باشد.

۸.۱.۳ وزن‌دهی مبتنی بر اهمیت در مرحله بازآموزی

پس از انتخاب زیرمجموعه داده‌های آموزشی $\mathcal{S}$ ، هدف مرحله بازآموزی، بهره‌برداری حداکثری از نمونه‌های باقی‌مانده به‌منظور جبران حذف بخشی از داده‌ها است. اگرچه در مرحله هرس، تنها نمونه‌های با امتیاز اهمیت بالا حفظ می‌شوند، اما میزان پراطلاح بودن این نمونه‌ها نیز یکسان نیست. از این رو، در روش پیشنهادی، علاوه بر انتخاب نمونه‌ها، سهم هر نمونه در فرآیند یادگیری نیز به‌صورت صریح کنترل می‌شود.

بدین منظور، به هر نمونه $x_n \in \mathcal{S}$ وزنی متناسب با امتیاز نهایی آن اختصاص داده می‌شود. ابتدا امتیازهای نهایی نمونه‌های باقی‌مانده به بازه $[0, 1]$ نرمال‌سازی می‌شوند:

$$\hat{S}_n = \frac{S_n - \min_{m \in \mathcal{S}} S_m}{\max_{m \in \mathcal{S}} S_m - \min_{m \in \mathcal{S}} S_m}. \quad (31.3)$$

سپس، وزن هر نمونه به‌صورت یک تابع خطی صعودی از امتیاز نرمال‌شده آن تعریف می‌شود:

$$w_n = 1 + \lambda \hat{S}_n, \quad \lambda \geq 0, \quad (32.3)$$

که در آن λ پارامتر تنظیم شدت وزن‌دهی بوده و میزان تأکید بر نمونه‌های با اهمیت بالاتر را کنترل می‌کند. انتخاب $\lambda = 0$ منجر به بازآموزی استاندارد بدون وزن‌دهی می‌شود، در حالی که مقادیر بزرگ‌تر λ سهم نمونه‌های پراطلاح را در یادگیری افزایش می‌دهند. بر اساس این وزن‌دهی، تابع خطای بازآموزی به‌صورت وزن‌دار بازتعریف می‌شود:

$$\mathcal{L}_w(\theta) = \frac{1}{|\mathcal{S}|} \sum_{n \in \mathcal{S}} w_n \ell(f_\theta(x_n), y_n), \quad (33.3)$$

که در آن $\ell(\cdot)$ تابع خطای پایه (نظیر Cross-Entropy) و θ پارامترهای مدل می‌باشد. از دیدگاه بهینه‌سازی، گرادینت تابع هزینه وزن‌دار نسبت به پارامترهای مدل به‌صورت زیر قابل بیان است:

$$\nabla_\theta \mathcal{L}_w(\theta) = \frac{1}{|\mathcal{S}|} \sum_{n \in \mathcal{S}} w_n \nabla_\theta \ell(f_\theta(x_n), y_n). \quad (34.3)$$

این رابطه نشان می‌دهد که نمونه‌هایی با وزن بزرگ‌تر، سهم بیشتری در جهت و اندازه به‌روزرسانی پارامترهای مدل دارند. از آن‌جا که وزن w_n به‌طور مستقیم تابعی از امتیاز اهمیت S_n است، نمونه‌هایی که در طول آموزش اولیه موجب نوسانات شدیدتر یا تغییرات توزیعی بزرگ‌تری در خروجی مدل

شده‌اند، تأثیر پررنگ‌تری در بازآموزی خواهند داشت. از منظر یادگیری آماری، این راهبرد وزن‌دهی را می‌توان به‌عنوان نوعی بازنمونه‌برداری نرم^۱ تفسیر کرد که در آن، به‌جای تکرار فیزیکی نمونه‌های مهم، اثر آن‌ها از طریق افزایش سهمشان در تابع هزینه تقویت می‌شود. این رویکرد ضمن جلوگیری از بیش‌برازش^۲، امکان تمرکز مدل بر نمونه‌های دشوار، مرزی و پراطلاح را فراهم می‌سازد. در مجموع، ترکیب هرس داده مبتنی بر امتیاز اهمیت با وزن‌دهی صریح در مرحله بازآموزی، منجر به حفظ اطلاعات حیاتی مجموعه داده اصلی و کاهش افت عملکرد مدل نهایی می‌گردد. این مرحله نقش کلیدی در موفقیت عملی روش پیشنهادی ایفا می‌کند، به‌ویژه در سناریوهایی که نسبت هرس داده بالا است.

۲.۳ تحلیل پیچیدگی زمانی و حافظه‌ای روش پیشنهادی

در این بخش، پیچیدگی زمانی و حافظه‌ای^۳ روش پیشنهادی به‌صورت گام‌به‌گام مورد بررسی قرار می‌گیرد. تحلیل بر اساس پارامترهای زیر انجام می‌شود:

- N : تعداد کل نمونه‌های آموزشی،
- T : تعداد دوره‌های آموزش اولیه،
- C : تعداد کلاس‌ها،
- J : طول پنجره زمانی در محاسبه عدم قطعیت پویا،
- K_t : طول پنجره زمانی در محاسبه امتیازدهی دوعمقی زمانی،
- $|S| = (1 - p)N$: تعداد نمونه‌های باقی‌مانده پس از هرس.

۱.۲.۳ پیچیدگی ثبت دینامیک خروجی مدل

در مرحله نخست، لاجیت‌های خروجی مدل برای تمامی نمونه‌های آموزشی و در هر دوره آموزش ذخیره می‌شوند. برای هر مدل یک بار روی کل مجموعه داده آموزشی اعمال می‌شود. بنابراین، پیچیدگی زمانی این مرحله برابر است با:

$$O(T \cdot N \cdot C), \quad (35.3)$$

که در آن عامل C ناشی از تولید بردار لاجیت خروجی برای هر نمونه است.

¹Soft resampling

²Overfitting

³Computational and memory complexity

از نظر حافظه‌ای، ذخیره تانسور لاجیت‌ها به ابعاد $N \times T \times C$ نیاز دارد، در نتیجه پیچیدگی حافظه‌ای این مرحله برابر است با:

$$\mathcal{O}(N \cdot T \cdot C). \quad (36.3)$$

۲.۲.۳ پیچیدگی نگاشت لاجیت به توزیع احتمال

نگاشت لاجیت‌ها به توزیع احتمال از طریق تابع Softmax برای تمامی نمونه‌ها و در هر دوره آموزش انجام می‌شود. این عملیات شامل محاسبه نمایی و نرمال‌سازی روی C کلاس است، بنابراین پیچیدگی زمانی آن برابر است با:

$$\mathcal{O}(N \cdot T \cdot C). \quad (37.3)$$

از آنجا که این مرحله می‌تواند به صورت درجا انجام شود، سربار حافظه‌ای^۱ اضافی قابل توجهی نسبت به ذخیره لاجیت‌ها ایجاد نمی‌کند.

۳.۲.۳ پیچیدگی محاسبه عدم قطعیت پویا وزن‌دار

برای هر نمونه، محاسبه عدم قطعیت پویا شامل پیمایش پنجره‌های زمانی به تعداد $(T - J + 1)$ و محاسبه انحراف معیار وزن‌دار روی پنجره‌ای به طول J است. بنابراین، پیچیدگی زمانی این مرحله برای کل داده‌ها برابر است با:

$$\mathcal{O}(N \cdot (T - J + 1) \cdot J) \approx \mathcal{O}(N \cdot T \cdot J). \quad (38.3)$$

پیچیدگی حافظه‌ای این مرحله تنها شامل ذخیره یک مقدار اسکالر U_n برای هر نمونه است:

$$\mathcal{O}(N). \quad (39.3)$$

۴.۲.۳ پیچیدگی محاسبه امتیازدهی دو عمقی زمانی هموار شده

در این مرحله، ابتدا واگرایی KL بین توزیع‌های احتمال متوالی برای هر نمونه و هر ایپاک محاسبه می‌شود. محاسبه واگرایی KL شامل پیمایش روی C کلاس است، بنابراین پیچیدگی زمانی آن برابر است با:

$$\mathcal{O}(N \cdot T \cdot C). \quad (40.3)$$

¹Memory overhead

سپس، برای هر نمونه، واریانس قدرمطلق واگرایی KL در پنجره‌های زمانی به طول K_t محاسبه می‌شود که پیچیدگی زمانی آن برابر است با:

$$\mathcal{O}(N \cdot (T - K_t + 1) \cdot K_t) \approx \mathcal{O}(N \cdot T \cdot K_t). \quad (41.3)$$

اعمال هموارسازی میانگین نمایی بر روی این مقادیر دارای پیچیدگی زمانی خطی نسبت به تعداد پنجره‌ها است و در مرتبه بالا تأثیری بر پیچیدگی نهایی ندارد. از نظر حافظه‌ای، این مرحله نیز تنها به ذخیره یک مقدار اسکالر R_n برای هر نمونه نیاز دارد:

$$\mathcal{O}(N). \quad (42.3)$$

۵.۲.۳ پیچیدگی نرمال‌سازی، ترکیب معیارها و مرتب‌سازی

نرمال‌سازی خطی و ترکیب معیارهای U_n و R_n دارای پیچیدگی زمانی خطی نسبت به تعداد نمونه‌ها است:

$$\mathcal{O}(N). \quad (43.3)$$

مرتب‌سازی نمونه‌ها بر اساس امتیاز نهایی S_n دارای پیچیدگی زمانی:

$$\mathcal{O}(N \log N) \quad (44.3)$$

می‌باشد که در مقایسه با مراحل قبلی، هزینه محاسباتی ناچیزی محسوب می‌شود.

۶.۲.۳ پیچیدگی مرحله بازآموزی

در مرحله بازآموزی، مدل تنها بر روی زیرمجموعه $\mathcal{S}$ شامل $(1-p)N$ نمونه آموزش داده می‌شود. بنابراین، پیچیدگی زمانی این مرحله نسبت به آموزش کامل مدل به صورت خطی کاهش می‌یابد و برابر است با:

$$\mathcal{O}(T_{\text{re}} \cdot (1-p)N), \quad (45.3)$$

که در آن T_{re} تعداد دوره‌های آموزشی در مرحله بازآموزی است. اعمال وزن‌دهی مبتنی بر اهمیت، تنها یک ضرب اسکالر در تابع هزینه بوده و سربار محاسباتی^۱ قابل توجهی ایجاد نمی‌کند.

¹Computational overhead

۷.۲.۳ جمع‌بندی پیچیدگی کلی

در مجموع، پیچیدگی زمانی غالب روش پیشنهادی توسط مراحل ثبت دینامیک خروجی مدل و محاسبه واگرایی KL تعیین می‌شود و به صورت تقریبی برابر است با:

$$\mathcal{O}(N \cdot T \cdot C), \quad (۴۶.۳)$$

در حالی که پیچیدگی حافظه‌ای غالب ناشی از ذخیره لاجیت‌ها بوده و برابر است با:

$$\mathcal{O}(N \cdot T \cdot C). \quad (۴۷.۳)$$

با توجه به این‌که این هزینه‌ها تنها در مرحله آموزش اولیه پرداخت می‌شوند و مرحله بازآموزی بر روی مجموعه داده کوچک‌تری انجام می‌گیرد، روش پیشنهادی از نظر محاسباتی مقرون به صرفه بوده و برای مجموعه داده‌های با اندازه متوسط تا بزرگ کاملاً قابل اجرا است.

۳.۳ تحلیل نوآوری‌ها و تمایز روش پیشنهادی نسبت به Dyn-Unc و TDDS

روش پیشنهادی این پژوهش با الهام از دو خط فکری اصلی در حوزه هرس داده مبتنی بر دینامیک آموزش، یعنی عدم قطعیت پویا [۳۲] و امتیازدهی دو عمقی زمانی [۷۲] توسعه یافته است. با این حال، روش نهایی ارائه شده نه یک ترکیب ساده از این دو معیار، بلکه چارچوبی یکپارچه و توسعه یافته است که محدودیت‌های هر یک از روش‌های پیشین را به صورت سیستماتیک برطرف می‌کند. در ادامه، نوآوری‌ها و تمایزهای اصلی روش پیشنهادی به صورت دقیق مورد تحلیل قرار می‌گیرد.

۱.۳.۳ تحلیل نوآوری نسبت به روش Dyn-Unc

روش Dyn-Unc معیار عدم قطعیت نمونه‌ها را بر اساس واریانس احتمال کلاس صحیح در طول فرآیند آموزش تعریف می‌کند. اگرچه این معیار قادر به شناسایی نمونه‌های دشوار یا مرزی است، اما دارای محدودیت‌های اساسی می‌باشد؛ از جمله عدم توجه به اهمیت نسبی ایپاک‌های متأخر که مدل به همگرایی نزدیک‌تر است، نادیده گرفتن تغییرات کلی توزیع خروجی مدل و تمرکز صرف بر احتمال کلاس صحیح، و همچنین حساسیت بالا به نوسانات کوتاه مدت در مراحل ابتدایی آموزش. در روش پیشنهادی، این محدودیت‌ها از طریق معرفی عدم قطعیت پویا وزن دار برطرف شده‌اند. به طور مشخص، با تعریف وزن‌های زمانی w_j به صورت صعودی، سهم دوره‌های آموزشی متأخر در

محاسبه انحراف معیار افزایش یافته است:

$$\sigma_n^{(t)} = \sqrt{\sum_{j=1}^J w_j \left(p_n^{(t+j-1)} - \mu_n^{(t)} \right)^2}. \quad (48.3)$$

این اصلاح باعث می شود که معیار عدم قطعیت، بیش از آن که تحت تأثیر رفتار ناپایدار اولیه مدل باشد، رفتار نمونه در نواحی نزدیک به همگرایی را منعکس کند. در نتیجه، نمونه هایی که در مراحل پایانی آموزش همچنان موجب نوسان در پیش بینی مدل می شوند، به درستی به عنوان نمونه های پراطلاع شناسایی می گردند.

۲.۳.۳ تحلیل نوآوری نسبت به روش TDDS

روش TDDS با تحلیل واگرایی KL بین توزیع های احتمال متوالی، تلاش می کند تغییرات عمیق تری در رفتار مدل نسبت به نمونه ها را استخراج کند. با این حال، این روش نیز با چالش هایی مواجه است، از جمله حساسیت واگرایی KL به مقادیر بسیار کوچک یا صفر در توزیع های احتمال، تمرکز بر مقدار لحظه ای واگرایی و عدم توجه کافی به پایداری زمانی تغییرات، و عدم ارائه سازوکار صریح برای ترکیب این معیار با سایر شاخص های عدم قطعیت.

در روش پیشنهادی، ابتدا با اعمال هموارسازی بر روی توزیع دوره آموزشی قبلی، پایداری عددی محاسبه واگرایی KL تضمین شده است:

$$\tilde{p}_{n,c}^{(t-1)} = (1 - \epsilon) p_{n,c}^{(t-1)} + \epsilon \frac{1}{C}. \quad (49.3)$$

سپس، به جای استفاده مستقیم از مقادیر واگرایی KL، واریانس قدرمطلق این واگرایی ها در پنجره های زمانی لغزان محاسبه می شود:

$$R_n^{(w)} = \text{Var} \left(|D_n^{(w)}|, \dots, |D_n^{(w+K_t-1)}| \right), \quad (50.3)$$

که این امر امکان استخراج میزان ناپایداری پایدار در تغییرات توزیعی خروجی مدل را فراهم می سازد. در نهایت، با به کارگیری هموارسازی میانگین نمایی، اثر نوسانات گذرا کاهش یافته و روند کلی رفتار نمونه در طول آموزش استخراج می شود.

۳.۳.۳ نوآوری در ترکیب چندمعیاره و امتیازدهی نهایی

یکی از نوآوری های کلیدی روش پیشنهادی، ارائه یک چارچوب ترکیب چندمعیاره برای امتیازدهی نهایی نمونه ها است. برخلاف روش های پیشین که تنها بر یک جنبه از رفتار مدل تمرکز دارند، در این پژوهش دو معیار مکمل با ماهیت های متفاوت به صورت همزمان مورد استفاده قرار می گیرند:

عدم قطعیت پویا وزن دار U_n که نوسانات احتمال کلاس صحیح را مدل می‌کند و امتیازدهی دو عمقی زمانی هموار شده R_n که تغییرات کلی توزیع خروجی مدل را در نظر می‌گیرد. این دو معیار پس از نرمال سازی، از طریق یک ترکیب RMS مانند ادغام می‌شوند:

$$S_n = \sqrt{\alpha \hat{U}_n^2 + (1 - \alpha) \hat{R}_n^2}. \quad (51.3)$$

این نوع ترکیب باعث می‌شود نمونه‌هایی که تنها در یکی از معیارها دارای مقدار بزرگ هستند، به‌طور افراطی غالب نشوند و در مقابل، نمونه‌هایی که به‌صورت همزمان در هر دو بعد دارای رفتار پیچیده هستند، امتیاز بالاتری دریافت کنند.

۴.۳.۳ نوآوری در یکپارچه سازی هرس و بازآموزی

در حالی که بسیاری از روش‌های هرس داده، انتخاب نمونه‌ها و آموزش مجدد را به‌صورت دو مرحله مستقل در نظر می‌گیرند، در روش پیشنهادی این دو مرحله به‌صورت یکپارچه طراحی شده‌اند. به‌طور خاص، امتیاز نهایی S_n نه تنها برای انتخاب نمونه‌ها، بلکه برای وزن‌دهی آن‌ها در مرحله بازآموزی نیز مورد استفاده قرار می‌گیرد:

$$w_n = 1 + \lambda \hat{S}_n. \quad (52.3)$$

این یکپارچگی باعث می‌شود اطلاعات به‌دست آمده از تحلیل دینامیک آموزش اولیه، به‌طور کامل در فرآیند بازآموزی نیز مورد بهره‌برداری قرار گیرد، امری که در روش‌های Dyn-Unc و TDDS به‌صورت صریح وجود ندارد.

۵.۳.۳ جمع بندی تمایزها

در مجموع، نوآوری‌های اصلی روش پیشنهادی شامل وزن‌دهی زمانی در محاسبه عدم قطعیت پویا و تمرکز بر دوره‌های آموزشی متأخر، هموارسازی عددی و زمانی در محاسبه امتیازدهی مبتنی بر واگرایی KL، ترکیب چندمعیاره مبتنی بر RMS برای استخراج امتیاز نهایی نمونه‌ها، استفاده همزمان از امتیاز نهایی برای هرس داده و وزن‌دهی در بازآموزی، و ارائه یک چارچوب یکپارچه، پایدار و مقیاس پذیر برای هرس داده مبتنی بر دینامیک آموزش است. این تمایزها موجب می‌شوند که روش پیشنهادی نه تنها از نظر تجربی عملکرد بهتری نسبت به روش‌های مرجع ارائه دهد، بلکه از منظر نظری نیز دارای انسجام و توجیه پذیری بالاتری باشد.

۴.۳ جمع‌بندی

در این فصل، یک چارچوب جامع برای هرس داده آموزشی مبتنی بر تحلیل دینامیک زمانی فرآیند یادگیری مدل ارائه شد. ایده اصلی روش پیشنهادی بر این فرض استوار است که رفتار زمانی خروجی مدل در طول آموزش، حاوی اطلاعات ارزشمندی درباره میزان اهمیت، دشواری و پراطلاح بودن هر نمونه آموزشی می‌باشد؛ اطلاعاتی که در روش‌های ایستا یا مبتنی بر یک تصویر لحظه‌ای^۱ از مدل قابل استخراج نیستند.

بدین منظور، در گام نخست دینامیک خروجی مدل از طریق ثبت لاجیت‌ها در طول چندین دوره آموزشی اولیه مدل‌سازی شد. سپس با نگاشت این لاجیت‌ها به توزیع‌های احتمال، دو جنبه مکمل از رفتار نمونه‌ها مورد تحلیل قرار گرفت: (۱) نوسانات زمانی احتمال کلاس صحیح به‌عنوان شاخصی از عدم قطعیت پویا، و (۲) تغییرات کلی توزیع پیش‌بینی مدل در طول زمان با استفاده از واگرایی کولبک-لایبیلر به‌عنوان شاخصی از بازتنظیم عمیق مرزهای تصمیم مدل.

برای افزایش پایداری و دقت این تحلیل، عدم قطعیت پویا به‌صورت وزن‌دار و با تأکید بر دوره‌های آموزشی متأخر تعریف شد و امتیازدهی مبتنی بر واگرایی کولبک-لایبیلر نیز از طریق هموارسازی عددی و زمانی اصلاح گردید. در ادامه، این دو معیار پس از نرمال‌سازی، به‌صورت یکپارچه و از طریق یک ترکیب RMS مانند ادغام شدند تا امتیاز نهایی اهمیت هر نمونه استخراج شود. این امتیاز مبنای انتخاب نمونه‌ها در فرآیند هرس داده قرار گرفت.

پس از هرس، مرحله بازآموزی مدل تنها بر روی زیرمجموعه منتخب داده‌ها انجام شد. به‌منظور بهره‌برداری حداکثری از اطلاعات نمونه‌های باقی‌مانده، راهبرد وزن‌دهی مبتنی بر اهمیت در تابع هزینه به‌کار گرفته شد تا نمونه‌های پراطلاح سهم بیشتری در به‌روزرسانی پارامترهای مدل داشته باشند. این یکپارچه‌سازی مرحله هرس و بازآموزی، از ویژگی‌های کلیدی روش پیشنهادی محسوب می‌شود.

تحلیل پیچیدگی زمانی و حافظه‌ای نشان داد که سربار محاسباتی اصلی روش تنها در مرحله آموزش اولیه پرداخت می‌شود و با توجه به کاهش اندازه داده در مرحله بازآموزی، هزینه کلی آموزش کاهش می‌یابد. علاوه بر این، تحلیل مقایسه‌ای با روش‌های Dyn-Unc و TDDS نشان داد که چارچوب پیشنهادی با رفع محدودیت‌های این روش‌ها، دید جامع‌تری نسبت به رفتار نمونه‌ها در طول آموزش ارائه می‌دهد.

در مجموع، روش پیشنهادی یک راهکار عمومی، مستقل از معماری شبکه و نوع داده، و مبتنی بر اصول یادگیری عمیق^۲ برای هرس داده آموزشی فراهم می‌سازد که قادر است با کاهش مؤثر حجم داده، عملکرد مدل نهایی را در سطحی قابل مقایسه با آموزش بر روی کل داده‌ها حفظ نماید. این ویژگی‌ها روش حاضر را به گزینه‌ای مناسب برای کاربرد در سناریوهای با داده‌های حجیم و محدودیت‌های محاسباتی تبدیل می‌کند.

^۱Snapshot

^۲Deep learning

Algorithm ۱: TD-DyUn

ورودی: $\alpha, \beta, \epsilon, \lambda, p, K_t, J, T, f_\theta, \mathcal{D}\{(x_n, y_n)\}_{n=1}^N$

۱: مقداردهی اولیه پارامترهای مدل $\theta^{(0)}$

۲: ثبت دینامیک خروجی مدل در طول آموزش
۳: برای $t=1$ تا T

۴: آموزش مدل f_θ به مدت یک دوره روی $\mathcal{D}$

۵: محاسبه و ذخیره لاجیت خروجی $\mathbb{R}^C \ni \mathbf{z}_n^{(t)}$ برای تمام نمونه‌ها

(رابطه (3.7))

۶: محاسبه توزیع احتمال با Softmax

(رابطه (3.9))

۷: استخراج احتمال کلاس صحیح $p_n^{(t)} = p_{n,y_n}^{(t)}$

۸: محاسبه عدم قطعیت پویا وزن دار

۹: تشکیل پنجره‌های زمانی لغزان به طول J

(رابطه (3.14))

۱۰: محاسبه انحراف معیار وزن دار $\sigma_n^{(t)}$

(رابطه (3.15))

۱۱: تجميع زمانی و محاسبه عدم قطعیت نهایی U_n

۱۲: تحلیل دینامیک توزیع خروجی مدل

(رابطه (3.17))

۱۳: محاسبه واگرایی KL هموارشده بین دوره‌های متوالی

۱۴: محاسبه واریانس محلی واگرایی‌ها در پنجره‌های زمانی

(رابطه (3.18))

۱۵: اعمال هموارسازی نمایی زمانی

۱۶: استخراج معیار نهایی تغییرات توزیعی R_n

۱۷: نرمال‌سازی و ترکیب معیارها

۱۸: نرمال‌سازی Min-Max معیارهای U_n و R_n

(رابطه (3.24))

۱۹: محاسبه امتیاز نهایی اهمیت نمونه S_n

۲۰: انتخاب نمونه‌ها و هرس داده

۲۱: مرتب‌سازی نزولی نمونه‌ها بر اساس S_n

۲۲: انتخاب زیرمجموعه هرس شده $\mathcal{S}$ با اندازه $\lfloor (1-p)N \rfloor$

۲۳: بازآموزی وزن دار مدل

۲۴: نرمال‌سازی امتیازها و محاسبه وزن نمونه‌ها $\lambda \hat{S}_n + 1 = w_n$

۲۵: بازآموزی مدل روی $\mathcal{S}$ با تابع هزینه وزن دار

خروجی: زیرمجموعه هرس شده $\mathcal{S}$ ، امتیاز اهمیت نمونه‌ها $\{S_n\}$ ، و مدل بازآموزی شده f_{θ_S}

شکل ۱.۳: الگوریتم نهایی هرس داده‌های بزرگ با روش عدم قطعیت دینامیک

فصل ۴

پیاده‌سازی و نتایج

۱.۴ مجموعه داده‌ها و پیش‌پردازش

در این پژوهش، برای ارزیابی عملکرد روش پیشنهادی، از دو مجموعه داده‌ی استاندارد CIFAR-10 و CIFAR-100 استفاده شده است. علاوه بر مشخصات ذاتی این مجموعه داده‌ها، مراحل پیش‌پردازش^۲، افزایش داده^۳ و نرمال‌سازی^۴ با دقت و به‌صورت یکسان در تمامی آزمایش‌ها اعمال شده‌اند تا مقایسه‌ای منصفانه و بازتولیدپذیر حاصل شود.

۱.۱.۴ مجموعه داده CIFAR-10

مجموعه داده CIFAR-10 [۳۶] شامل $N = 60,000$ تصویر رنگی با ابعاد 32×32 پیکسل^۵ است که در ۱۰ کلاس مجزا دسته‌بندی شده‌اند. از این تعداد $N = 50,000$ تصویر برای آموزش^۶ و $N = 10,000$ تصویر برای آزمون^۷ مورد استفاده قرار گرفته است. کلاس‌های این مجموعه داده شامل اشیای روزمره نظیر هواپیما، خودرو، پرنده، گربه، سگ و کشتی می‌باشند.

افزایش داده و پیش‌پردازش: به‌منظور بهبود تعمیم‌پذیری مدل^۸ و کاهش بیش‌برازشی^۹، مجموعه‌ای از تکنیک‌های افزایش داده در مرحله‌ی آموزش به‌کار گرفته شده است. این تکنیک‌ها شامل برش تصادفی تصاویر^{۱۰} با حاشیه‌ی چهار پیکسل و وارون‌سازی افقی تصادفی^{۱۱} می‌باشند.

²Preprocessing

³Data augmentation

⁴Normalization

⁵Pixel

⁶Train set

⁷Test set

⁸Model generalization

⁹Overfitting

¹⁰Random image cropping

¹¹Random horizontal flipping

پس از اعمال مراحل افزایش داده، تصاویر به قالب تانسور^۱ تبدیل شده و با استفاده از میانگین (۰/۴۴۶۵, ۰/۴۸۲۲, ۰/۴۹۱۴) و انحراف معیار (۰/۲۶۱, ۰/۲۴۳, ۰/۲۴۷) نرمال سازی شده اند. برای داده های آزمون، تنها مراحل تبدیل به تانسور و نرمال سازی اعمال شده و هیچ گونه افزایش داده ای انجام نشده است.

تقسیم داده و بارگذاری: در مرحله ی آموزش، داده ها به صورت تصادفی و در قالب دسته های آموزشی با اندازه ی دسته^۲ برابر با ۱۲۸ به مدل ارائه شده اند. به منظور ارزیابی پایدار و قابل تکرار، مجموعه ی آموزش علاوه بر حالت تصادفی، به صورت غیر تصادفی نیز برای محاسبه ی معیارهای ارزیابی مورد استفاده قرار گرفته است. تعداد کل نمونه های آموزشی برابر با $N = 50,000$ و تعداد کلاس ها برابر با $C = 10$ می باشد.

۲.۱.۴ مجموعه داده CIFAR-100

مجموعه داده CIFAR-100 [۳۶] از نظر ساختار مشابه CIFAR-10 بوده و شامل $N = 60,000$ تصویر رنگی با ابعاد 32×32 پیکسل است، با این تفاوت که تصاویر در ۱۰۰ کلاس مختلف سازمان دهی شده اند. این مجموعه داده نیز شامل $N = 50,000$ نمونه ی آموزشی و $N = 10,000$ نمونه ی آزمون می باشد که در نتیجه، تنها ۶۰۰ نمونه برای هر کلاس در دسترس است.

افزایش داده و پیش پردازش: مراحل پیش پردازش و افزایش داده برای CIFAR-100 مشابه CIFAR-10 بوده و شامل برش تصادفی با حاشیه ی چهار پیکسل و وارون سازی افقی تصادفی است. در ادامه، تصاویر به تانسور تبدیل شده و با استفاده از میانگین (۰/۴۴۰۸, ۰/۴۸۶۷, ۰/۵۰۷۱) و انحراف معیار (۰/۲۷۶۱, ۰/۲۵۶۵, ۰/۲۶۷۵) نرمال سازی شده اند. مشابه حالت قبل، برای مجموعه ی آزمون تنها مراحل تبدیل و نرمال سازی اعمال شده است.

تقسیم داده و بارگذاری: در مرحله ی آموزش، داده ها به صورت تصادفی و در قالب دسته های آموزشی با اندازه ی ثابت به مدل ارائه شده اند. اندازه ی هر دسته برابر با ۱۲۸ در نظر گرفته شده است که توازن مناسبی میان پایداری گرادیان، سرعت همگرایی و کارایی محاسباتی فراهم می کند. به منظور ارزیابی پایدار و قابل تکرار، مجموعه ی آموزش علاوه بر حالت تصادفی، به صورت غیر تصادفی نیز برای محاسبه ی معیارهای ارزیابی مورد استفاده قرار گرفته است. تعداد کل نمونه های آموزشی برابر با $N = 50,000$ و تعداد کلاس ها برابر با $C = 10$ می باشد.

¹Tensor

²Batch size

۳.۱.۴ هدف از انتخاب مجموعه داده‌ها

استفاده‌ی هم‌زمان از CIFAR-10 و CIFAR-100 این امکان را فراهم می‌کند تا عملکرد روش پیشنهادی در شرایطی با تعداد کلاس کم و توزیع ساده‌تر، و همچنین در شرایط پیچیده‌تر با تعداد کلاس بالا و عدم قطعیت بیشتر، به‌طور جامع ارزیابی شود. این مقایسه نقش مؤثری در تحلیل پایداری، تعمیم‌پذیری و کارایی روش پیشنهادی هرس داده مبتنی بر عدم قطعیت پویا ایفا می‌کند.

جدول ۱.۴: خلاصه‌ی مجموعه داده‌ها و مراحل پیش‌پردازش مورد استفاده در آزمایش‌ها

Dataset	Class N	Train Samples	Data Augmentation	Normalization
CIFAR-10	۱۰	۵۰,۰۰۰	crop Random with 32×32 ؛ padding=4 Random flip horizontal	Mean (۰/۴۹۱۴, ۰/۴۸۲۲, ۰/۴۴۶۵) Std (۰/۲۴۷, ۰/۲۴۳, ۰/۲۶۱)
CIFAR-100	۱۰۰	۵۰,۰۰۰	crop Random with 32×32 ؛ padding=4 Random flip horizontal	Mean (۰/۵۰۷۱, ۰/۴۸۶۷, ۰/۴۴۰۸) Std (۰/۲۶۷۵, ۰/۲۵۶۵, ۰/۲۷۶۱)

۲.۴ کتابخانه‌ها، ابزارها و محیط اجرا

در این پژوهش، تمامی مراحل پیاده‌سازی، آموزش و ارزیابی مدل‌ها با استفاده از محیط Google Colab Pro انجام شده است. این بستر محاسباتی مبتنی بر فضای ابری، امکان دسترسی به منابع سخت‌افزاری قدرتمند و مقیاس‌پذیر را فراهم می‌کند و محدودیت‌های محاسباتی سیستم‌های محلی را کاهش می‌دهد. در طول آزمایش‌ها، از پردازنده‌های گرافیکی NVIDIA Tesla T4 و NVIDIA A100 استفاده شده است. کارت گرافیک ۴T عمدتاً برای آزمایش‌های اولیه و تنظیم ابرپارامترها^۱ به کار رفته و کارت گرافیک ۱۰۰A برای آموزش مدل‌ها در مقیاس بزرگ‌تر و با هزینه‌ی محاسباتی بالاتر مورد استفاده قرار گرفته است.

^۱Hyper parameters

چارچوب اصلی مورد استفاده برای پیاده‌سازی مدل‌های یادگیری عمیق^۱، کتابخانه‌ی PyTorch بوده است. این کتابخانه به دلیل پشتیبانی از محاسبات موازی^۲ بر روی GPU، گراف محاسباتی پویا و انعطاف‌پذیری بالا، یکی از پرکاربردترین ابزارها در پژوهش‌های یادگیری عمیق محسوب می‌شود. برای تعریف معماری شبکه‌های عصبی^۳ و پیاده‌سازی توابع هزینه و عملیات یادگیری، از زیرماژول‌های torch.nn و torch.nn.functional استفاده شده است.

به‌منظور بارگذاری، مدیریت و پیش‌پردازش مجموعه‌داده‌ها، از کتابخانه‌ی torchvision و ماژول‌های مرتبط با آن استفاده شده است. عملیات‌هایی نظیر نرمال‌سازی داده‌ها، اعمال تبدیلات داده‌ای و افزایش داده از طریق torchvision.transforms انجام شده‌اند. همچنین، برای مدیریت فرآیند آموزش و ایجاد دسته‌های داده‌ای^۴، از کلاس‌های DataLoader، Dataset و Subset موجود در torch.utils.data استفاده شده است.

برای انجام محاسبات عددی پایه و عملیات آرایه‌ای، کتابخانه‌ی NumPy به کار رفته است. علاوه بر این، ماژول‌های استاندارد زبان پایتون شامل os، math، time و glob به ترتیب برای مدیریت مسیرها و فایل‌ها، انجام محاسبات ریاضی ساده، اندازه‌گیری زمان اجرا و پیمایش فایل‌ها مورد استفاده قرار گرفته‌اند.

برنامه ۱.۴: کتابخانه‌های مورد استفاده در پیاده‌سازی

```
tropmi os, math, time, glob
tropmi numpy sa np
3
tropmi torch
tropmi torch.nn sa nn
tropmi torch.nn.functional sa F
7
morf torchvision tropmi datasets, transforms
morf torch.utils.data tropmi DataLoader, Dataset, Subset
10
morf tqdm tropmi tqdm
```

۳.۴ مدل‌های مورد استفاده

به‌منظور انجام مقایسه‌ای منصفانه و هم‌راستا با تنظیمات تجربی مقاله‌ی مرجع [۷۲]، در این پژوهش از مجموعه‌ای از معماری‌های استاندارد و پرکاربرد در حوزه‌ی طبقه‌بندی تصویر استفاده شده است.

^۱Deep learning

^۲Parallel computing

^۳Nueral Networks

^۴Mini-batch

انتخاب این مدل‌ها به‌طور مستقیم بر اساس مدل‌های به‌کاررفته در مقاله‌ی مذکور صورت گرفته تا امکان بازتولید نتایج و ارزیابی دقیق عملکرد روش پیشنهادی فراهم شود. در این راستا، معماری‌های ResNet-18، ResNet-50 و ConvNeXt به‌عنوان مدل‌های پایه در نظر گرفته شده و تمامی آن‌ها تحت شرایط آموزشی یکسان آموزش داده شده‌اند.

۱.۳.۴ ResNet-18

معماری ResNet-18 [۳۱] یکی از نمونه‌های کلاسیک شبکه‌های باقی‌مانده^۱ است که برای رفع مشکل ناپدید شدن گرادیان^۲ در شبکه‌های عمیق معرفی شده است. این شبکه از بلوک‌های باقی‌مانده شامل دو لایه‌ی کانولوشن متوالی^۳ بهره می‌برد که توسط اتصالات میان‌برهویی^۴ به یکدیگر متصل شده‌اند. این ساختار امکان یادگیری نگاشت‌های باقی‌مانده را فراهم می‌کند و موجب تسهیل فرآیند بهینه‌سازی می‌شود. به دلیل عمق نسبتاً کم، تعداد پارامترهای محدود و هزینه‌ی محاسباتی پایین، ResNet-18 به‌عنوان یک خط پایه مناسب برای تحلیل رفتار روش پیشنهادی در شرایط منابع محدود انتخاب شده است.

۲.۳.۴ ResNet-50

مدل ResNet-50 [۳۱] نسخه‌ی عمیق‌تر خانواده‌ی شبکه‌های باقی‌مانده بوده و از بلوک‌های Bottleneck Residual متشکل از سه لایه‌ی کانولوشن با ساختار 1×1 ، 3×3 و 1×1 استفاده می‌کند. این طراحی امکان افزایش عمق شبکه تا ۵۰ لایه را بدون افزایش چشمگیر تعداد پارامترها فراهم می‌سازد و در نتیجه ظرفیت نمایش مدل را به‌طور قابل توجهی افزایش می‌دهد. در مقایسه با ResNet-18، این معماری قادر به استخراج ویژگی‌های سطح بالاتر و الگوهای پیچیده‌تر تصویری است. استفاده از ResNet-50 در این پژوهش با هدف بررسی تأثیر روش روش پیشنهادی هرس داده در شرایطی صورت گرفته است که مدل از پیچیدگی و ظرفیت بالاتری برخوردار است. بدین ترتیب، امکان تحلیل پایداری و اثربخشی روش پیشنهادی در شبکه‌های عمیق‌تر فراهم شده و می‌توان میزان وابستگی عملکرد روش به پیچیدگی معماری مدل را به‌صورت دقیق ارزیابی کرد.

۳.۳.۴ ConvNeXt

معماری ConvNeXt نمایانگر یک شبکه‌ی عصبی کانولوشنی^۵ مدرن است که با هدف ارتقاء کارایی شبکه‌های کانولوشنی سنتی و مقابله با مدل‌های نوظهور مبتنی بر ترنسفورمر^۶ طراحی شده

¹Residual Neural Networks

²Vanishing gradient

³Sequential convolutional layer

⁴Identity Skip Connections

⁵Convolutional Neural Network, CNN

⁶Transformer

است [۴۲]. برخلاف بسیاری از شبکه‌های کانولوشنی قدیمی، ConvNeXt با بازنگری سیستماتیک طراحی ساختارها، از مفاهیمی الهام گرفته از معماری‌های ترنسفورمر بهره می‌برد تا عملکرد و بازدهی شبکه را بهبود بخشد. این طراحی شامل استفاده از بلوک‌های کانولوشنی مدرن با هسته‌های بزرگ‌تر، جایگزینی نرمال‌سازی دسته‌ای^۱ با نرمال‌سازی لایه‌ای^۲ و به کارگیری تابع فعال‌سازی GELU است که موجب بهبود پایداری آموزش و افزایش قدرت استخراج ویژگی‌ها می‌شود، در حالی که ساختار شبکه همچنان کاملاً کانولوشنی باقی می‌ماند.

یکی از ویژگی‌های برجسته‌ی ConvNeXt این است که با حفظ مزایای محاسباتی شبکه‌های کانولوشنی، ظرفیت بالایی برای استخراج ویژگی‌های پیچیده ارائه می‌دهد و در بسیاری از بنچمارک‌های طبقه‌بندی تصویر^۳ نتایج رقابتی با مدل‌های ترنسفورمر نشان داده است [۴۲].

استفاده از ConvNeXt در این پژوهش با هدف بررسی تأثیر روش حذف داده‌ها روی مدل‌های ارتقا یافته و پیچیده‌تر انتخاب شده است. با توجه به ظرفیت نمایش بالاتر و پیچیدگی بیشتر این مدل نسبت به شبکه‌های کلاسیک‌تر مانند ResNet-50، امکان تحلیل دقیق‌تر اثربخشی و پایداری روش پیشنهادی در معماری‌های مدرن فراهم می‌شود. بنابراین، ConvNeXt نیز به عنوان یکی از مدل‌های پایه برای آزمایش‌ها در نظر گرفته شده است.

۴.۴ نتایج به تفکیک مجموعه داده

در ادامه‌ی این فصل، نتایج حاصل از آزمایش‌ها به صورت تفکیک شده برای هر مجموعه داده ارائه می‌شود. برای هر مجموعه داده، عملکرد مدل‌های مختلف مورد بررسی قرار گرفته و نتایج به دست آمده با سایر روش‌های حذف داده‌ها مقایسه می‌گردد. همچنین، تأثیر تنظیم ابرپارامترها بر عملکرد روش پیشنهادی و مدل‌های مورد استفاده به طور دقیق تحلیل و گزارش خواهد شد.

۱.۴.۴ نتایج دیتاست CIFAR-100

در این بخش، نتایج آزمایش‌های انجام شده بر روی مجموعه داده‌ی CIFAR-100 ارائه و تحلیل می‌شود. به منظور ارزیابی دقیق روش پیشنهادی، مدل ResNet-18 به عنوان معماری پایه انتخاب شده و عملکرد آن با مجموعه‌ای از روش‌های متداول حذف داده‌ها که در مقاله‌ی مرجع [۷۲] گزارش شده‌اند، شامل روش‌های Entropy [۱۶]، Forgetting [۶۷]، EL2N [۵۰]، AUM [۵۳] و Moderate [۷۰] می‌باشند، مقایسه شده است. این ارزیابی شامل بررسی دقت طبقه‌بندی در نسبت‌های مختلف حذف داده، میزان پایداری مدل در شرایط حذف شدید داده و مقایسه‌ی مستقیم با روش‌های مقاله‌های مرجع [۷۲، ۳۲] یعنی Uncertainty Dynamic و TDDS می‌باشد.

¹Batch Normalization

²Layer Normalization

³Image Classification

در گام نخست، مدل ResNet-18 به صورت کامل بر روی مجموعه داده‌ی CIFAR-100 آموزش داده شد. این مرحله که به عنوان فاز اول در نظر گرفته می‌شود، صرفاً با هدف محاسبه‌ی معیارهای حذف داده انجام شده و به مدت ۱۰۰ دوره آموزش^۱ اجرا گردید. در طول این فاز، مقادیر لاجیت هر نمونه در تمامی اپیک‌ها ذخیره شد تا امکان محاسبه‌ی معیارهای پویا و وابسته به زمان فراهم شود.

پس از پایان فاز اول، نمونه‌ها بر اساس معیارهای عدم قطعیت پویا وزن‌دار^۲ و امتیازدهی دو عمقی زمانی هموار شده^۳، امتیازدهی و رتبه‌بندی شدند. در این مرحله، پارامترهای کنترلی k و j به ترتیب برای تعیین پنجره‌های زمانی امتیازدهی و شدت انتخاب نمونه‌ها مورد استفاده قرار گرفتند، به گونه‌ای که پویایی تغییرات عدم قطعیت در طول آموزش به صورت دقیق مدل‌سازی شود.

بر اساس امتیازهای محاسبه شده، زیرمجموعه‌هایی از داده‌ها با نسبت‌های حذف^۴ (۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪) انتخاب گردید. سپس مدل تنها با استفاده از داده‌های نگه‌داشته شده وارد فاز دوم شد و برای مدت ۲۰۰ دوره آموزش، مجدداً آموزش داده شد.

تنظیمات آموزشی در هر دو فاز کاملاً منطبق با مقاله‌ی پایه [۷۲] انتخاب شده‌اند تا مقایسه‌ای منصفانه و قابل تکرار میان روش‌ها تضمین شود. به طور مشخص، آموزش با اندازه‌ی دسته ۱۲۸، نرخ یادگیری اولیه^۵ ۰/۱، بهینه‌ساز SGD^۶ با مومنتوم^۷ ۰/۹ و ضریب منظم‌سازی وزن^۸ $10^{-4} \times 5$ انجام شده است. میانگین‌گیری نمایی^۹ پارامترها با ضریب ۰/۹ به کار گرفته شده است. همچنین، نسبت حذف داده برای آزمایش‌ها در مقادیر مختلف تنظیم شده و عامل وزنی اهمیت^{۱۰} نمونه‌ها در فرآیند حذف برابر با ۱ در نظر گرفته شده است. لازم به ذکر است که برای هر یک از نسبت‌های حذف داده (۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪)، مدل به صورت کاملاً مستقل و از ابتدا بر روی مجموعه داده آموزش داده شده است. بدین ترتیب، هر مقدار حذف داده منجر به یک اجرای جداگانه از مدل شده و نتایج حاصل از این اجراهای مستقل در جدول ۳.۴ قابل مشاهده است.

جدول ۳.۴ نتایج دقت طبقه‌بندی حاصل از این آزمایش‌ها را بر روی مجموعه داده‌ی CIFAR-100 و با معماری ResNet-18 در مقایسه با سایر روش‌های حذف داده نشان می‌دهد.

مطابق نتایج جدول ۳.۴، روش‌های مبتنی بر معیارهای ایستا نظیر Entropy [۱۶]، EL2N [۵۰] و AUM [۵۳] با افزایش نسبت حذف داده، افت شدیدی در دقت طبقه‌بندی تجربه می‌کنند؛ به طوری که در نسبت‌های بالای حذف (۷۰٪ و ۸۰٪) عملکرد آن‌ها به طور قابل توجهی کاهش می‌یابد. این امر نشان می‌دهد که این روش‌ها در شناسایی نمونه‌های پراطلاع در شرایط حذف شدید داده با محدودیت

^۱Epochs

^۲Dynamic weighted uncertainty

^۳Temporally Smoothed Dual-Depth Scoring

^۴Pruning ratio

^۵Initial learning rate

^۶Stochastic Gradient Descent

^۷Momentum

^۸Weight decay

^۹Exponential Moving Average (EMA)

^{۱۰}Importance weight factor

جدول ۳.۴: دقت طبقه‌بندی مدل ResNet-18 روی مجموعه داده‌ی CIFAR-100 در نسبت‌های مختلف حذف داده

Method	۳۰٪	۵۰٪	۷۰٪	۸۰٪
Random	۷۵.۵۳	۷۱.۹۵	۶۴.۵۹	۵۷.۷۹
Entropy [16]	۷۲.۳۹	۶۴.۴۴	۵۰.۷۳	۴۲.۸۶
Forgetting [67]	۷۷.۳۸	۷۰.۷۶	۴۹.۹۲	۳۸.۴۲
EL2N [50]	۷۶.۸۹	۶۷.۵۷	۳۶.۴۵	۱۷.۳۱
AUM [53]	۷۷.۳۵	۶۸.۱۷	۳۱.۶۹	۱۸.۴۳
Moderate [70]	۷۴.۶۰	۷۰.۲۹	۶۲.۸۱	۵۶.۵۲
Dyn-Unc [32]	۷۳.۳۶	۶۵.۹۰	۵۰.۱۶	۳۹.۱۹
TDDS [72]	۷۷.۵۶	۷۴.۰۴	۶۷.۷۸**	۶۳.۰۱**
TD-DyUn(Ours)	۷۸.۴۶**	۷۴.۹۵**	۶۵.۴۷*	۵۵.۷۰*


مواجه هستند.

در مقایسه با این روش‌ها، روش Dynamic Uncertainty [۳۲] عملکرد پایدارتری نسبت به روش‌های ایستا نشان می‌دهد، اما همچنان در نسبت‌های بالای حذف داده افت دقت قابل توجهی دارد. به عنوان مثال، دقت Dyn-Unc در نسبت حذف ۸۰٪ به ۳۹/۱۹٪ کاهش می‌یابد. این کاهش شدید نشان می‌دهد که تنها در نظر گرفتن نوسانات عدم قطعیت بدون مدل‌سازی دقیق رفتار زمانی نمونه‌ها برای حفظ عملکرد مدل کافی نیست و نمونه‌های مهم ممکن است به اشتباه حذف شوند.

در مقابل، روش TDDS [۷۲]، با مدل‌سازی تغییرات زمانی logits و تمرکز بر نمونه‌هایی با رفتار آموزشی پایدار، به طور قابل توجهی پایداری بیشتری در تمامی نسبت‌های حذف داده نشان می‌دهد. حتی در نسبت حذف ۸۰٪، TDDS موفق شده است دقت ۶۳/۰۱٪ را حفظ کند که اختلاف قابل توجهی با Dyn-Unc و سایر روش‌های ایستا دارد. برای مقایسه، دقت اصلی مدل ResNet-18 روی مجموعه داده‌ی CIFAR-100 بدون حذف داده برابر با ۷۸/۲۱٪ است [۷۲]، بنابراین TDDS

با حذف ۸۰٪ داده هنوز بیش از ۶۰٪ دقت اصلی مدل را حفظ کرده است. روش پیشنهادی TD-DyUn، در نسبت‌های حذف پایین و متوسط (۳۰٪ و ۵۰٪) بهترین عملکرد را در میان تمامی روش‌ها ارائه می‌دهد. دقت TD-DyUn به ترتیب در حذف ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪ برابر با ۷۸/۴۶٪، ۷۴/۹۵٪، ۶۵/۴۷٪ و ۵۵/۷۰٪ است. این موضوع نشان می‌دهد که ادغام اطلاعات دینامیک تغییرات logits و تحلیل تغییرات زمانی نمونه‌ها امکان شناسایی دقیق‌تر نمونه‌های کلیدی در مراحل اولیه حذف داده را فراهم می‌کند. حتی در نسبت‌های حذف بسیار بالا (۷۰٪ و ۸۰٪)، اگرچه دقت TD-DyUn اندکی نسبت به TDDS کاهش می‌یابد، اما همچنان به طور معناداری بهتر از Dyn-Unc و سایر روش‌های مقایسه‌ای باقی می‌ماند و حفظ عملکرد بالای آن نشان‌دهنده پایداری روش پیشنهادی است.

به طور کلی، نتایج این بخش نشان می‌دهد که TD-DyUn نه تنها نسبت به روش‌های کلاسیک حذف داده برتری دارد، بلکه در مقایسه مستقیم با روش‌های پایه Dyn-Unc و TDDS نیز عملکرد رقابتی و پایداری بالاتری، به ویژه در نسبت‌های حذف پایین و متوسط، ارائه می‌دهد. این امر مؤید اثرگذاری ترکیب معیارهای پویا و تحلیل تغییرات زمانی برای انتخاب نمونه‌های مهم و مناسب بودن روش پیشنهادی در سناریوهای حذف داده در مقیاس‌های مختلف است.



شکل ۱.۴: مقایسه دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 در حالت آموزش با کل داده‌ها و آموزش با نسبت‌های مختلف حذف داده با استفاده از روش TD-DyUn.

همان‌طور که در شکل ۱.۴ مشاهده می‌شود، روش TD-DyUn حتی با حذف ۳۰٪ از داده‌های آموزشی، عملکردی قابل مقایسه با آموزش بر روی کل داده‌ها ارائه می‌دهد. با افزایش نسبت حذف داده، دقت مدل به صورت تدریجی کاهش می‌یابد، اما همچنان روند افت عملکرد کنترل‌شده و پایدار باقی می‌ماند، که نشان‌دهنده توانایی این روش در حذف مؤثر داده‌های کم‌اهمیت و مقاوم‌بودن در برابر کاهش حجم داده‌های آموزشی است.

۲.۱.۴.۴ تأثیر تغییرات ابرپارامترها

برای تحلیل حساسیت مدل به تنظیم ابرپارامترها، مقادیر مختلفی از پارامترهای کلیدی α ، k و β بررسی شد. این پارامترها نقش مهمی در محاسبه‌ی امتیاز نمونه‌ها و انتخاب زیرمجموعه‌ی نگه‌داشته شده دارند.

تحلیل اثر پارامترهای کنترلی روش TD-DyUn

در روش TD-DyUn، پارامترهای k و j نقش کلیدی در کنترل فرآیند امتیازدهی پویا و انتخاب نمونه‌ها برای حذف داده ایفا می‌کنند. به‌طور مشخص، پارامتر j تعیین‌کننده‌ی طول پنجره‌ی زمانی برای تجمیع اطلاعات عدم قطعیت و محاسبه‌ی معیارهای پویا است، در حالی که پارامتر k شدت و گستره‌ی انتخاب نمونه‌ها را در فرآیند رتبه‌بندی و حذف داده مشخص می‌کند.

پارامتر j با تعیین تعداد دوره‌های آموزشی که در آن‌ها تغییرات logits و عدم قطعیت نمونه‌ها مورد بررسی قرار می‌گیرد، بر میزان پایداری زمانی معیار TD-DyUn اثر مستقیم دارد. مقادیر کوچک‌تر j منجر به واکنش سریع‌تر معیار به نوسانات آموزشی می‌شوند، اما می‌توانند نسبت به نویزهای گذرا حساس باشند؛ در مقابل، مقادیر بزرگ‌تر j باعث هموارسازی بیش از حد و کاهش توان تفکیک نمونه‌های سالم از نویزی می‌شوند. در تمامی آزمایش‌های این بخش، مقدار j ثابت در نظر گرفته شده تا اثر پارامتر k به‌صورت ایزوله مورد بررسی قرار گیرد.

پارامتر k مستقیماً با میزان سخت‌گیری در انتخاب نمونه‌ها برای حذف داده مرتبط است. مقادیر کوچک‌تر k منجر به انتخاب محافظه‌کارانه‌تر نمونه‌ها و تمرکز بیشتر بر نمونه‌هایی با عدم قطعیت بالا و پایداری می‌شود، در حالی که مقادیر بزرگ‌تر k دامنه‌ی وسیع‌تری از نمونه‌ها را شامل شده و احتمال ورود نمونه‌های نویزی به مجموعه‌ی آموزش را افزایش می‌دهد. این مسئله به‌ویژه در نرخ‌های بالای نویز برچسب اهمیت بیشتری پیدا می‌کند.


برای بررسی دقیق اثر پارامتر k ، آزمایش‌هایی بر روی مجموعه‌داده‌ی CIFAR-100 با معماری ResNet-18 و برای دو مقدار متفاوت $k = 20$ و $k = 30$ انجام شده است. نتایج حاصل در جدول ۴.۴ گزارش شده‌اند.

جدول ۴.۴: تأثیر پارامتر k بر عملکرد روش TD-DyUn بر روی مجموعه‌داده‌ی CIFAR-100 با معماری ResNet-18

مجموعه‌داده	مدل	۳۰٪	۵۰٪	۷۰٪	۸۰٪
CIFAR-100	TD-DyUn ($k = 10$)	۷۸/۴۶	۷۴/۹۵	۶۵/۴۷	۵۵/۷۰
CIFAR-100	TD-DyUn ($k = 20$)	۷۸/۸۶	۷۵/۱۵	۶۷/۹۵	۶۳/۵۴
CIFAR-100	TD-DyUn ($k = 30$)	۷۸/۸۲	۷۴/۸۷	۶۱/۶۳	۵۵/۶۰

مطابق با نتایج جدول ۴.۴، در نرخ‌های حذف پایین (۳۰٪ و ۵۰٪) اختلاف عملکرد میان دو مقدار k ناچیز است، که نشان می‌دهد در شرایط نرخ حذف محدود، TD-DyUn نسبت به مقدار k حساسیت کمتری دارد. با این حال، با افزایش نرخ حذف به ۷۰٪ و ۸۰٪، تفاوت عملکرد به صورت معنادار افزایش می‌یابد. به طور مشخص، مقدار $k = 20$ در نرخ حذف ۸۰٪ بیش از ۱۰ واحد درصد عملکرد بهتری نسبت به $k = 30$ ارائه می‌دهد.

این نتایج نشان می‌دهد که انتخاب مقادیر بزرگ‌تر برای k در شرایط نرخ حذف شدید منجر به تضعیف توان مدل در تفکیک نمونه‌های سالم از نمونه‌های دارای برچسب نادرست می‌شود. در مقابل، تنظیم محافظه کارانه‌ی k در کنار مقدار مناسب برای j باعث افزایش پایداری معیار TD-DyUn و بهبود مقاومت مدل در برابر نویز برچسب می‌گردد.




شکل ۲.۴: تحلیل پارامتر اندازه پنجره k بر عملکرد مدل ResNet-18 روی مجموعه داده CIFAR-100. خطوط نمودار مربوط به مقادیر مختلف k هستند (مثلث: $k = 10$ ، دایره: $k = 20$ ، مربع: $k = 30$) و عملکرد مدل را در نرخ‌های مختلف حذف داده نشان می‌دهند.

تأثیر مقادیر مختلف α

پارامتر α نقش کلیدی در ترکیب دو معیار عدم قطعیت پویا و وزن دار و امتیازدهی دو عمقی زمانی هموار شده برای انتخاب نمونه‌ها پس از آموزش کامل مدل دارد. این دو معیار با هم ترکیب می‌شوند تا نمونه‌هایی که هم دارای عدم قطعیت لحظه‌ای بالا و هم تغییرات طولانی مدت پیش‌بینی قابل توجهی هستند، بیشتر برجسته شوند. تحلیل اثر α :

● $\alpha = 0$: تنها معیار امتیازدهی دو عمقی زمانی هموار شده نقش دارد و وزن‌دهی به نوسانات لحظه‌ای مدل نادیده گرفته می‌شود. در این حالت، نمونه‌ها بر اساس تغییرات طولانی مدت مدل



شکل ۳.۴: نمودار Heatmap نشان‌دهنده دقت مدل TD-DyUn با معماری ResNet-18 روی مجموعه داده CIFAR-100 برای مقادیر مختلف پنجره k و نرخ‌های prune متفاوت است. رنگ‌ها و اعداد داخل سلول‌ها دقت (%) مدل را نشان می‌دهند.

انتخاب می‌شوند و حساسیت به نویز لحظه‌ای کاهش می‌یابد، اما ممکن است نمونه‌های با عدم قطعیت واقعی کمتر نادیده گرفته شوند.

- $\alpha = 1$: تنها عدم قطعیت پویا وزن دار اهمیت دارد و معیار امتیازدهی دو عمقی زمانی هموار شده حذف می‌شود. نمونه‌هایی که مدل نسبت به آن‌ها بیشترین عدم قطعیت لحظه‌ای را دارد برجسته می‌شوند. این حالت تمرکز روی نمونه‌های «مشکل دار» را افزایش می‌دهد اما حساسیت بالایی به نویز لحظه‌ای و نوسانات کوتاه مدت دارد.

- مقادیر میانی $0 < \alpha < 1$: ترکیب همزمان دو معیار باعث تعادل می‌شود. نمونه‌هایی که هم دارای عدم قطعیت لحظه‌ای هستند و هم تغییرات بلندمدت بالایی دارند، بیشتر انتخاب می‌شوند. مقدار $\alpha = 0.5$ اغلب بهترین عملکرد را نشان می‌دهد و تعادل بهینه بین دو معیار ایجاد می‌کند.

پس از محاسبه اهمیت نمونه‌ها، مقادیر آن نرمال سازی شده و تعداد مشخصی از نمونه‌ها با بیشترین اهمیت حفظ می‌شوند. در مرحله بازآموزی^۱ هر نمونه با وزن متناسب با اهمیت آن در محاسبه تابع زیان استفاده می‌شود. بنابراین α تأثیر مستقیمی بر اهمیت نمونه‌ها در مرحله دارد.

نتایج تجربی: جدول ۵.۴ نشان‌دهنده تأثیر مقادیر مختلف α بر دقت نهایی مدل ResNet-18 روی مجموعه داده CIFAR-100 برای دو نرخ حذف متفاوت (۳۰٪ و ۸۰٪) است. مقادیر نشان‌دهنده دقت (%) مدل پس از حذف داده و بازآموزی اهمیت وزن دار است.

¹Retrain

جدول ۵.۴: تأثیر α بر دقت مدل ResNet-18 روی CIFAR-100 با نرخ‌های حذف مختلف.

value- α	%۳۰	%۸۰
۰	۵۵/۶۵	۴۹/۶۳
۰/۳	۷۸/۷۰	۵۴/۲۶
۰/۵	۷۸/۸۶	۶۳/۵۴
۰/۷	۷۸/۶۲	۵۱/۸۳
۱	۴۵/۷۵	۳۹/۵۴


مقادیر میانی $\alpha \approx ۰/۵$ عملکرد بهینه را ارائه می‌کنند و بالاترین دقت در هر دو نرخ حذف مشاهده می‌شود. افزایش α بیش از حد باعث تمرکز زیاد روی نمونه‌های نامطمئن لحظه‌ای و کاهش دقت به ویژه در نرخ‌های حذف بالا می‌شود. کاهش α نزدیک به صفر اثر معیار امتیازدهی دوعمقی زمانی هموارشده را تقویت می‌کند، اما عدم توجه به عدم قطعیت لحظه‌ای موجب کاهش دقت در نرخ‌های حذف پایین می‌شود. این تحلیل نشان می‌دهد که α پارامتری حیاتی برای تعادل بین اطلاعات لحظه‌ای و بلندمدت مدل است و تنظیم دقیق آن تأثیر مستقیم بر انتخاب نمونه‌ها و عملکرد نهایی مدل دارد.

تأثیر مقادیر مختلف β

پارامتر β به عنوان یک عامل هموارکننده^۱ در محاسبه‌ی امتیازدهی دوعمقی زمانی هموارشده عمل می‌کند و کنترل می‌کند که تغییرات زمانی logits چه میزان در شاخص امتیازدهی دوعمقی زمانی مؤثر باشند. به طور دقیق، امتیازدهی دوعمقی زمانی هموارشده در این روش به صورت یک ترکیب نمایی از واریانس اختلاف KL بین پیش‌بینی‌های متوالی محاسبه می‌شود، به طوری که مقدار β مشخص می‌کند که چقدر پیش‌بینی‌های گذشته بر مقدار فعلی تأثیرگذار باشند:

مقادیر پایین در β (نزدیک ۰)، حساسیت این معیار به تغییرات لحظه‌ای بالاست و حتی نوسانات کوتاه‌مدت logits می‌توانند این شاخص را تحت تأثیر قرار دهند. این باعث می‌شود نمونه‌هایی که مدل نسبت به آن‌ها تغییرات سریع پیش‌بینی دارد برجسته شوند، ولی احتمال انتخاب نمونه‌های نویزی افزایش می‌یابد و دقت در نرخ‌های حذف بالاتر کاهش می‌یابد. در مقادیر میانی β (۸۵.۰-۹۰.۰)، تعادل بین حساسیت به تغییرات کوتاه‌مدت و تأکید بر تغییرات بلندمدت برقرار می‌شود. نمونه‌هایی که هم تغییرات کوتاه‌مدت و هم نوسانات بلندمدت معنی‌دار دارند، به طور بهینه برجسته می‌شوند و عملکرد مدل در هر سه نرخ حذف بهبود می‌یابد. مقادیر بالای β (۹۵.۰ یا بیشتر)، هموارسازی شدید رخ می‌دهد و این شاخص بیشتر بر تغییرات بلندمدت تمرکز می‌کند. نمونه‌هایی که تغییرات پیش‌بینی طولانی‌مدت دارند برجسته می‌شوند و حساسیت به نوسانات کوتاه‌مدت کاهش می‌یابد، که

¹Smoothing Factor




شکل ۴.۴: نمودار نشان‌دهنده تأثیر مقادیر مختلف α بر دقت مدل ResNet-18 روی مجموعه داده CIFAR-100 برای دو نرخ حذف متفاوت (۳۰٪ و ۸۰٪) است. بیشترین دقت در مقادیر میانی $\alpha \approx 0.5$ مشاهده می‌شود.

به ویژه در حذف شدید (مثلاً ۷۰٪) مفید است. در مرحله حذف، تعداد نمونه‌های حفظ شده بر اساس این معیار با وزن‌دهی β انتخاب می‌شوند و در مرحله بازآموزی، هر نمونه اهمیت خود را بر اساس شاخص امتیازدهی دوعمقی زمانی هموارشده و وزن‌دهی ترکیبی دریافت می‌کند. بنابراین β تأثیر مستقیمی بر انتخاب نمونه‌ها و عملکرد نهایی مدل دارد.

جدول ۶.۴ مقادیر دقت نهایی مدل ResNet-18 روی مجموعه داده CIFAR-100 را برای سه نرخ حذف مختلف (۳۰٪، ۵۰٪ و ۷۰٪) و مقادیر متفاوت β نشان می‌دهد. این نتایج مربوط به مرحله حذف و بازآموزی با اهمیت‌وزن‌دار هستند.

همان‌گونه که در شکل ۶.۴ مشاهده می‌شود، پارامتر β نقش مهمی در تنظیم پایداری معیار TD-DyUn ایفا می‌کند. افزایش مقدار β تا حدود ۰/۹ موجب بهبود دقت مدل در تمامی نرخ‌های حذف داده می‌شود، در حالی که مقادیر بزرگ‌تر از آن منجر به افت نسبی عملکرد، به‌ویژه در نرخ‌های بالاتر پرونینگ، می‌گردد. این نتایج نشان می‌دهد که مقدار $\beta = 0.9$ انتخابی مناسب برای دستیابی به توازن میان هموارسازی و حساسیت معیار پیشنهادی است.

نمودار ۷.۴ نشان می‌دهد که مقادیر میانی β (۸۵.۰ و ۹۰.۰) عموماً دقت بالاتری در تمام نسبت‌های حذف ارائه می‌کنند، که نشان‌دهنده این است که هموارسازی معیار امتیازدهی دوعمقی زمانی باعث بهبود انتخاب نمونه‌ها و افزایش پایداری مدل پس از حذف می‌شود. مقادیر بسیار پایین ($\beta = 0$) یا بسیار بالا ($\beta = 0.95$) یا هموارسازی زمانی را نادیده می‌گیرند یا سیگنال را بیش از حد



شکل ۵.۴: تأثیر پارامتر α بر دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 برای نرخ‌های مختلف حذف داده در روش TD-DyUn.

جدول ۶.۴: تأثیر β بر دقت مدل ResNet-18 روی CIFAR-100 برای نرخ‌های prune مختلف.


value- β	۳۰٪	۵۰٪	۷۰٪
۰	۷۶/۳۳	۷۳/۰۶	۶۲/۵۷
۰/۸۵	۷۸/۱۷	۷۴/۹۰	۶۵/۶۶
۰/۹	۷۸/۸۶	۷۵/۱۵	۶۷/۹۵
۰/۹۵	۷۸/۸۵	۷۴/۸۴	۶۵/۰۳

هموار می‌کنند که می‌تواند باعث کاهش جزئی دقت شود. این تحلیل اهمیت تنظیم صحیح ضریب کاهش β برای تعادل بین پاسخ‌دهی به logits اخیر و ثبات روند بلندمدت را نشان می‌دهد.

۲.۴.۴ نتایج دیتاست CIFAR-10

۱.۲.۴.۴ نتایج روی مدل ResNet-18

به منظور ارزیابی جامع و منصفانه‌ی عملکرد روش پیشنهادی TD-DyUn بر روی مجموعه داده‌ی CIFAR-10، دقیقاً همان پروتکل آزمایشی مورد استفاده در آزمایش‌های مربوط به CIFAR-10 به کار گرفته شده است. بدین ترتیب، هرگونه تفاوت مشاهده شده در نتایج صرفاً ناشی از ویژگی‌های ذاتی مجموعه داده و رفتار روش حذف داده بوده و تأثیر تنظیمات آموزشی به حداقل می‌رسد.



شکل ۶.۴: تأثیر پارامتر β بر دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 برای نرخ‌های مختلف حذف داده در روش TD-DyUn.

در این راستا، مدل ResNet-18 ابتدا به صورت کامل و بدون حذف داده به مدت ۱۰۰ دوره آموزش بر روی مجموعه‌ی آموزشی CIFAR-100 آموزش داده شد. در طول این فاز، خروجی‌های خام شبکه مربوط به تمامی نمونه‌ها در هر دوره آموزش ذخیره گردید تا امکان محاسبه‌ی دقیق معیارهای پویای مبتنی بر عدم قطعیت فراهم شود. این logits ذخیره‌شده مبنای محاسبه‌ی معیار عدم قطعیت پویای وزن‌دار و همچنین معیار امتیازدهی دو عمقی زمانی هموارشده در روش پیشنهادی TD-DyUn قرار گرفتند.


برای تضمین مقایسه‌ای منصفانه با روش‌های پیشین، لازم به تأکید است که دقت مدل پایه‌ی ResNet-18 بر روی مجموعه داده‌ی CIFAR-100 بدون اعمال هیچ‌گونه حذف داده، مطابق گزارش ارائه‌شده در [۷۲] برابر با ۹۵/۲۳٪ است. این مقدار به عنوان خط مبنا^۱ در نظر گرفته شده و تمامی نتایج حاصل از حذف داده نسبت به آن تفسیر می‌شوند.

پس از اتمام فاز نخست آموزش و محاسبه‌ی امتیاز هر نمونه، داده‌های آموزشی بر اساس امتیاز ترکیبی TD-DyUn به صورت نزولی رتبه‌بندی شدند. سپس، برای نسبت‌های مختلف حذف داده شامل ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪، زیرمجموعه‌های متناظر از داده‌ها انتخاب شده و برای هر نسبت حذف، یک اجرای مستقل از مدل انجام گرفت. در هر یک از این اجراها، مدل ResNet-18 تنها با استفاده از داده‌های نگه‌داری شده به مدت ۲۰۰ دوره آموزش، مجدداً آموزش داده شد.

شایان ذکر است که تمامی تنظیمات آموزشی، از جمله اندازه‌ی دسته، نرخ یادگیری اولیه، بهینه‌ساز SGD با مومنتوم، ضریب منظم‌سازی وزن، میانگین‌گیری وزنی پارامترها و همچنین تکنیک‌های افزایش

¹Baseline

Effect of Beta on Accuracy for Different Prune Ratios (ResNet-18, CIFAR-100)



شکل ۷.۴: تأثیر ضریب کاهش β بر دقت مدل ResNet-18 روی مجموعه داده CIFAR-100 برای نسبت‌های حذف مختلف. هر نمودار جزئی مربوط به یک نسبت حذف مشخص (۵۰٪، ۳۰٪، ۷۰٪) است و چهار میله در هر نمودار نشان‌دهنده مقادیر β برابر با ۰، ۰/۸۵، ۰/۹ و ۰/۹۵ هستند. ارتفاع هر میله دقت طبقه‌بندی پس از حذف داده و بازآموزی با وزن‌دهی اهمیت نمونه‌ها را نشان می‌دهد.

داده، دقیقاً مطابق با تنظیمات گزارش شده در مقاله مرجع [۷۲] انتخاب شده‌اند. این رویکرد تضمین می‌کند که مقایسه‌ی انجام شده میان روش پیشنهادی و سایر روش‌های حذف داده، قابل تکرار، منصفانه و از نظر تجربی معتبر باشد.

جدول ۷.۴ نتایج دقت طبقه‌بندی حاصل از روش پیشنهادی را در مقایسه با روش‌های مختلف حذف داده بر روی مجموعه داده‌ی CIFAR-100 نشان می‌دهد.

مطابق جدول ۷.۴ و شکل ۸.۴، روش پیشنهادی TD-DyUn در تمامی نسبت‌های حذف داده عملکردی پایدار و رقابتی از خود نشان می‌دهد. به‌طور مشخص، در نرخ حذف ۳۰٪، دقت مدل به ۹۶/۰۳٪ می‌رسد که نه تنها افتی نسبت به مدل پایه بدون حذف داده (۹۵/۲۳٪) نشان نمی‌دهد، بلکه بهبود مطلق ۰/۸٪ را نیز به همراه دارد. این رفتار بیانگر حذف مؤثر نمونه‌های کم‌اطلاعات یا نویزی در مراحل اولیه آموزش است.

با افزایش نرخ حذف به ۵۰٪، دقت مدل برابر با ۹۵/۷۸٪ باقی می‌ماند که همچنان بالاتر از دقت مدل پایه گزارش شده در [۷۲] است و نشان می‌دهد که حتی با حذف نیمی از داده‌های آموزشی، روش TD-DyUn قادر به حفظ اطلاعات کلیدی موردنیاز برای تعمیم مدل است. در نرخ‌های بالاتر حذف داده، یعنی ۷۰٪ و ۸۰٪، دقت مدل به ترتیب به ۹۳/۹۱٪ و ۹۱/۶۰٪ کاهش می‌یابد؛ با این حال، این مقادیر در مقایسه با سایر روش‌های حذف داده، به‌ویژه در سناریوهای شدید کم‌داده، برتری قابل‌توجهی را نشان می‌دهند.

به‌طور کلی، نتایج عددی جدول و روند مشاهده‌شده در نمودار نشان می‌دهد که TD-DyUn با ترکیب اطلاعات عدم قطعیت پویا و پویایی تغییرات پیش‌بینی در طول زمان، قادر است نمونه‌هایی


جدول ۷.۴: دقت طبقه‌بندی مدل ResNet-18 روی مجموعه داده‌ی CIFAR-10 در نسبت‌های مختلف حذف داده

Method	۳۰٪	۵۰٪	۷۰٪	۸۰٪
Random	۹۴.۵۸	۹۳.۳۸	۹۰.۶۱	۸۸.۸۷
Entropy [16]	۹۴.۴۵	۹۱.۹۰	۸۶.۲۴	۸۳.۴۹
Forgetting [67]	۹۵.۴۵	۹۵.۰۵	۸۹.۱۴	۷۶.۱۸
EL2N [50]	۹۵.۴۳	۹۵.۰۶	۸۶.۶۹	۶۸.۶۴
AUM [53]	۹۵.۴۴	۹۵.۱۹	۹۱.۱۹	۶۹.۶۰
Moderate [70]	۹۳.۹۶	۹۲.۳۴	۸۹.۷۱	۸۷.۷۵
Dyn-Unc [32]	۹۵.۰۸	۹۴.۰۳	۸۹.۴۰	۷۹.۷۶
TDDS [72]	۹۵.۴۷	۹۵.۲۱	۹۳.۰۳**	۹۱.۳۰**
TD-DyUn(Ours)پ	۹۶.۰۳**	۹۵.۷۸**	۹۳.۹۱**	۹۱.۶۰**


را انتخاب کند که بیشترین سهم را در یادگیری مؤثر مدل دارند. این ویژگی موجب می‌شود که حتی در شرایط حذف شدید داده، افت دقت به‌صورت کنترل‌شده و تدریجی رخ دهد، که این امر TD-DyUn را به گزینه‌ای مناسب برای سناریوهای آموزش کم‌داده و کاهش هزینه‌های محاسباتی تبدیل می‌کند.

نمودار ۹.۴ نشان می‌دهد که با افزایش نسبت حذف داده، دقت همه روش‌ها کاهش می‌یابد، اما روش TD-DyUn کاهش کمتری دارد و حتی در نرخ‌های حذف بالا عملکرد پایداری ارائه می‌دهد که نشان‌دهنده توانایی این روش در حفظ نمونه‌های مهم و افزایش پایداری^۱ مدل است.

¹Robustness



شکل ۸.۴: دقت طبقه‌بندی مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-10 در نسبت‌های مختلف حذف داده با استفاده از روش پیشنهادی TD-DyUn.



شکل ۹.۴: دقت مدل ResNet-18 بر روی مجموعه داده‌ی CIFAR-10 برای نسبت‌های مختلف حذف داده در روش‌های ذکر شده. نمودار نشان می‌دهد که روش TD-DyUn کاهش دقت کمتری نسبت به سایر روش‌ها دارد و در حذف شدید داده عملکرد پایدارتری ارائه می‌دهد.

۲.۲.۴.۴ نتایج روی مدل ResNet-50

به منظور بررسی قابلیت تعمیم روش پیشنهادی TD-DyUn به مدل‌های پیچیده‌تر، آزمایشی روی معماری ResNet-50 بر روی مجموعه داده CIFAR-10 انجام شد. در این آزمایش، مدل ابتدا بر روی کل داده‌ها آموزش داده شد و خروجی‌های logits هر نمونه در هر دوره آموزش ذخیره شد تا بتوان میزان اهمیت نمونه‌ها را با استفاده از ترکیب عدم قطعیت پویا وزن‌دار و امتیازدهی دوعمقی زمانی هموارشده محاسبه کرد. تنظیمات آموزش شامل ۵۰ دوره آموزش اولیه، اندازه دسته برابر با ۶۴ اعمال شد. همچنین برای تقویت داده‌ها از برش تصادفی، چرخش افقی تصادفی استفاده شد. پس از آموزش اولیه، نمونه‌ها با اعمال نسبت‌های حذف داده مختلف شامل ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪ انتخاب شدند و مدل بر روی مجموعه نگهداری شده بازآموزی شد. وزن‌دهی اهمیت نمونه‌ها در محاسبه تابع زیان اعمال شد و بازآموزی به مدت ۱۰۰ دوره آموزش انجام شد.

نتایج دقت طبقه‌بندی مدل پس از بازآموزی در جدول ۸.۴ ارائه شده است. دقت مدل روی کل داده‌ها برابر با ۹۱/۵۶٪ بود. پس از اعمال ۳۰٪ حذف داده، دقت مدل کمی افزایش یافت و به ۹۱/۷۸٪ رسید که نشان‌دهنده توانایی روش TD-DyUn در شناسایی و نگهداری نمونه‌های حیاتی است. با افزایش نسبت حذف داده، کاهش تدریجی دقت مشاهده می‌شود، به طوری که در ۸۰٪ حذف داده، دقت مدل به ۸۶/۴۵٪ کاهش می‌یابد. این نتایج نشان می‌دهد که روش TD-DyUn حتی در شرایط حذف شدید داده‌ها، توانایی حفظ عملکرد مدل را دارد و قابلیت تعمیم به مدل‌های پیچیده‌تر مانند ResNet-50 را دارا است.


جدول ۸.۴: دقت طبقه‌بندی مدل ResNet-50 روی مجموعه داده CIFAR-10 پس از اعمال نسبت‌های مختلف حذف با روش TD-DyUn.

نسبت prune	۳۰٪	۵۰٪	۷۰٪	۸۰٪
TD-DyUn	۹۱/۷۸٪	۹۰/۳۵٪	۸۸/۵۴٪	۸۶/۴۵٪

۳.۲.۴.۴ نتایج روی مدل ConvNeXt

به منظور بررسی قابلیت تعمیم روش پیشنهادی TD-DyUn و تحلیل عملکرد مدل پیچیده‌تر ConvNeXt، آزمایشی مشابه بخش قبل انجام شد. مدل برای بررسی بیشتر آموزش دیده و تنظیمات آموزشی دقیقاً مشابه بخش قبل است. پس از آموزش اولیه، نمونه‌ها با اعمال نسبت‌های حذف داده مختلف شامل ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪ انتخاب شدند و مدل بر روی مجموعه نگهداری شده بازآموزی شد. وزن‌دهی اهمیت نمونه‌ها در محاسبه تابع زیان اعمال شد و بازآموزی به مدت ۱۰۰ دوره آموزش انجام شد.

نتایج دقت طبقه‌بندی مدل پس از بازآموزی در جدول ۹.۴ ارائه شده است. دقت مدل روی کل داده‌ها برابر با ۹۲/۵۴٪ بود. پس از اعمال ۳۰٪ حذف داده، دقت مدل کمی افزایش یافت و




شکل ۱۰.۴: دقت طبقه‌بندی مدل ResNet-50 روی مجموعه داده CIFAR-10 برای نسبت‌های مختلف حذف داده. میله اول دقت مدل روی کل داده‌ها و میله‌های بعدی دقت پس از حذف ۳۰، ۵۰، ۷۰ و ۸۰ درصد داده‌ها را نشان می‌دهند.

به ۹۲/۶۱٪ رسید که نشان‌دهنده توانایی روش TD-DyUn در شناسایی و نگهداری نمونه‌های حیاتی است. با افزایش نسبت حذف داده، کاهش تدریجی دقت مشاهده می‌شود، به طوری که در ۸۰٪ حذف داده، دقت مدل به ۸۷/۵۲٪ کاهش می‌یابد. این نتایج نشان می‌دهد که روش TD-DyUn حتی در شرایط حذف شدید داده‌ها، توانایی حفظ عملکرد مدل را دارد و قابلیت تعمیم به مدل‌های پیچیده‌تر مانند ConvNeXt را دارا است.

جدول ۹.۴: دقت طبقه‌بندی مدل ConvNeXt روی مجموعه داده CIFAR-10 پس از اعمال نسبت‌های مختلف حذف با روش TD-DyUn.

نسبت prune	۳۰٪	۵۰٪	۷۰٪	۸۰٪
TD-DyUn	۹۲/۶۱٪	۹۱/۴۶٪	۸۹/۸۱٪	۸۷/۵۲٪



شکل ۱۱.۴: دقت طبقه‌بندی مدل ConvNeXt روی مجموعه داده CIFAR-10 برای نسبت‌های مختلف حذف داده. میله اول دقت مدل روی کل داده‌ها و میله‌های بعدی دقت پس از حذف ۳۰٪، ۵۰٪، ۷۰٪ و ۸۰٪ داده‌ها را نشان می‌دهند.

فصل ۵

نتیجه گیری و جمع بندی

۱.۵ جمع بندی و نتیجه گیری

در این پایان نامه، مسئله‌ی افزایش هزینه‌های محاسباتی، زمان آموزش و مصرف منابع در مدل‌های یادگیری عمیق^۲ در اثر رشد فزاینده‌ی حجم داده‌های آموزشی مورد بررسی قرار گرفت. با توجه به این که افزایش اندازه‌ی مجموعه داده همواره منجر به بهبود متناسب عملکرد مدل نمی‌شود، هرس داده^۳ به عنوان راهکاری مؤثر برای کاهش هزینه‌های آموزش با حفظ کارایی مدل مطرح گردید. در این راستا، یک روش هرس داده‌ی پویا^۴ مبتنی بر عدم قطعیت^۵ ارائه شد که با بهره‌گیری از رفتار دینامیکی مدل در طول آموزش، به صورت تطبیقی اقدام به شناسایی و حذف داده‌های کم اهمیت می‌کند.

روش پیشنهادی بر پایه‌ی ثبت خروجی‌های مدل در طول فاز اولیه‌ی آموزش و استخراج معیارهای مبتنی بر عدم قطعیت و ناپایداری پیش‌بینی بنا شده است. سپس با استفاده از یک سازوکار امتیازدهی دو عمقی زمانی^۶، اهمیت هر نمونه در بازه‌های زمانی مختلف ارزیابی شده و فرآیند پالایش داده‌ها به صورت تدریجی انجام می‌گیرد. این پراطلاع رویکرد امکان تفکیک مؤثر نمونه‌های تکراری، ساده یا کم‌اثر از نمونه‌های پراطلاع^۷ و مؤثر در شکل‌گیری مرزهای تصمیم مدل را فراهم می‌سازد. ارزیابی‌های تجربی انجام شده بر روی مجموعه داده‌های CIFAR-10 و CIFAR-100 و مدل‌های ResNet18,50 و ConvNeXt نشان داد که روش پیشنهادی قادر است با حذف درصد قابل توجهی از داده‌های آموزشی، تنها افت دقت ناچیزی را در عملکرد نهایی مدل ایجاد کند. علاوه بر این، نتایج بیانگر پایداری مناسب فرآیند یادگیری حتی در نرخ‌های بالای هرس داده^۸ بوده و نشان می‌دهد که بازآموزی مدل بر روی زیرمجموعه‌ی منتخب داده‌ها می‌تواند عملکردی قابل مقایسه با آموزش بر روی مجموعه داده‌ی

²Deep learning

³Data pruning

⁴Dynamic

⁵Uncertainty

⁶Temporal Dual-Depth Scoring

⁷Informative

⁸Pruning ratio

کامل ارائه دهد.

تحلیل پیچیدگی زمانی و حافظه‌ای^۱ روش نیز نشان داد که سربار محاسباتی^۲ عمدتاً به فاز اولیه آموزش محدود شده و در مراحل بعدی، به دلیل کاهش اندازه داده‌ها، هزینه کلی آموزش به‌طور محسوسی کاهش می‌یابد. در مجموع، نتایج حاصل از این پژوهش نشان می‌دهد که هرس داده‌ی پویا مبتنی بر عدم قطعیت می‌تواند به‌عنوان راهکاری کارآمد و مقیاس‌پذیر برای آموزش مدل‌های یادگیری عمیق بر روی مجموعه داده‌های بزرگ^۳ مورد استفاده قرار گیرد.

۲.۵ مسیرهای آینده پژوهش

با وجود نتایج مطلوب به‌دست‌آمده در این پژوهش، روش پیشنهادی همچنان ظرفیت توسعه و بهبود در ابعاد مختلف را داراست. یکی از مهم‌ترین مسیرهای آینده، ارزیابی این روش بر روی مجموعه داده‌های بزرگ‌تر و پیچیده‌تر و همچنین به‌کارگیری آن در وظایف متنوع یادگیری ماشین^۴، از جمله تشخیص شیء^۵، بخش‌بندی تصاویر^۶ و پردازش زبان طبیعی^۷ است. چنین بررسی‌هایی می‌تواند میزان تعمیم‌پذیری^۸ و پایداری روش هرس داده‌ی پویا مبتنی بر عدم قطعیت را در سناریوهای واقعی و مقیاس‌پذیرتر روشن سازد.

از سوی دیگر، ترکیب روش ارائه‌شده با تکنیک‌های فشرده‌سازی مدل^۹ نظیر هرس پارامترها^{۱۰}، کوانتیزاسیون^{۱۱} می‌تواند به کاهش هم‌زمان هزینه‌های داده‌ای و مدل منجر شود و کارایی کلی سامانه‌های یادگیری عمیق را به‌طور محسوسی افزایش دهد. علاوه بر این، از آن‌جا که فاز اولیه آموزش در روش پیشنهادی نیازمند ثبت و پردازش خروجی‌های دینامیکی مدل است، طراحی سازوکارهای سبک‌تر یا تقریبی برای کاهش سربار حافظه‌ای^{۱۲} و محاسباتی این مرحله می‌تواند کاربردپذیری روش را در مقیاس‌های بسیار بزرگ بهبود بخشد.

همچنین، توسعه‌ی رویکردهای تطبیقی^{۱۳} برای تنظیم خودکار ابرپارامترهای^{۱۴} کلیدی، از جمله طول پنجره‌های زمانی^{۱۵}، ضرایب ترکیب معیارها^{۱۶} و نرخ هرس داده، می‌تواند وابستگی روش به

¹Computational and memory complexity

²Computational overhead

³Big data

⁴Machine Learning Tasks

⁵Object Detection

⁶Image Segmentation

⁷Natural Language Processing

⁸Generalization

⁹Model Compression

¹⁰Parameter Pruning

¹¹Quantization

¹²Memory Overhead

¹³Adaptive Approaches

¹⁴Hyper parameters

¹⁵Sliding Window Length

¹⁶Criterion Combination Coefficients

تنظیمات دستی را کاهش داده و پایداری آن را در شرایط مختلف آموزشی افزایش دهد. در نهایت، بررسی قابلیت استفاده از این روش در چارچوب‌های یادگیری برخط^۱ و یادگیری فعال^۲، که در آن‌ها محدودیت منابع محاسباتی و تغییرپذیری توزیع داده‌ها چالش‌های اصلی محسوب می‌شوند، می‌تواند مسیرهای پژوهشی نوینی را برای توسعه‌ی هرس داده‌ی پویا مبتنی بر عدم قطعیت فراهم آورد.

^۱Online Learning

^۲Active Learning

واژه‌نامه

Hyperparameters	ابریپارامتر
Data Augmentation	افزایش داده
Score	امتیاز
Overconfidence	بیش اعتمادی
Overfitting	بیش برازش
Feature Vector (Input)	بردار ویژگی‌ها
Label	برچسب
Smoothing Parameter	پارامتر هموارسازی
Computational Complexity	پیچیدگی محاسباتی
Sliding Time Window	پنجره زمانی لغزان
Preprocessing	پیش پردازش
Loss Function	تابع زیان
Regularization Function	تابع منظم‌سازی
Transformers	ترنسفورمرها
Nonlinear Combination	ترکیب غیرخطی
Generalization	تعمیم‌پذیری
Dataset Distillation	تقطیر دادگان
Snapshot-based	تصویر لحظه‌ای
Prediction Margin	حاشیه پیش‌بینی
Model Sensitivity	حساسیت مدل
Autoencoder	خودرمزگذار
Data	داده
Outliers	داده پرت
Informative Data	داده‌های پراطلاع
Big Data	داده‌های کلان
Decision Tree	درخت تصمیم
Epochs	دوره آموزش

Overlap Coefficient	ضریب هم پوشانی
Exponential Smoothing Coefficient	ضریب هموارسازی نمایی
Uncertainty	عدم قطعیت
Entropic Uncertainty	عدم قطعیت آنتروپیک
Power Law	قانون توانی
Encoder–Decoder Approach	کدگذاری و رمزگشایی
Exponential Moving Average (EMA)	میانگین گیری نمایی
Hessian Matrix	ماتریس هسین
Second-order Derivatives	مشتقات مرتبه دوم
Power Law Scaling	مقیاس پذیری قانون توانی
Exponential Scaling	مقیاس پذیری نمایی
Regression Models	مدل های رگرسیونی
Observations	مشاهدات
Training Set	مجموعه آموزشی
Test Set	مجموعه آزمایشی
Validation Set	مجموعه اعتبارسنجی
Dataset	مجموعه داده
Classification Problem	مسئله کلاس بندی
Batch Normalization	نرمال سازی دسته ای
Layer Normalization	نرمال سازی لایه ای
Pruning Ratio	نرخ هرس
Redundant Samples	نمونه های بسیار مشابه
Data Pruning	هرس داده
Forgetting-based Pruning	هرس داده ها بر اساس معیارهای فراموشی
Geometric Clustering-based Pruning	هرس بر اساس خوشه بندی هندسی
Local Influence Pruning	هرس بر اساس اثر محلی
Influence Function-based Pruning	هرس مبتنی بر تابع اثر
Confidence-based Pruning	هرس مبتنی بر اطمینان مدل
Error-based Pruning	هرس مبتنی بر خطای پیش بینی
Model-based Pruning	هرس مبتنی بر مدل
Model Sensitivity-based Pruning	هرس مبتنی بر حساسیت مدل به داده ها
Stability	پایداری
Robustness	مقاومت
Active Learning	یادگیری فعال
Deep Learning	یادگیری عمیق

Machine Learning	یادگیری ماشین
Semi-supervised Learning	یادگیری نیمه نظارتی
Convolutional Neural Networks	شبکه‌های عصبی کانولوشنی
Computational Overhead	سر بار محاسباتی

- [1] C. Agarwal, N. Beckmann, and A. G. Wilson. Data pruning in the age of foundation models. *arXiv preprint arXiv:2305.02241*, 2023.
- [2] N. Agarwal, B. Bullins, and E. Hazan. Second-order stochastic optimization for machine learning in linear time. In *Conference on Machine Learning (ICML)*, 2017.
- [3] C. C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015.
- [4] C. C. Aggarwal. *Outlier Analysis*. Springer, 2nd edition, 2017.
- [5] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander. Optics: Ordering points to identify the clustering structure. In *Proceedings of the 1999 ACM SIGMOD International Conference on Management of Data*, pages 49–60, 1999.
- [6] E. Barshan, M. Brunet, and G. R. G. Lanckriet. Relating input concepts to model behavior via shapley influence functions. *International Conference on Machine Learning (ICML)*, 2020.
- [7] S. Basu, P. Hennig, and M. Kloft. On second-order group influence functions for black-box predictions. In *International Conference on Machine Learning (ICML)*, pages 715–725, 2020.

- [8] S. Basu, P. W. Koh, T. Hashimoto, and P. Liang. Influence functions in deep learning are fragile. In *International Conference on Learning Representations (ICLR)*, 2021.
- [9] M. I. Belghazi, A. Baratin, S. Rajeshwar, S. Ozair, Y. Bengio, A. Courville, and D. Hjelm. Mutual information neural estimation (mine). In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- [10] V. Birodkar, H. Mobahi, and S. Bengio. Semantic redundancies in image-classification datasets: The 10% you don’t need. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 44(9):5056–5070, 2022.
- [11] V. Birodkar and L. P. Semantic redundancy in big data. *Journal of Machine Learning*, 2019.
- [12] L. Breiman, J. Friedman, R. Olshen, and C. Stone. *Classification and Regression Trees*. Wadsworth International Group, 1984.
- [13] R. J. G. B. Campello, D. Moulavi, and J. Sander. Density-based clustering based on hierarchical density estimates. *Advances in Knowledge Discovery and Data Mining (PAKDD)*, pages 160–172, 2013.
- [14] G. Cazenavette, T. Wang, A. Torralba, A. A. Efros, and J.-Y. Zhu. Dataset distillation by matching training trajectories. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [15] G. Chandrashekar and F. Sahin. A survey on feature selection methods. *Computers & Electrical Engineering*, 40(1):16–28, 2014.

- [16] C. Coleman, C. Yeh, S. Mussmann, B. Mirzasoleiman, P. Bailis, P. Liang, J. Leskovec, and M. Zaharia. Selection via proxy: Efficient data selection for deep learning. In *International Conference on Learning Representations (ICLR)*, 2019.
- [17] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *CVPR*, 2009.
- [18] Z. Deng and O. Russakovsky. Remember the past: Distilling datasets into addressable memories for neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [19] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 226–231, 1996.
- [20] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 226–231, 1996.
- [21] P. A. Estévez, H. M. Gutiérrez, and C. M. A. Vidal. Geometric perspectives in data pruning and representation learning. *Pattern Recognition Letters*, 135:132–140, 2020.
- [22] V. Feldman, C. Zhang, S. Gunasekar, and I. Mironov. What neural networks memorize and why: Discovering the long tail via influence estimation. *Advances in Neural Information Processing Systems (NeurIPS)*, 33:2881–2891, 2020.

- [23] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [24] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 2672–2680, 2014.
- [25] A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. In *Algorithmic Learning Theory (ALT)*, 2005.
- [26] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger. On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1321–1330, 2017.
- [27] I. Guyon and A. Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003.
- [28] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik. Gene selection for cancer classification using support vector machines. In *Machine Learning*, volume 46, pages 389–422, 2002.
- [29] G. Hacohen and D. Weinshall. On the power of curriculum learning in training deep networks. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 2535–2544, 2020.
- [30] S. Han, J. Pool, J. Tran, and W. Dally. Learning both weights and connections for efficient neural network. *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.

- [31] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [32] Y. He et al. Large-scale dataset pruning with dynamic uncertainty. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2024.
- [33] J. Hestness and L. D. Scaling deep learning models. *Journal of AI Research*, 2017.
- [34] J. Kaplan, S. McCandlish, and M. P. Scaling laws in deep learning. In *NeurIPS*, 2020.
- [35] P. W. Koh and P. Liang. Understanding black-box predictions via influence functions. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1885–1894. PMLR, 2017.
- [36] A. Krizhevsky and G. Hinton. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.
- [37] H. Kwon and B.-D. Lee. Reinforcement learning-based dataset distillation. In *AAAI*.
- [38] Y. LeCun, J. S. Denker, and S. A. Solla. Optimal brain damage. *Advances in Neural Information Processing Systems (NeurIPS)*, 2:598–605, 1990.
- [39] S. Lei and D. Tao. A comprehensive survey of dataset distillation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(1):17–32, 2024.
- [40] H. Li, C. Ma, W. Xu, and X. Liu. Feature statistics guided efficient filter pruning. In *Proceedings of the 29th International Joint Conference on Artificial Intelligence (IJCAI)*, 2020.

- [41] S. Liu, K. Wang, X. Yang, J. Ye, and X. Wang. Dataset distillation via factorization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [42] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie. A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11976–11986, 2022.
- [43] J. MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pages 281–297, 1967.
- [44] B. Mirzasoleiman, J. Bernstein, and J. Bilmes. Core-set selection for efficient neural network training. In *International Conference on Machine Learning (ICML)*, 2020.
- [45] B. Mirzasoleiman and K. T. Coresets for efficient data processing in large datasets. *IEEE Transactions*, 2020.
- [46] P. Molchanov, S. Tyree, T. Karras, T. Aila, and J. Kautz. Pruning convolutional neural networks for resource efficient inference. In *International Conference on Learning Representations (ICLR)*, 2017.
- [47] T. Nguyen, Z. Chen, and J. Lee. Dataset metalearning from kernel ridge regression. In *International Conference on Learning Representations (ICLR)*, 2021.
- [48] T. Nguyen, Z. Chen, and J. Lee. Dataset metalearning from kernel ridge regression. In *International Conference on Learning Representations (ICLR)*, 2021.
- [49] R. Panda, K. Subramanian, and B. Raj. Probabilistic data pruning via stochastic forgetting. In *Conference on Neural Information Processing Systems (NeurIPS)*, 2023.

- [50] M. Paul, S. Ganguli, and G. K. Dziugaite. Deep learning on a data diet: Finding important examples early in training. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 20596–20607, 2021.
- [51] M. Paul, C. Zhang, and S. Bengio. Data valuation using reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [52] T. Paul and C. D. Deep dataset pruning. *Journal of Artificial Intelligence Research*, 2021.
- [53] G. Pleiss, T. Zhang, E. Elenberg, and K. Q. Weinberger. Identifying mislabeled data using the area under the margin ranking. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 17044–17056, 2020.
- [54] G. Pruthi, F. Liu, S. Kale, and M. Sundararajan. Estimating training data influence by tracing gradient descent. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 19920–19930, 2020.
- [55] J. R. Quinlan. Simplifying decision trees. In *International Journal of Man-Machine Studies*, volume 27, pages 221–234, 1987.
- [56] J. R. Quinlan. *C4.5: Programs for Machine Learning*. Morgan Kaufmann, 1993.
- [57] S. Ramaswamy, R. Rastogi, and K. Shim. Efficient algorithms for mining outliers from large data sets. In *ACM SIGMOD Conference*, pages 427–438, 2000.
- [58] P. J. Rousseeuw and M. Hubert. Robust statistics for outlier detection. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 1(1):73–79, 2005.

- [59] B. Schölkopf, A. Smola, R. C. Williamson, and P. L. Bartlett. New support vector algorithms. *Neural Computation*, 12(5):1207–1245, 2001.
- [60] O. Sener and S. Savarese. Active learning for convolutional neural networks: A core-set approach. In *International Conference on Learning Representations (ICLR)*, 2018.
- [61] B. Sorscher, S. Ganguli, and D. Yamins. Beyond neural scaling laws: Beating power law scaling via data pruning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [62] F. P. Such, A. Rawal, J. Lehman, K. O. Stanley, and J. Clune. Generative teaching networks: Accelerating neural architecture search by learning to generate synthetic training data. In *International Conference on Machine Learning (ICML)*, pages 9206–9216, 2020.
- [63] P. Sucholutsky and M. Schonlau. Soft-label dataset distillation. In *NeurIPS*, 2021.
- [64] M. Sundararajan, A. Taly, and Q. Yan. Axiomatic attribution for deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 3319–3328, 2017.
- [65] L. Theis, W. Shi, A. Cunningham, and F. Huszár. Lossy image compression with compressive autoencoders. *International Conference on Learning Representations (ICLR)*, 2018.
- [66] M. Toneva, A. Sordoni, R. T. des Combes, A. Trischler, Y. Bengio, and G. J. Gordon. An empirical study of example forgetting during deep neural network learning. In

Proceedings of the 7th International Conference on Learning Representations (ICLR), 2019.

- [67] M. Toneva, A. Sordoni, R. Tachet des Combes, A. Trischler, Y. Bengio, and G. J. Gordon. An empirical study of example forgetting during deep neural network learning. In *International Conference on Learning Representations (ICLR)*, 2019.
- [68] K. Wang, B. Zhao, X. Peng, Z. Zhu, S. Yang, G. Huang, X. Wang, and Y. You. Cafe: Learning to condense dataset by aligning features. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [69] T. Wang, J.-Y. Zhu, and A. Torralba. Dataset distillation. In *ICLR*, 2018.
- [70] X. Xia, J. Liu, J. Yu, X. Shen, B. Han, and T. Liu. Moderate coreset: A universal method of data selection for real-world data-efficient deep learning. In *International Conference on Learning Representations (ICLR)*, 2022.
- [71] C.-K. Yeh, J. Kim, I. E.-H. Yen, and P. Ravikumar. Representer point selection for explaining deep neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 9291–9301, 2018.
- [72] X. Zhang, J. Du, Y. Li, W. Xie, and J. T. Zhou. Spanning training progress: Temporal dual-depth scoring (tdds) for enhanced dataset pruning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.
- [73] B. Zhao and H. Bilen. Dataset condensation with distribution matching. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023.

- [74] B. Zhao and H. Bilen. Dataset condensation with distribution matching. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 651–660, 2023.
- [75] B. Zhao, Z. Lin, and J. Zhu. Dataset condensation with gradient matching. In *ICML*, 2021.
- [76] B. Zhao, K. R. Mopuri, H. Bilen, K. Wang, et al. Dataset condensation with gradient matching. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1):180–195, 2022.

Abstract

With the increasing volume of data in deep learning tasks, computational costs, training time, and energy consumption have risen significantly, while the growth of data does not always lead to a proportional improvement in model performance. Therefore, data pruning has been proposed as an effective approach to reduce the size of training datasets while maintaining model efficiency. In this thesis, a dynamic, uncertainty-based data pruning method is presented, aimed at identifying and removing less important and unnecessary data during the training process.

In the proposed method, the importance of data is evaluated adaptively based on the model's behavior throughout training, using a time-based dynamic scoring mechanism. By leveraging a two-level temporal scoring strategy, this mechanism effectively distinguishes between less significant and influential data, gradually refining the training dataset. Empirical evaluation results show that the proposed method can remove a substantial portion of the data with minimal accuracy loss, while maintaining stability throughout the learning process. These results indicate that dynamic, uncertainty-based data pruning can serve as an efficient solution for improving scalability and reducing the training costs of deep learning models.

Keywords: Data pruning, deep learning, uncertainty, two-level scoring, sample selection, scalability



University of Tehran

College of Science

School of Mathematics, Statistics, and Computer Science

Large-scale Dataset Pruning with Dynamic Uncertainty

Author

Bahar Niknam

Supervisor

Dr. Hedieh Sajedi

A thesis submitted to graduate studies office in partial fulfillment of the requirements for the
degree of master of science in Mathematical Statistics

December 2025